표현 이질적 캐스케이드 웹 공격 탐지: 넘김 판단의 한계와 개선, 배포 조건별 속도–정확도 교환의 재평가

Representation-Heterogeneous Cascades for Web Attack Detection: Limits and Improvement of Deferral Decisions, and a Re-evaluation of Speed–Accuracy Trade-offs under Deployment Conditions

요 약

웹 요청을 48×48 바이트 이미지로 바꾸어 얕은 CNN으로 분류하는 방식은 문자 수준 CNN보다 정확도가 유의하게 낮았다. 본 논문은 이 음성 결과에서 출발하여, 이미지 CNN이 모든 요청을 먼저 보고 확신도가 낮은 요청만 문자 수준 CNN으로 넘기는 표현 이질적 캐스케이드를 실트래픽 기반 SR-BH 2020에서 다시 평가한다. 공개 페이로드 모음 기반의 이전 데이터셋에서 이 구조는 2차 모델보다 5.07배 빨랐다. 그러나 SR-BH에서는 2차 입력을 최대 길이로 채우고 순전파만 재는 기존 방식으로도 요청 단위 CPU 처리의 이득이 1.22배, 선행 연구가 가정한 배포 공격 비율(3.3%)에서는 0.99배였고, 1차를 클래스 가중치로 학습해도 1.63배와 1.42배에 그쳤다. 전처리를 포함하고 채움을 없앤 기준으로 다시 재자 1차(1.311ms)가 2차(0.393ms)보다 느려 캐스케이드는 2차 단독의 0.27배였고, 측정 전에 정한 규칙에 따라 요청 단위 CPU 처리의 속도 이득 주장을 철회한다. 같은 인코딩을 1차원 합성곱으로 읽는 1차는 Macro-F1이 3.9%p 높았지만(Holm $p=0.009$) 배수는 0.28배였다. 이미지 변환만으로도 2차 전체보다 오래 걸리기 때문이다. 반대로 1차를 문자 n-그램 TF-IDF 선형 모델로 바꾸면 1.24배(실사용자 정상 요청에서는 0.86배)로 이미지 1차의 4.7배였다. 표현 이질성은 두 단계의 오류를 덜 겹치게 했으나(Q 통계량 0.954 대 0.996) 속도 이득의 필요조건이 아니었다. 넘김 판단의 개선은 측정 전에 정한 채택 기준을 충족하지 못했다. 5-fold 교차검증에서 확신도 게이트는 이상적 라우터보다 평균 10.5배 많이 넘겼고, 확신도 신호 교체, 1차 내부 표현을 쓰는 로지스틱 회귀 라우터, 특징 공간 거리 점수(넘김 46~128% 증가) 모두 기준에 미달하였다. 예측 클래스별 임계값은 분할을 바꾼 세 번의 확인 실험 모두에서 정확도-속도 경계가 표준 확신도 넘김보다 위였으나 유의하지 않았고($p=0.17$~0.41), 운영점의 이득도 기준에 미달하였다. fold 5개의 비교라 검정력이 낮아, 이는 개선이 없다는 증거가 아니라 개선을 검출하지 못했다는 뜻이다. 또한 시험 집합의 넘김률 기준을 통과한 게이트가 정상 요청의 넘김을 늘려 배포 조건의 속도를 오히려 낮춘 사례를 보이고, 게이트를 평가할 때 정상 요청의 넘김률과 공격 비율로 재가중한 속도 배수를 함께 보고할 것을 제안한다. 1차가 강하게 확신하고 틀린 요청 110건 가운데 70.9%는 라벨 불일치로 판정되어(대조 집합 31.8%, 대형 언어모델 단일 판정), 데이터셋 라벨 잡음이 넘김 판단 평가의 목표 자체에 섞여 있을 가능성을 보였다.

ABSTRACT

Classifying web requests as 48×48 byte images with a shallow CNN was significantly less accurate than a character-level CNN. Starting from this negative result, we re-evaluate on the SR-BH 2020 dataset a representation-heterogeneous cascade in which an image CNN screens every request and defers only low-confidence requests to a character-level CNN. On an earlier payload-collection dataset the cascade was 5.07 times faster than the second-stage model. On SR-BH, even under the earlier protocol (forward pass only, second-stage input padded to the maximum length) the speedup for single-request CPU inference was 1.22×, and 0.99× at the 3.3% attack rate assumed in prior work; training the first stage with class weights raised these only to 1.63× and 1.42×. Under a protocol that includes preprocessing and removes padding, the first stage (1.311 ms) was slower than the second (0.393 ms), so the cascade ran at 0.27× the speed of the second stage alone; following a pre-specified rule we withdraw the speedup claim for single-request CPU inference. A first stage that reads the same encoding with 1-D convolutions gained 3.9 percentage points of Macro-F1 (Holm $p=0.009$) but still gave 0.28×, because image conversion alone takes longer than the entire second stage. Replacing the first stage with a character n-gram TF-IDF linear model gave 1.24× (0.86× on real-user benign traffic), 4.7 times the image first stage. Representation heterogeneity made the errors of the two stages overlap less (Q statistic 0.954 versus 0.996) but was not necessary for a speedup. Improvements to the deferral decision did not meet pre-specified acceptance criteria. In 5-fold cross-validation the confidence gate deferred 10.5 times more requests than an oracle router, and replacing the confidence signal, a logistic-regression router using the first stage's internal representation, and feature-space distance scores (46–128% more deferral) all fell short. Class-wise thresholds lay above standard confidence deferral on the accuracy-speed frontier in all three confirmation runs on new splits, but not significantly

(p=0.17–0.41), and the gain at the operating point also fell short of the criterion. With five folds these tests have low power, so they indicate an undetected rather than an absent improvement. We further show gates that passed a test-prevalence deferral criterion yet slowed the cascade at deployment attack rates by deferring more benign requests, and recommend reporting benign deferral rates and prevalence-reweighted speedups when evaluating gates. Finally, 70.9% of 110 confidently misclassified requests were judged to be mislabeled by a single large-language-model rater (31.8% in a control set), suggesting that label noise contaminates the target against which deferral is evaluated.

Keywords: Web attack detection, Cascade inference, Learning to defer, Byte image, Inference latency

I. 서론

웹 애플리케이션 방화벽(web application firewall, WAF)에 기계학습 탐지기를 붙이려면 정확도와 함께 요청 하나를 처리하는 데 드는 시간을 따져야 한다. 탐지기는 모든 요청의 경로 위에 놓이므로, 정확한 모델이라도 느리면 서비스 지연으로 바로 이어진다. 보안 분야 기계학습 평가에서 실험 조건과 배포 조건이 어긋나 결과가 과장되는 문제는 이미 여러 차례 지적되었다[1].

본 연구는 원래 다음 질문에서 출발하였다. 악성코드 바이너리를 이미지로 바꾸어 분류하는 방법[2]처럼, 웹 공격 요청을 바이트 이미지로 바꾼 CNN이 텍스트 기반 모델과 비슷하거나 더 나은 성능을 내는가(Q1). 답은 “아니오”였다. 48×48×3 이미지를 입력으로 받는 얕은 CNN(이하 RGB CNN)은 문자 수준 CNN(이하 char-CNN)보다 Macro-F1이 유의하게 낮았다(V장 5.1절). 이 결과를 감추거나 질문을 바꾸지 않고 그대로 보고한다.

다만 고정 길이 입력의 순전파로 재면 RGB CNN은 char-CNN보다 가볍다. 두 모델은 같은 요청을 서로 다른 표현(2차원 바이트 배치와 1차원 문자열)으로 보므로 틀리는 요청도 다르다. 여기서 두 번째 질문이 나왔다. 값싼 RGB CNN이 모든 요청을 먼저 판정하고 확신도가 낮은 요청만 char-CNN으로 넘기면(이하 캐스케이드), char-CNN 수준의 정확도를 더 낮은 비용으로 얻을 수 있는가(Q2). 공개 페이로드 모음을 쓴 이전 실험에서는 그렇게 보였다. 요청의 8%만 넘기고도 Macro-F1은 char-CNN에 0.2%p 뒤졌을 뿐이며 지연은 5.07배 낮았다.

이 수치는 두 가지 이유로 다시 측정할 필요가 있었다. 첫째, 이전 데이터셋의 공격 표본은 페이로드 문자열만으로 이루어져 표면 토큰만으로도 분류가 거의 포화되어 있었다. 둘째, 5.07배는 GPU에서 512개씩 묶어 처리한 값이다. 요청이 하나씩 들어오는 WAF 환경, 그리고 대부분의 요청이 정상인 배포 환경에서도 같은 이득이 나는지는 확인되지 않았다. 캐스케이드의 넘김 판단(이하 게이트)이 얼마나 정확한지도 따로 따져야 한다. 확신도만 보는 게이트는 2차 모델이 그 요청을 맞힐지 알지 못한다[11].

본 논문은 실트래픽 기반 SR-BH 2020 데이터셋[6]에서 이 두 가지를 측정한다. 기여는 다음과 같다.

- 본 연구의 바이트 이미지 인코딩과 얕은 CNN이 텍스트 모델에 진다는 음성 결과를 두 데이터셋에서 통계 검정과 함께 보고하고, 캐스케이드가 이 결과에서 파생된 설계임을 밝힌다. 이와 함께 캐스케이드의 속도-정확도 교환을 장치 2종 × 배치 크기 4종과 공격 비율 3종에서 다시 측정한다. 이전 데이터셋의 5.07배는 SR-BH에서 요청 단위 CPU 처리와 배포 공격 비율일 때 1배 아래로 떨어지며, 그 원인이 정상 요청의 과다 넘김에 있음을 보인다. 이 넘김은 게이트가 아니라 1차의 학습 방식으로 줄었다(0.99배 → 1.42배, 순전파 지연 기준). 나아가 전처리를 포함하고 2차 입력의 채움을 없앤 지연 기준에서는 1차가 2차보다 느려 요청 단위 CPU 처리의 속도 이득이 없음을 보이고(0.27배), 1차를 2차와 같은 문자 표현의 선형 모델로 바꾸면 이득이 생기므로(1.24배) 표현 이질성이 속도 이득의 필요조건이 아님을 보인다.
- 확신도 게이트가 이상적 라우터보다 몇 배 더 넘기는지(과잉 넘김 배율)를 5-fold 교차검증으로 측정하고, 신호 교체·클래스별 임계값·1차 내부 표현을 쓰는 학습형 라우터 어느 것도 측정 전에 정한 기준을 충족하지 못했음을 보인다. 또한 게이트를 시험 집합의 넘김률로만 평가하면 배포 조건의 속도를 거꾸로 판단할 수 있음을 실측으로 보이고, 정상 요청 넘김률과 공격 비율 재가중 배수를 함께 보고하는 평가 방식을 제안한다. 넘김에 쓰는 수치 자체를 1차 내부 표현의 거리 점수로 바꾼 경우도 MSP보다 나빴고(1차 오답 탐지 AUROC 0.20~0.87 대 0.94), 실사용자 트래픽에서는 검증 집합 기반 배포 배수가 낙관적임을 보인다. 클래스별 임계값은 분할을 바꾼 세 번의 확인 실험 모두에서 정확도-속도 경계가 표준 넘김보다 위였으나, 통계적 유의성과 운영점의 이득은 확인하지 못했다.

모든 판정 기준(대표 운영점 규칙, 헤드라인 측정 조건, 1차 학습 방식과 게이트 개선의 채택 기준)은 측정 전에 버전 관리되는 연구 기록에 고정하였다(커밋 039d7d4, b0202f4). 그 뒤의 공정 지연 재측정과 확인 실험(5.11~5.14절)의 규칙도 측정 전에 따로 고정하였다(커밋 2a456d7). 기준에 없던 비교는 탐색적 결과로 구분해 적는다. 1차 확신 오답의 라벨 감사(5.7절)는 대형 언어모델 1인 판정이라 보조 증거로만 쓴다.

II. 관련 연구

2.1 이미지 기반 보안 탐지

Nataraj 등[2]은 악성코드 바이너리의 바이트를 회색조 이미지로 그려 계열을 분류하였다. 이후 소스코드를 이미지로 바꾸어 취약점을 찾는 연구[3], 어셈블리 명령의 구문 정보를 RGB 채널에 나누어 담는 연구[4]로 이어졌다. 본 연구의 RGB 채널 구성은 이 두 계열을 따른다.

2.2 텍스트 기반 웹 공격 탐지

웹 공격 탐지는 대부분 요청 문자열을 직접 다룬다. Tadhani 등[5]은 CNN과 LSTM을 결합해 XSS와 SQL 삽입을 탐지하였다. SR-BH 2020[6]은 실제 웹 서버에 들어온 요청에 CAPEC 기반 다중 라벨을 붙인 데이터셋으로, 공개 페이로드 모음과 달리 요청 전체(URI, 본문, 헤더)를 담는다.

2.3 캐스케이드와 넘김 판단

Wang 등[7]은 사전학습된 모델을 확신도 임계값으로 잇기만 해도 같은 정확도에서 큰 모델보다 수 배 빠르다는 것을 보였다. 웹 공격 탐지에서도 Tasdemir 등[8]은 가벼운 1차 모델과 BERT 2차 모델의 캐스케이드로 약 20배의 속도 향상을 보고하였고(SQL 삽입 단일 공격, 비교 기준은 BERT 단독), 2단 구성의 WAF 탐지기[9]와 실시간 제로데이 탐지 캐스케이드[10]도 제안되었다. 이들 수치는 2차 모델과 측정 조건이 서로 달라 직접 비교할 수 없다.

넘김 규칙은 일반 기계학습에서 별도로 연구되었다. 최대 소프트맥스 확률(maximum softmax probability, MSP)은 오분류 탐지의 기준선이다[12]. 선택적 분류는 1차 모델의 기각을 위험-커버리지 교환으로 다루고[13], 넘김 학습(learning to defer)은 뒤의 결정자를 고려해 넘길 대상을 학습한다[14][15]. Kag 등[16]은 엣지 모델과 라우터를 함께 학습해 서버 모델이 맞힐 어려운 예제만 보냈다. Jitkrittum 등[11]은 최적 넘김 규칙이 두 모델의 정답 확률 차이에 달려 있으므로 1차 확신도만 보는 규칙은 2차의 정오를 알 수 없고, 2차가 일부 입력에만 강하거나 라벨에 잡음이 있을 때 실패한다는 것을 보였다. 본 연구의 학습형 라우터는 이 분석이 권하는 대로 "1차는 틀리고 2차는 맞는가"를 직접 예측한다. Enomoto와 Eda[17]는 일반적인 확률 보정이 캐스케이드에서는 오히려 해로울 수 있음을 보고하였다. 조기 종료 신경망[18]은 한 모델 안에서 같은 발상을 쓴다.

2.4 지연과 측정 조건

Hong 등[19]은 입력을 조작해 조기 종료를 막는 지연 유발 공격을 보였다. 캐스케이드의 비용이 입력에 따라 달라진다는 점에서 본 연구의 넘김률 분석과 맞닿는다. 추론 성능은 질의를 하나씩 처리하는지, 묶어서 처리하는지에 따라 크게 달라지므로, MLPerf Inference[20]는 시나리오별로 따로 측정한다. 침입 탐지에서는 공격의 기저 비율이 낮을수록 오경보가 지배적이 된다는 기저율 문제[21]가 오래전에 지적되었다. 본 연구는 이 문제를 캐스케이드 지연과 게이트 평가에 적용한다.

III. 방법

3.1 요청의 이미지 변환

요청에서 URI와 본문을 이어 붙인 바이트열 b의 앞 2,304바이트를 48×48 격자에 행 우선으로 배치한다. 짧은 요청은 0으로 채운다.

$$x[r, c] = b[48r + c],\ 0 \le r, c < 48 \tag{1}$$

세 채널에는 같은 위치의 다른 정보를 담는다. R은 원래 바이트 값, G는 문자 종류(영문·숫자·특수문자 등), B는 그 위치 주변 n-gram의 지역 엔트로피이다. 이전 데이터셋에서 1채널 회색조를 3채널로 바꾸었을 때 정확도가 올랐고, 채널 조합 사이의 차이는 유의하지 않았다. 변환 예는 Fig. 1과 같다. SR-BH의 요청은 대부분 짧다(중앙값 96바이트, 99백분위 353바이트). 격자에서 채워지는 행 수의 중앙값은 2줄이고, 픽셀의 약 95%가 패딩이다.



Fig. 1. Byte images of SR-BH 2020 requests (URI and body, 48×48, RGB). Most requests are short (median 96 bytes) and fill only the top few rows (median two).

3.2 1차·2차 모델과 1차 학습 방식

1차 RGB CNN은 합성곱 3단(32·64·128 채널, 배치 정규화, ReLU, 최대 풀링)과 전역 평균 풀링, 완전연결층으로 이루어지며 파라미터는 93,988개이다. 2차 char-CNN은 같은 바이트열을 1차원 문자 시퀀스로 받는다. 바이트(257개 기호, 패딩 포함)를 64차원으로 임베딩하고, 커널 크기 3·5·7의 1차원 합성곱(각 128채널)

과 시간축 최대 풀링을 거쳐 완전연결층으로 분류한다. 입력은 2,304바이트로 패딩하며 파라미터는 141,252개이다. 두 모델은 각각 따로 학습하며, 캐스케이드는 학습된 두 모델을 추가 학습 없이 잇는다. 따라서 캐스케이드가 줄이는 것은 추론 비용뿐이고 학습 비용은 두 모델의 합이다.

SR-BH는 클래스가 크게 불균형하다(Table 1). 1차는 두 방식으로 학습해 비교한다. (가) 언더샘플링: 학습 집합의 각 클래스를 가장 작은 클래스(CmdI, 3,886행)에 맞춰 무작위로 줄여 15,544행으로 학습한다. (나) 클래스 가중치: 학습 집합 186,157행을 모두 쓰고 손실에 클래스 빈도의 역수에 비례하는 가중치를 준다. 2차 char-CNN은 두 경우 모두 (가)로 학습한 같은 모델을 써서 1차의 효과만 분리한다.

3.3 캐스케이드와 확신도 게이트

1차 모델의 클래스 확률을 $p_1(k|x)$, 확신도를 $s(x) = \max_k p_1(k|x)$라 할 때 캐스케이드의 예측은 다음과 같다.

$$\hat{y}(x) = h_1(x) \text{ if } s(x) \geq \tau, \text{ otherwise } h_2(x) \tag{2}$$

임계값 τ는 검증 집합에서 넘김 예산 b(넘길 요청의 비율)에 해당하는 확신도 분위수로 정하고, 시험 집합에는 한 번만 적용한다. $\tau \to 0$이면 RGB CNN 단독, $\tau \to 1$이면 char-CNN 단독과 같다. 이 단일 임계값 게이트를 B0라 부른다.

3.4 과잉 넘김 배율

이상적 라우터(오라클)는 1차가 틀리는 요청만 넘긴다. 그 넘김률을 e_o, 게이트가 2차 단독 Macro-F1에 도달하는 데 필요한 최소 넘김률을 e_g라 하면 과잉 넘김 배율은 다음과 같다.

$$\rho = e_g / e_o \tag{3}$$

ρ=1이면 게이트가 오라클만큼 효율적이고, ρ가 클수록 1차가 맞힌 요청을 불필요하게 넘긴다.

3.5 지연과 공격 비율

요청 하나의 1차·2차 지연을 t_1, t_2, 넘김률을 r이라 하면 캐스케이드의 기대 지연과 char-CNN 단독 대비 속도 배수 S는 다음과 같다. 학습형 라우터를 쓰면 그 지연 t_g를 t_1에 더한다.

$$t = t_1 + r \cdot t_2, \quad S = t_2 / t \tag{4}$$

넘김률은 정상 요청(r_N)과 공격 요청(r_A)에서 다르다. 공격 비율이 π 인 환경의 넘김률은 다음과 같이 다시 가중한다.

$$r(\pi) = \pi \cdot r_A + (1 - \pi) \cdot r_N \tag{5}$$

배포 환경의 공격 비율은 시험 집합(74.8%)보다 훨씬 낮으므로, $\pi \in \{74.8\%, 3.3\%, 0.1\%\}$ 에서 S를 함께 보고한다. 3.3%는 Tasdemir 등[8]이 쓴 기저 비율이고, 0.1%는 공격이 드문 환경을 나타내는 가정값이다. π가 작으면 $r(\pi)$는 r_N에 수렴한다. 식 (5)는 r_N, r_A가 π와 무관하다고, 즉 정상·공격 요청 각각의 분포는 그대로이고 비율만 바뀐다고 가정한다. 본 연구의 r_N은 스캐너가 대부분인 정상 요청에서 추정한 값이므로, 실사용자 트래픽에서는 달라질 수 있다.

3.6 예측 클래스별 임계값

단일 τ는 클래스마다 다른 확신도 분포를 하나의 기준으로 자른다. 예측 클래스 c마다 임계값 τ_c를 두어 다음과 같이 넘긴다(이하 G2).

$$\text{defer } x \Leftrightarrow s(x) < \tau_{\hat{c}_1(x)}, \quad \hat{c}_1(x) = \operatorname{argmax}_k p_1(k|x) \tag{6}$$

τ_c는 검증 집합에서 탐욕적으로 고른다. 넘김을 검증 행의 0.5% 단위로 늘리되, 매 단계 네 클래스 가운데 다음 0.5%를 넘겼을 때 검증 Macro-F1이 가장 높아지는 클래스에 배정한다. 이 탐색은 검증 목적함수에 대한 탐욕적 근사이며, 4차원 전수 탐색의 최적을 보장하지 않는다.

3.7 학습형 라우터

Jitkrittum 등[11]의 분석에 따르면 넘길 가치가 있는 요청은 "1차는 틀리고 2차는 맞는" 요청이다. 이를 표적 $z(x) = \mathbb{1}[h_1(x) \neq y \wedge h_2(x) = y]$로 두고, 넘김 점수 $g(x) = P(z=1|\phi(x))$를 로지스틱 회귀로 학습한다. 점수가 높은 순서로 넘기며, 임계값은 B0와 같은 규칙으로 정한다. 특징 φ는 두 가지이다.

- G3-lite(11차원): 1차 확률 4개, MSP, 상위 두 확률의 차, 원문 통계 5개(로그 바이트 길이, 특수문자·%·숫자의 비율, 2,304바이트 초과 여부). 원문 통계는 1차 확률에 없는 정보를 2차를 돌리지 않고 얻는다.
- G3-full(139차원): G3-lite에 1차의 전역 평균 풀링 출력(128차원)을 더한다. 1차를 이미 돌렸으므로 추가 추론이 없다.

라우터는 검증 집합에서만 학습한다. 같은 점수로 임계값까지 고르면 과적합되므로, 검증 집합을 라벨 층화로 둘로 나누어 한쪽에서 학습한 라우터의 점수를 다른 쪽에 매기는 교차 적합을 하고, 시험 점수는 두 라우터의 평균을 쓴다. 특징 계산과 두 내적을 포함한 라우터의 요청당 CPU 지연은 G3-lite 0.018ms, G3-full 0.024ms 였다.

3.8 특징 공간 거리 기반 넘김 점수

MSP와 그 변형(온도 보정 MSP, 상위 두 확률의 차, 엔트로피)은 모두 1차 확률 p_1의 함수이므로, p_1이 가진 정보를 넘을 수 없다. 넘김에 쓰는 수치 자체가 맞지 않는지 확인하려고, 확률이 아니라 1차의 내부 표현 z(x)(전역 평균 풀링 출력, 128차원)에서 재는 점수 네 개를 문헌에서 그대로 가져왔다(새 점수를 만들지 않았다).

참조 집합은 그 1차를 학습한 학습 행의 표현과 라벨이며, 점수가 클수록 넘긴다.

- maha[25]: 클래스 평균과 공유 공분산(Ledoit-Wolf 수축)으로 잰 최소 마할라노비스 거리.
- rmaha[26]: 위 거리에서 학습 표현 전체의 단일 가우시안까지의 거리를 뺀 상대 마할라노비스 거리.
- knn[27]: L2 정규화 표현에서 클래스마다 2,000행을 뽑은 참조 뱅크까지의 50번째 최근접 거리.
- trust[28]: 예측 클래스 뱅크까지의 최근접 거리에 대한 다른 클래스 뱅크까지의 최근접 거리의 비(신뢰 점수)의 음수.

임계값과 운영점은 B0와 같은 규칙으로 정한다. 3.4절의 과잉 넘김 배율은 시험 집합의 공격 비율에서 잰 값이라 배포 속도와 방향이 어긋날 수 있으므로(5.6절), 이 비교의 1차 지표는 식 (5)의 배포 재가중 넘김률 $E_{\pi} = r(\pi = 3.3\%)$로 측정 전에 정하였다. 판정 기준은 교차검증에서 B0 대비 E_{π} 20% 이상 감소, 대응표본 검정의 Holm 보정(4쌍) $p<0.05$, Macro-F1 손실 0.3%p 이하, 점수 계산 지연 0.035ms(1차의 10%) 이하이며, 고정 분할에서도 E_{π} 차이의 부트스트랩 신뢰구간 상한이 0 미만이어야 개선으로 쓴다.

IV. 실험 환경

4.1 데이터셋

주 데이터셋은 SR-BH 2020[6]이다. 원본 907,815행의 CAPEC 라벨을 정상(Normal), SQL 삽입(SQLi), 코드 삽입(CodeInjection), 명령 삽입(CmdI) 4클래스로 대응시키고, 자체 시그니처 감사로 라벨이 의심되는 30,280행, 같은 입력에 다른 라벨이 붙은 행, 완전 중복을 제거하여 265,939행을 얻었다. CodeInjection은 XSS가 아니라 서버 측 PHP 코드 삽입 탐침이 대부분이다. SR-BH의 라벨은 요청 전체(헤더 포함)에 ModSecurity CRS 3.3.0을 탐지 전용으로 적용한 뒤 수작업 검토를 거쳐 붙여진 것이다[6]. 반면 본 연구의 입력은 URI와 본문뿐이므로, 헤더에만 근거가 있는 라벨은 입력에서 관찰할 수 없다. 쿠키를 더한 입력은 RGB CNN의 Macro-F1을 올렸지만, 쿠키 값을 같은 길이의 무의미한 문자로 지운 입력과의 차이를 검출하지 못해(Holm 보정 $p=0.17$) 이득의 출처(내용 대 길이·존재)를 판정할 수 없었다. 따라서 더 단순한 URI·본문 입력을 유지하였다. 70/15/15 층화 분할(seed 42)이다(Table 1).

Table 1. SR-BH 2020 track after cleaning (rows per split)

Split	Normal	SQLi	CodeInj.	CmdI	Total
Train	46,864	128,502	6,905	3,886	186,157
Validation	10,042	27,537	1,480	832	39,891
Test	10,042	27,536	1,480	833	39,891

SR-BH의 정상 요청은 대부분 취약점 스캐너의 탐색 요청이다. 중복 제거 후 97.8%가 스캐너 사용자 에이전트를 달고 있고, 실사용자 에이전트만 있는 정상 요청은 645개(시험 집합 95개)이다. 따라서 정상 요청 오탐률(FPR)은 스캐너 트래픽 기준의 값이며, 실사용자 층의 오탐 수를 함께 적는다. 비교를 위해 이전 실험의 데이터셋(공개 SQLi·XSS·CmdI 페이로드 모음과 CSIC 2010 정상 트래픽, 이하 이전 데이터셋)의 결과도 병기한다.

4.2 평가 절차

평가 지표는 Macro-F1, FPR 1%에서의 탐지율(TPR@1%FPR), 정상 요청 FPR이다. 게이트 비교의 주 판정(V장 5.4·5.5절)은 시험 집합을 건드리지 않도록 학습+검증 풀 226,048행을 5-fold로 나눈 교차검증에서 수행하였다. 각 fold에서 1차(클래스 가중치)와 2차는 같은 학습·검증 분할을 쓰고, 임계값·온도·라우터는 fold의 검증 부분에서 정하며, 평가는 fold의 시험 부분에서 한다. 속도-정확도 곡선(5.2절)과 게이트의 확인 실험(5.6절)은 고정 분할의 시험 집합에 한 번 적용하였다.

5.2~5.10절의 지연은 모델의 순전파만 재며, 이미지·시퀀스 변환 같은 전처리 시간은 포함하지 않는다. 2차 char-CNN은 모든 요청을 2,304바이트로 패딩한 고정 길이 입력으로 잰다. 클래스 편향을 피하려고 무작위로 뽑은 대표 배치를 쓰며, 조건마다 한 번 측정하였다. 장치는 GPU(RTX 4080 SUPER)와 CPU(8 스레드), 배치 크기는 1·32·128·1024이다. 헤드라인 조건은 측정 전에 CPU·배치 1로 고정하였다. 요청이 하나씩 들어오는 WAF 환경에 가장 가깝고, MLPerf의 단일 스트림 시나리오[20]에 해당한다. 두 모델의 구조는 1차 학습 방식과 무관하므로 두 구성에 같은 지연 측정값을 쓴다. 배치가 1보다 클 때 캐스케이드 지연은 식 (4)의 근사이다. 이 측정 방식은 캐스케이드에 유리하므로, 요청 문자열에서 판정까지를 채움 없이 다시 잰 값을 5.11절에 따로 보고하고 결론은 그 값을 따른다.

대표 운영점은 검증 Macro-F1이 char-CNN 단독의 검증 Macro-F1에서 0.5%p 이내로 들어오는 가장 작은 넘김 예산으로 정하였다. 측정 전에 정한 판정 기준은 다음과 같다. (1) 운영점의 헤드라인 속도 배수가 2배에 못 미치면 속도 이득을 "조건부"로 낮춘다. (2) 1차 학습 방식은 클래스 가중치 구성이 π=3.3% 헤드라인 배수를 언더샘플링 구성보다 20% 이상 높이고(1.19배 이상) 운영점 Macro-F1 손실이 0.3%p 이하이면 권장 구성으로 바꾼다. (3) 교차검증의 게이트 개선은 B0 대비 과잉 넘김 배율 20% 이상 감소와 $p<0.05$를 모두 만족해야 채택한다. (4) 고정 분할의 확인 실험은 B0 대비 시험 넘김률 5%p 이상 감소, 부트스트랩(2,000회) 95% 신뢰구간 상한 0 미만, Macro-F1 손실 0.3%p 이하를 채택 기준으로 하였다.

V. 실험 결과

5.1 이미지 단독 탐지(Q1)

SR-BH 교차검증에서 RGB CNN의 Macro-F1은 0.8949±0.0140, char-CNN은 0.9884±0.0037 이었다(5-fold 대응표본 t-검정 $p<0.001$). 고정 분할의 시험 집합에서도 RGB CNN은 학습 방식에 따라 0.8118(언더샘플링)과 0.8672(클래스 가중치)로, char-CNN의 0.9853에 크게 못 미친다. 이전 데이터셋에서는 차이가 작았지만(0.9804 대 0.9954) 방향은 같았고 교차검증에서 유의하였다. 적어도 본 연구의 행 우선 바이트 배치와 얕은 CNN으로는 두 데이터셋 모두에서 이미지 단독 탐지가 텍스트 모델을 대체하지 못한다. 다른 이미지 배치나 더 깊은 모델에 대한 결론은 아니다.

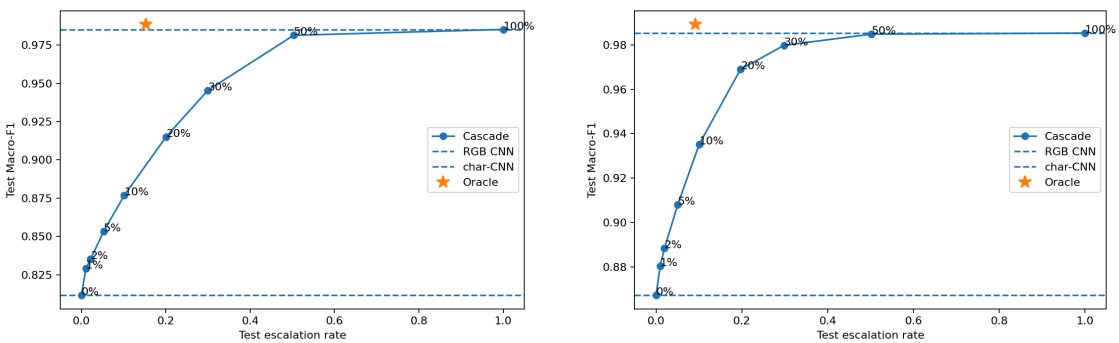
5.2 넘김 예산과 1차 학습 방식에 따른 속도–정확도 교환

Table 2와 Fig. 2는 넘김 예산에 따른 시험 집합 성능이다. 예산을 늘리면 Macro-F1이 단조롭게 오르고 곡선의 양 끝은 두 단독 모델과 일치한다. 1차를 언더샘플링으로 학습하면 대표 운영점 규칙을 처음 만족하는 예산이 50%였다(시험 0.9814). 이전 데이터셋에서 8%만 넘기면 되던 것과 크게 다르다. 클래스 가중치로 학습한 1차는 단독 Macro-F1이 0.8118에서 0.8672로, 정상 FPR이 9.38%에서 3.74%로 좋아졌고, 운영점이 30%(시험 0.9798)로 내려왔다. 같은 예산에서 비교하면 30%일 때 0.9455 대 0.9798, 20%일 때 0.9152 대 0.9690이다.

Table 2. Cascade performance on the SR-BH test split by deferral budget for two first-stage training schemes (τ chosen on validation; second stage is the same char-CNN)

Budget	First stage: undersampled				First stage: class-weighted			
	Deferred	Macro-F1	Normal FPR	Real-user FP	Deferred	Macro-F1	Normal FPR	Real-user FP
0% (RGB CNN)	0.00%	0.8118	9.38%	8/95	0.00%	0.8672	3.74%	6/95
5%	5.29%	0.8534	6.84%	7/95	5.06%	0.9080	2.32%	5/95
10%	10.17%	0.8769	4.94%	6/95	10.08%	0.9353	1.48%	5/95
20%	20.10%	0.9152	2.72%	6/95	19.71%	0.9690	1.03%	6/95
30%	29.98%	0.9455	1.65%	5/95	**29.84%**	**0.9798**	**0.90%**	**7/95**
50%	**50.30%**	**0.9814**	**0.94%**	**5/95**	50.21%	0.9848	0.79%	5/95
100% (char-CNN)	100%	0.9853	0.78%	5/95	100%	0.9853	0.78%	5/95
Oracle	15.33%	0.9886	–	–	9.16%	0.9892	–	–

Bold: operating point (smallest budget whose validation Macro-F1 is within 0.5 pp of the char-CNN).



(a) Undersampled first stage

(b) Class-weighted first stage

Fig. 2. Test Macro-F1 versus deferral rate on SR-BH 2020. Dashed lines mark the stand-alone RGB CNN (lower) and char-CNN (upper); the star is the oracle router.

두 구성 모두 운영점에서 정상 요청이 공격 요청보다 더 많이 넘겨졌다. 언더샘플링 구성은 r_N=70.7%, r_A=43.4%(실제 라벨 기준 CmdI 83.7%, SQLi 43.8%, CodeInjection 13.7%), 클래스 가중치 구성은 r_N=39.5%, r_A=26.6%(CmdI 61.2%, SQLi 26.8%, CodeInjection 2.2%)였다. 1차 학습 방식을 바꾸자 정상 넘김이 31%p 줄었다. 실사용자 층 오탐은 5/95와 7/95로, 표본이 95개뿐이라 두 구성과 char-CNN 단독(5/95)을 구별할 수 없다.

5.3 배포 조건별 지연

Table 3은 두 구성의 운영점에서 장치·배치별 속도 배수이다. 언더샘플링 구성은 헤드라인 조건(CPU·배치

1)에서 1.22배, 공격 비율 3.3%에서 0.99배로 char-CNN 단독보다 느려진다. 식 (5)에서 π가 작아지면 넘김률이 r_N=70.7%에 가까워지기 때문이다. 클래스 가중치 구성은 같은 조건에서 1.63배와 1.42배로, 측정 전에 정한 1차 학습 방식의 채택 기준(1.19배 이상, Macro-F1 손실 0.3%p 이하; 손실 0.16%p)을 충족하여 이후 권장 구성으로 삼는다. 다만 헤드라인 배수는 여전히 기준 2배에 못 미쳐 속도 이득은 "조건부"로 보고한다. 이득의 출처는 지연이 아니라 넘김률이다. 같은 지연에 넘김률만 39.1%(π=3.3%)로 바뀌었다. 이 절의 지연은 이미지 변환을 빼고 2차 입력을 2,304바이트로 채워 잰 순전파 값이다. 전처리를 넣고 채움을 없애면 CPU·배치 1의 배수는 모두 1배 아래가 되므로(5.11절), 이 절의 배수는 두 구성의 상대 비교로만 읽어야 한다.

Table 3. Per-request latency (ms) and cascade speedup S over the stand-alone char-CNN at each operating point, by device, batch size, and attack rate π

Device · batch	RGB CNN	char-CNN	Undersampled first stage (50.3%)			Class-weighted first stage (29.8%)		
			π=74.8%	π=3.3%	π=0.1%	π=74.8%	π=3.3%	π=0.1%
CPU · 1 (headline)	**0.350**	**1.114**	**1.22**	**0.99**	**0.98**	**1.63**	**1.42**	**1.41**
CPU · 32	0.132	0.901	1.54	1.18	1.17	2.25	1.86	1.85
CPU · 128	0.125	1.024	1.60	1.22	1.21	2.38	1.95	1.93
CPU · 1024	0.165	1.725	1.67	1.26	1.25	2.54	2.05	2.04
GPU · 1	0.209	0.235	0.72	0.63	0.63	0.84	0.78	0.78
GPU · 32	0.0081	0.0374	1.39	1.09	1.08	1.94	1.65	1.64
GPU · 128	0.0040	0.0699	1.79	1.32	1.31	2.81	2.23	2.21
GPU · 1024	0.0080	0.0634	1.59	1.21	1.20	2.35	1.93	1.92

Latencies from a single measurement shared by both configurations (same architectures). A separate run of the class-weighted configuration under a busier CPU gave 1.67× and 1.45× at the headline condition.

GPU·배치 1 에서는 두 모델 모두 커널 실행 오버헤드가 지배적이라 캐스케이드가 char-CNN 단독보다 느리다. 넘김이 0%일 때의 상한은 CPU·배치 1에서 t_2/t_1=3.18배이다. 이전 데이터셋의 13.6배는 GPU 처리량 비라 측정 조건이 달라 직접 비교할 수 없고, SR-BH 에서도 GPU·배치 128과 1024의 지연 비는 17.5배와 7.9배이다. 즉 상한을 낮춘 것은 데이터셋보다 요청 단위 CPU 처리라는 조건이다. 배치를 키우면 2차의 상대 비용이 커져 배수가 오르고, 클래스 가중치 구성은 GPU·배치 128에서 시험 비율 2.81배, π=3.3%에서 2.23배에 이른다. 이전 데이터셋의 5.07배(GPU·배치 512)와 가장 가까운 조건(GPU·배치 1024)에서 SR-BH의 배수는 1.59배와 2.35배이다.

5.4 확신도 신호 교체(게이트 한계)

운영점이 크게 밀린 원인이 게이트 신호에 있는지 확인하려고, MSP를 온도 보정 MSP(msp_T)[22], 상위 두 확률의 차(margin), 엔트로피로 바꾸어 교차검증에서 과잉 넘김 배율을 비교하였다(Table 4).

Table 4. Over-deferral ratio ρ of confidence signals in 5-fold cross-validation (target: stand-alone char-CNN Macro-F1 of each fold)

Fold	Oracle	MSP needs	MSP	msp_T	Margin	Entropy
1	7.98%	60.5%	7.58	7.58	7.65	7.58
2	6.29%	82.5%	13.12	12.96	12.96	12.96
3	5.95%	48.5%	8.15	8.07	8.15	8.07
4	8.29%	50.5%	6.09	6.09	6.09	6.09
5	5.59%	99.0%	17.73	15.49	15.58	15.49
Mean			**10.53**	**10.04**	**10.09**	**10.04**
Reduction vs. MSP (Holm p)				4.7% (0.96)	4.3% (0.96)	4.7% (0.96)

MSP 게이트는 오라클보다 평균 10.5배(6.1~17.7배) 많이 넘겼다. 이전 데이터셋의 단일 분할에서 측정한 14.8배와 같은 자릿수이다. 세 대체 신호는 배율을 4~5%만 줄였고 유의하지 않았다. 네 신호가 매기는 요청 순위의 상관(Spearman)은 모든 fold에서 0.997 이상이었고, 검증 집합에서 맞춘 온도는 0.99~1.06으로 1에 가까웠다. 확신도를 어떻게 요약하든 "1차가 덜 확신하는 요청"이라는 같은 집합을 고른다.

원인을 더 보려고 다섯 fold의 시험 부분을 모아 요청마다 1·2차의 정오를 나누었다(탐색적 분석). 1차 오답은 6.82%, 그 가운데 2차가 맞혀 넘길 가치가 있는 요청은 6.40% 였다. MSP는 1차 오답을 AUROC 0.938로 잘 가려냈지만, 넘길 가치가 있는 요청의 일부는 1차가 0.99 이상으로 확신한 꼬리에 있었다. 이 꼬리까지 회수해 95%를 고치려면 MSP 순서로 23.4%를 넘겨야

하고, 그 과정에서 1차가 맞힌 요청이 함께 넘어간다. 이렇게 낭비된 넘김의 53%가 정상 요청이었다.

5.5 게이트 개선: 클래스별 임계값과 학습형 라우터

신호 교체가 같은 순위를 내므로, 순위 자체를 바꾸는 두 방향을 측정 전에 정한 기준 (3)으로 검증하였다. G2는 같은 MSP에서 넘김 배분을 클래스별로 바꾸고, G3는 1차 확률 밖의 정보(원문 통계, 1차 내부 표현)로 순위를 다시 매긴다. 모든 게이트는 fold의 검증 부분에서 정한 것을 시험 부분에 적용하였다(Table 5).

Table 5. Over-deferral ratio ρ of the single threshold (B0), class-wise thresholds (G2), and learned routers (G3) in 5-fold cross-validation

Fold	Oracle	B0	G2	G3-lite	G3-full
1	7.98%	7.60	11.89	10.15	7.45
2	6.29%	13.11	7.58	7.41	12.25
3	5.95%	8.15	8.21	13.40	11.79
4	8.29%	6.10	5.45	4.99	5.88
5	5.59%	17.90	9.83	13.76	12.36
Mean		**10.57**	**8.59**	**9.94**	**9.95**
Reduction vs. B0 (paired t-test p)			18.7% (0.42)	6.0% (0.77)*	5.9% (0.69)

* G3-lite in cross-validation was not pre-specified (exploratory). B0 applies the validation-chosen threshold to fold-test, so it differs slightly from the MSP column of Table 4, which ranks fold-test directly.

G2는 평균 배율을 18.7% 줄였으나 p=0.42로 기준에 미달하였다. 효과의 방향도 fold마다 달라, B0가 거의 모든 요청을 넘겨야 했던 fold 2·5 에서는 크게 줄었지만 fold 1 에서는 오히려 늘었다. 1차 내부 표현 128차원을 더한 G3-full도 5.9%(p=0.69)에 그쳤다. 2차의 정오를 직접 표적으로 학습하고 1차가 본 정보를 모두 넣어도, 2차 단독과 같은 정확도를 요구하는 엄격한 목표에서는 넘김이 줄지 않았다. 사전 판정 기준으로 보면 세 개선 방향은 모두 기각이다.

실제 운영에서는 2차 단독과 정확히 같은 정확도보다 작은 여유를 둔 운영점이 쓰인다. 4.2절의 운영점 규칙으로 고른 결과를 Table 6에 정리하였다(탐색적).

Table 6. Operating point (validation Macro-F1 within 0.5 pp of char-CNN) in 5-fold cross-validation, fold means; S is the CPU, batch 1 estimate from Eq. (4)–(5) (exploratory)

	B0	G2	G3-lite	G3-full
Deferred (test)	24.9%	17.3%	22.4%	21.7%
Macro-F1 (test)	0.9830	0.9822	0.9835	0.9835
Benign deferral r_N	44.6%	27.4%	43.6%	39.6%
Attack deferral r_A	18.3%	13.9%	15.2%	15.6%
S (π=3.3%)	**1.34**	**1.75**	**1.49†**	**1.44†**

† Router latency excluded; including it (0.018 / 0.024 ms) lowers S by about 0.04. S is the mean of the per-fold S, not S evaluated at the mean r_N and r_A; the two differ most for G3-lite (1.49 vs. 1.35) because one fold defers 98.8% of benign requests.

여유를 둔 운영점에서는 세 게이트 모두 넘김을 줄였고, 그 크기는 정상 요청의 넘김을 얼마나 줄였는지에 따라 배포 배수로 이어졌다. G2는 줄어든 넘김의 대부분이 정상 요청이어서(r_N −17.2%p) 공격 비율 3.3%의 추정 배수를 1.34배에서 1.75배로 올렸다. G3 계열은 주로 공격 요청의 넘김을 줄여(r_A −3%p, r_N −1~5%p) 배포 배수의 이득이 작았다. 이 운영점 비교는 측정 전에 기준으로 정하지 않은 사후 분석이므로 개선으로 확정하지 않는다. G2의 임계값은 표본이 적은 CodeInjection에서 fold 간 표준편차가 0.26으로 불안정하였다.

5.6 고정 분할 확인과 게이트 평가의 함정

운영점 효과를 교차검증에 쓰지 않은 데이터에서 확인하려고, 고정 분할 시험 집합에서 기준 (4)로 G2·G3를 다시 판정하였다(Table 7 위쪽, 언더샘플링 1차). 기준은 측정 전에 정한 대로 시험 집합의 넘김률로 판정하였다. B0는 넘김 예산을 0.5% 단위로 고르므로 Table 2의 운영점(50.3%)과 조금 다르다.

Table 7. Gates at the operating point on the fixed SR-BH test split. S is CPU, batch 1, including router latency. Upper block: pre-specified confirmation (undersampled first stage); lower block: exploratory (class-weighted first stage)

First stage · gate	Deferred	Macro-F1	r_N	r_A	ρ	S (π=74.8%)	S (π=3.3%)	Verdict
Undersampled · B0	48.25%	0.9803	67.2%	41.9%	4.70	1.26	1.02	–
Undersampled · G2	39.47%	0.9795	71.0%	28.9%	4.30	1.41	0.99	accepted
Undersampled · G3-lite	47.59%	0.9809	98.3%	30.5%	4.84	1.24	0.77	rejected
Undersampled · G3-full	41.56%	0.9806	78.1%	29.3%	6.52	1.33	0.91	accepted
Class-weighted · B0	29.39%	0.9794	38.7%	26.2%	7.68	1.65	1.43	–
Class-weighted · G2	**15.29%**	**0.9779**	**22.7%**	**12.8%**	**5.24**	**2.14**	**1.86**	**(expl.)**
Class-weighted · G3-lite	24.03%	0.9766	46.7%	16.4%	4.89	1.76	1.27	(expl.)
Class-weighted · G3-full	23.11%	0.9771	43.1%	16.4%	10.92	1.77	1.32	(expl.)

언더샘플링 1차에서 G2는 넘김을 8.8%p(신뢰구간 −9.1~−8.4%p), G3-full은 6.7%p(−7.1~−6.3%p) 줄여 기준을 통과하였고, G3-lite는 0.7%p에 그쳐 기각되었다. 그러나 표의 오른쪽을 보면 결론이 달라진다. 세 게이트 모두 공격 요청의 넘김을 줄인 대신 정상 요청의 넘김을 늘렸다. 공격이 75%인 시험 집합에서는 이것이 이득이지만, 공격 비율 3.3%에서는 넘김률이 r_N에 수렴하므로 기준을 통과한 G2(0.99배)와 G3-full(0.91배)이 B0(1.02배)보다 느리다. G3-lite는 정상 요청의 98%를 넘긴다. 과잉 넘김 배율 ρ도 배포 속도와 같은 방향으로 움직이지 않았다(G3-full은 넘김을 줄였는데 ρ는 4.70에서 6.52로 나빠졌다).

이 어긋남은 사전 기준이 시험 집합의 공격 비율에서 넘김률을 쟀기 때문에 생겼다. 기준은 측정 후에 바꾸지 않고 그대로 판정했으며, 대신 이 사례를 게이트 평가의 함정으로 보고한다. 넘김 판단을 비교할 때는 시험 집합의 넘김률만이 아니라 r_N, r_A와 배포 공격 비율로 재가중한 속도 배수를 함께 보아야 한다. 클래스 가중치 1차 위에서는 G2가 정상·공격 넘김을 모두 줄여 π=3.3% 배수를 1.43배에서 1.86배로 올렸다(탐색적, 교차검증 운영점의 1.34→1.75배와 같은 방향). G3 계열은 이 구성에서도 정상 넘김을 늘려 B0보다 느렸다.

5.7 확신 오답의 라벨 감사

5.4절의 꼬리, 즉 1차가 0.99 이상으로 확신했는데 틀리고 2차는 맞힌 요청 110건을 원문으로 확인하였다. 대조로 두 모델이 모두 확신해서 맞힌 요청 110건을 무작위로 뽑아 섞고, 어느 집합인지와 모델 예측을 가린 채 원문과 라벨만 보고 "라벨이 맞다·의심·틀리다"를 판정하였다(Table 8). 판정은 대형 언어모델 한 개로 하였고 전문가 검수가 아니며, 판정자가 하나라 판정자 간 일치도는 없다.

Table 8. Label audit of confidently misclassified requests (blind to set and predictions)

Set	n	Correct	Doubtful	Wrong	Doubtful + wrong
First stage confident error, second stage correct	110	32	14	64	70.9%
Both confident and correct (control)	110	75	6	29	31.8%

Fisher's exact test: odds ratio 5.2, $p \approx 1\times10^{-8}$. By label: SQLi 62% vs. 23%, Normal 80% vs. 74%.

틀린 라벨의 대부분(64건 중 39건)은 명령 삽입 흔적(|cat /etc/passwd#, 백틱, ShellShock 문자열)이 SQLi나 정상으로 붙어 있는 경우였고, 정상 라벨에는 SQL 삽입·경로 탐색·외부 URL 삽입 탐침도 섞여 있었다. 대조 집합에서도 31.8%가 같은 문제를 보였고, 특히 정상 19건 중 14건이 공격 탐침이었다. 두 모델이 같은 잡음을 함께 학습했다는 뜻이다. 그러면 "2차가 맞혔다"는 것의 일부는 2차가 잡음까지 따라 했다는 의미가 되고, 넘김 평가의 목표인 char-CNN 단독 Macro-F1도 그만큼 잡음을 포함한다. 다만 이 110건은 넘길 가치가 있는 요청(교차검증 약 14,500건)의 0.8%라서 과잉 넘김의 주원인이 라벨 잡음이라고까지는 말할 수 없다.

5.8 특징 공간 거리 기반 넘김 점수

3.8절의 네 점수를 클래스 가중치 1차의 교차검증에서 B0(MSP)와 비교하였다(Table 9). 네 점수 모두 B0보다 유의하게 더 많이 넘겼고(Holm 보정 p는 모두 악화 방향), 점수 계산 지연도 기준(0.035ms)을 넘어 기각되었다. 고정 분할에서도 네 점수의 E_π 차이 신뢰구간이 모두 0보다 커(B0 0.383 대 trust 0.754 · knn 0.732 · maha 0.931 · rmaha 0.998) 같은 결론이었다.

Table 9. Feature-space deferral scores vs. MSP (B0) at the operating point, 5-fold cross-validation (class-weighted first stage). E_π: prevalence-reweighted deferral rate at π=3.3%; AUROC: detection of first-stage errors

Score	E_π	Change	Holm p	ΔMacro-F1	t_s (ms)	Error AUROC	Spearman w/ MSP	S (π=3.3%)	Verdict
B0 (MSP)	**0.437**	–	–	–	**0**	**0.938**	–	**1.34**	–
maha [25]	0.908	+108%	0.0005	+0.06 pp	0.063	0.203	−0.69	0.78	rejected
rmaha [26]	0.998	+128%	0.0004	+0.07 pp	0.120	0.707	0.11	0.70	rejected
knn [27]	0.784	+79%	0.0024	−0.04 pp	0.134	0.695	0.47	0.82	rejected
trust [28]	0.637	+46%	0.046	−0.11 pp	0.105	0.872	0.72	0.97	rejected

1차 오답 탐지 AUROC는 MSP(0.938)가 가장 높았고, maha는 0.203으로 역방향이었다. 1차가 틀리는 요청이 오히려 클래스 평균에 가깝다는 뜻이다. 오답은 학습 분포 밖이 아니라 클래스 덩어리가 겹치는 한가운데에 있으며, 5.7절에서 본 것처럼 정상 라벨이 붙은 탐침은 공격 덩어리 안에 놓인다. 분포 밖 입력을 찾도록 만들어진 거리 점수는 이런 오답을 원리상 잡기 어렵다. 이는 오분류 탐지에서 MSP가 대부분의 분포 밖 탐지 점수보다 강하다는 Jaeger 등[29]의 보고와 같은 방향이다. 확신도 신호 교체(5.4절)와 함께 보면, 이 데이터에서는 넘김에 어떤 수치를 쓰는가가 병목이 아니었다.

같은 교차검증 운영점을 E_π 기준으로 다시 보면 G2는 0.437을 0.270으로(−38%, 미보정 p=0.044) 줄여 π=3.3% 배수를 1.34배에서 1.75배로 올렸다. 그러나 G2의 사전 판정은 과잉 넘김 배율 기준으로 이미 기각되었고(5.5절)

E_π는 그 뒤에 정한 지표이므로, 이 값은 관찰로만 적는다. 분할을 바꾼 확인 실험은 5.12절에 있다.

5.9 실사용자 트래픽과 분포 이동에서의 넘김

식 (5)의 배포 배수는 검증 집합에서 잰 r_N이 배포 트래픽에도 성립한다고 가정한다. 그런데 검증 집합의 정상 요청은 96%가 스캐너 트래픽이다. 측정 전에 정한 기준(fold 평균 차이 +10%p 이상, $p<0.05$)으로, 교차검증 fold 시험 부분의 실사용자 정상 요청(550개) 넘김률이 fold 검증 부분의 정상 넘김률보다 높은지 확인하였다. B0의 차이는 +24.9%p(fold별 +22.8~+28.0%p, $p=1.7\times10^{-5}$)로 기준을 충족하였다. 실사용자 정상 요청의 넘김률은 B0 69.4%, G2 49.9%로, 정상 전체 검증 넘김률(44.5%, 27.1%)보다 크게 높다. 이 값으로 r_N을 바꾸면 π=3.3% 배수는 B0 1.34배 → 1.01배, G2 1.75배 → 1.28배가 된다. 즉 스캐너가 대부분인 정상 트래픽에서 잰 배포 배수는 실사용자 트래픽에서 낙관적이며, 실사용자 기준으로는 B0의 속도 이득이 사실상 사라진다.

분포 이동의 한 예로, 원본에서 정상 라벨이 붙었지만 감사 시그니처가 공격 탐침으로 판정해 트랙에서 뺀 요청 29,520개(트랙과 겹치지 않는 행)에 권장 구성을 적용하였다(서술 결과). B0는 이 중 48.3%를 넘겨(시험 집합 정상 38.7%) 57.0%를 공격으로 판정하였고(RGB CNN 단독 44.9%, char-CNN 단독 70.1%), G2는 넘김을 19.9%로 줄였지만 공격 판정률은 54.0%로 3%p 낮았다. 명령 삽입 탐침은 1차가 4.1%만 공격으로 보아 캐스케이드도 21.4%(B0)만 잡았다.

5.10 1차 폭, 2차 후보, 변형에 의한 넘김 부풀리기

1차 폭. 1차를 더 싸게 만들면 배포 배수가 오르는지 보려고, RGB CNN의 채널 폭을 ×0.5·×2로 바꿔 클래스 가중치로 다시 학습하고 같은 실행에서 지연을 쟀다(Table 10). 측정 전 기준(π=3.3% 배수가 ×1보다 20% 이상 높고 Macro-F1 손실 0.3%p 이하)을 두 폭 모두 충족하지 못하였다. ×0.5는 1차 지연을 41% 줄였지만 정상 요청의 확신도가 낮아져 E_π가 0.391에서 0.493으로 올라 이득을 상쇄하였다. 시험 집합 비율에서는 공격 요청이 많아 배수가 1.66배에서 1.96배로 오르므로, 시험 집합 기준만 보면 여기서도 판단이 뒤집힌다. ×2는 1차 지연이 2차의 73%에 이르러 캐스케이드의 전제가 무너졌다.

Table 10. First-stage width sweep (class-weighted, B0 at the operating point, CPU, batch 1, t_2 from the same run)

Width	t_1 (ms)	t_2 (ms)	Macro-F1	E_π	S (π=74.8%)	S (π=3.3%)
×0.5	0.171	0.822	0.9816	0.493	1.96	1.42
×1	**0.292**	**0.957**	**0.9798**	**0.391**	**1.66**	**1.44**
×2	0.666	0.908	0.9822	0.731	0.81	0.68

2차 후보. 권장 1차에 2차로 BiLSTM(언더샘플링 학습)과 TF-IDF(문자 2~4그램)+로지스틱 회귀를 붙여 char-CNN과 비교하였다. 측정 전 기준은 후보 곡선의 어떤 점이 지연이 같거나 작은 char-CNN 곡선의 점보다 Macro-F1이 높고 그 차이의 부트스트랩 95% 신뢰구간 하한이 0보다 크면 대안으로 병기하는 것이었다. BiLSTM(t_2 7.28ms, 단독 Macro-F1 0.959)은 모든 구간에서 char-CNN에 뒤졌다. TF-IDF(t_2 0.29ms, 단독 0.938)는 기대 지연 0.40ms 부근에서 char-CNN 곡선보다 1.84%p 높아(신뢰구간 1.44~2.23%p) 기준을 충족하였다. 그러나 TF-IDF 곡선은 단독 성능인 0.938에서 멈추므로, 운영점 목표(약 0.98)가 있는 구간에서는 char-CNN만 남는다. 더 중요한 관찰은 TF-IDF 단독(0.29ms, 0.938)이 1차 RGB CNN 단독(0.36ms, 0.867)보다 빠르고 정확하며, Macro-F1 0.938에 이르는 가장 싼 캐스케이드(0.46ms)보다도 빠르다는 점이다. TF-IDF 지연은 특징 변환을 포함하고 CNN 지연은 이미지 변환을 빼고 쟀으므로 이 비교는 TF-IDF에 불리한 쪽이다. 따라서 본 캐스케이드가 의미 있는 구간은 Macro-F1 0.94를 넘는 영역뿐이며, TF-IDF를 1차로 쓰는 구성은 5.13절에서 따로 측정한다(이 문단은 탐색적 관찰).

변형에 의한 넘김 부풀리기. 캐스케이드는 공격자가 넘김을 늘려 지연을 키우는 비용 기반 공격면을 갖는다[19]. 개선 게이트(G2)가 이 공격면을 넓히는지 보려고, 시험 집합의 공격 요청 29,849개에 표면 변형을 하나씩 적용하고 검증 집합에서 고른 임계값을 고정한 채 공격 요청 넘김률 r_A의 증가 배율을 쟀다. URL 인코딩 한 번으로 r_A는 B0 0.262 → 0.463(×1.77), G2 0.128 → 0.226(×1.76)으로 늘었고, 이중 인코딩은 ×1.83, ×2.00이었다. 대소문자 변형은 ×1.11, ×0.97에 그쳤다. 변형 평균 배율은 B0 1.28, G2 1.49로 그 비가 1.16이라, 측정 전에 정한 "게이트 개선의 대가" 기준(1.5배)에 미달하였다(행 수 가중 배율은 1.55 대 1.57). 즉 G2가 B0보다 이 공격면에 크게 더 취약하지는 않았지만, 캐스케이드 자체의 공격면은 실재한다. URL 인코딩은 넘김을 1.8배 가까이 늘리는 동시에 캐스케이드의 공격 판정률을 99.3%에서 85.5%로 떨어뜨렸다. 변형은 URI·본문 전체에 적용했으므로 일부는 HTTP 의미를 보존하지 않는다.

5.11 공정 지연 기준선

5.3절의 지연은 두 가지 점에서 캐스케이드에 유리하게 재어져 있었다. 1차는 미리 만든 이미지의 순전파만 쟀고, 2차는 모든 요청을 2,304바이트로 채워 쟀다. 측정 전에 기준을 다시 고정하고(커밋 2a456d7) 요청 문자열에서 판정까지의 전 과정을 다시 쟀다. 1차 지연에는 RGB 이미지 변환을, 2차 지연에는 바이트 부호화를 넣고, 2차에는 채우지 않은 실제 길이의 입력을 넣는다. 검증 집합에서 뽑은 2,000개 요청(길이 중앙값

97바이트, 99번째 백분위 349바이트)을 30회 반복해 중앙값을 취하고, 스레드 수를 1·4·8로 나누었다. 채우지 않은 입력과 채운 입력의 판정은 시험 집합 39,891개 중 5개만 달랐고 Macro-F1은 0.9860과 0.9857이었다. 판정 기준은 이 조건의 공격 비율 3.3% 배수가 1 미만이면 요청 단위 CPU 처리의 속도 이득 주장을 철회한다는 것이었다.

Table 11. End-to-end per-request latency (median, ms) on CPU at batch size 1, with unpadded second-stage input. S uses the class-weighted first stage with B0 at its operating point.

Component	1 thread	4 threads	8 threads
First stage: RGB image conversion	0.407	0.540	0.540
First stage: forward pass	0.879	0.586	0.399
First stage, total (t_1)	**1.311**	**1.130**	**0.945**
Second stage, padded to 2,304 bytes (as in Table 3)	2.990	1.691	1.090
Second stage, actual length, total (t_2)	**0.393**	**0.314**	**0.240**
Upper bound t_2/t_1	0.300	0.278	0.254
S (π=3.3%)	**0.268**	**0.251**	**0.231**
S (π=3.3%), forward pass only with padded second stage	1.460	1.356	1.321

공정한 기준에서는 1차 RGB CNN(1.311ms)이 2차 char-CNN(0.393ms)보다 3.3배 느리다. 상한 t_2/t_1이 1보다 작으므로 넘김을 0으로 줄여도 캐스케이드는 char-CNN 단독보다 빠를 수 없다. 세 스레드 조건 모두에서 철회 기준이 충족되어, 요청 단위 CPU 처리에서 캐스케이드가 2차 단독보다 빠르다는 주장은 철회한다. 5.2~5.10절의 속도 배수는 측정 오류가 아니라 2차 입력을 최대 길이로 채우는 구현을 전제한 값이며(8 스레드에서 순전파만 재면 0.399ms와 1.090ms로 5.3절의 0.350ms, 1.114ms와 일치한다), 이하 "채움 기준"으로 구분한다. 채움을 없애는 것만으로 2차는 7.7배 빨라진다. 실제 캐스케이드 경로를 그대로 실행해 잰 지연(1 스레드 1.418ms)은 식 (4)의 값과 3.8% 이내로 맞았다.

GPU에서 요청을 묶어 처리하는 조건도 다시 쟀다(순전파). 묶음 안의 가장 긴 요청 길이까지만 채우면 상한 t_2/t_1은 배치 32에서 0.86, 128에서 1.49, 1024에서 1.89이고, 2,304바이트로 채우면 3.35, 15.8, 7.9이다. 5.3절의 GPU 배수 역시 채움이 만든 값이 대부분이며, 캐스케이드가 이득을 볼 여지는 GPU의 큰 배치 조건에 상한 2배 미만으로만 남는다.

5.12 클래스별 임계값의 확인 실험

5.8절의 G2 관찰은 G2를 찾아낸 바로 그 교차검증 분할에서 나온 값이다. 측정 전에 판정 규칙을 고정하고 (커밋 2a456d7), 분할 seed를 바꾸어 두 모델을 처음부터 다시 학습한 교차검증에서 B0와 G2를 비교하였다. 비교는 한 점이 아니라 정확도-속도 경계에서 한다. 각 게이트에 대해 넘김률 E_π 이하에서 낼 수 있는 가장 높은 fold 시험 Macro-F1을 잇고, 미리 정한 네 지점(E_π = 48.6, 35.3, 25.7, 18.6%)에서 두 경계를 비교한다. 1차 규칙은 네 지점 모두에서 fold 평균이 G2 쪽으로 높고 세 지점 이상에서 4개 이상의 fold가 같은 방향이면 "경계가 위"로 쓰되, fold별 네 지점 평균 차이의 보정 t-검정[30]이 $p \geq 0.05$이면 유의성을 확인하지 못했다고 함께 적는 것이다. 2차 규칙은 검증 부분에서 고른 운영점의 π=3.3% 배수가 B0보다 20% 이상 높고 $p<0.05$, Macro-F1 손실 0.3%p 이하일 때 운영점의 이득으로 쓰는 것이다.

Table 12. Pre-specified confirmation of class-wise thresholds on a new cross-validation split (seed 43): frontier Macro-F1 at four deferral levels, G2 minus B0 in percentage points, and the number of folds in which G2 is higher

Benign traffic	E_π 48.6%	35.3%	25.7%	18.6%	p
Validation mix, B0 → G2	0.9852 → 0.9854	0.9818 → 0.9845	0.9774 → 0.9813	0.9717 → 0.9784	
Validation mix, difference (folds)	**+0.02 (4/5)**	**+0.28 (4/5)**	**+0.39 (3/5)**	**+0.67 (4/5)**	**0.32**
Real users, B0 → G2	0.9765 → 0.9812	0.9702 → 0.9764	0.9653 → 0.9726	0.9604 → 0.9678	
Real users, difference (folds)	**+0.47 (3/5)**	**+0.62 (4/5)**	**+0.73 (5/5)**	**+0.74 (5/5)**	**0.22**

1차 규칙은 두 정상 요청 분포 모두에서 충족되었다(Table 12, Fig. 3). 따라서 클래스별 임계값은 표준 확신도 넘김보다 정확도-속도 경계가 위이나, 통계적 유의성은 확인하지 못했다(p=0.32, 0.22). 효과의 크기는 G2를 찾아낸 분할의 절반 이하이다. 그 분할에서는 같은 네 지점의 차이가 +0.21, +0.67, +1.17, +1.72%p였다. 가장 느린 지점의 차이는 +0.02%p로 사실상 0이고, 다섯 fold 가운데 둘은 네 지점 평균 차이가 0에 가깝거나 음수였다. 2차 규칙은 충족되지 않았다. 검증 부분에서 고른 운영점에서 G2는 E_π를 32.3%에서 23.2%로 줄이고 다섯 fold 모두에서 더 빨랐지만(p=0.010), 채움 기준의 π=3.3% 배수는 1.59배에서 1.84배로 15.7% 오르는 데 그쳤다(Macro-F1 손실 0.14%p). 5.8절에서 관찰한 +30%는 재현되지 않았다. 5.11절의 지연 기준에서는 두 게이트 모두 0.27~0.28배이므로 이 규칙은 적용 대상이 아니다. 정리하면 경계는 위이지만 검증으로 고른 운영점의 이득은 확인하지 못했다. 새 분할은 같은 풀을 다시 나눈 것이어서 독립 표본이 아니며, 경계는 fold 시험 부분에서 가장 좋은 점을 이은 것이라 두 게이트 모두에 낙관적이다.

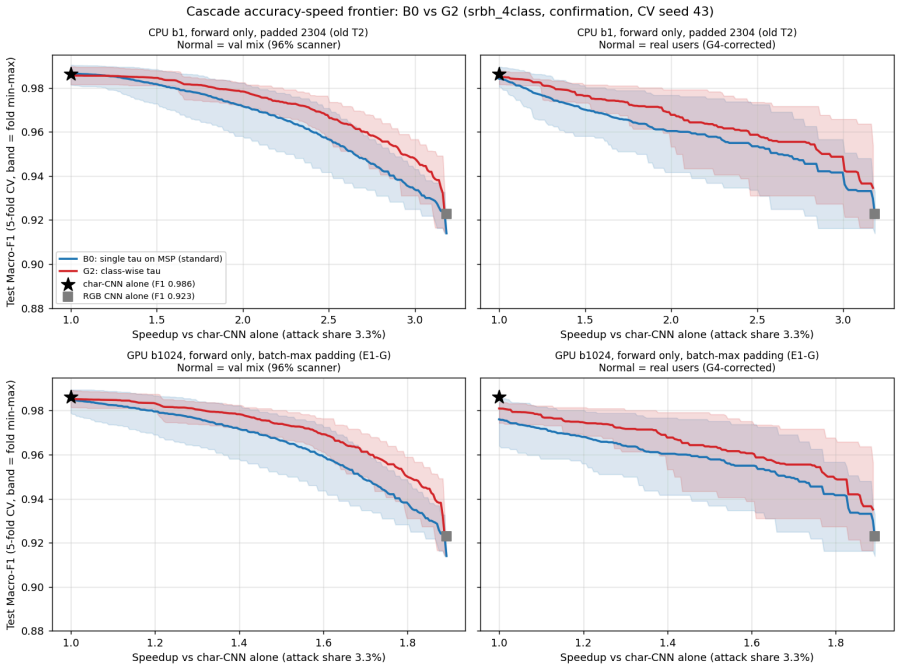


Fig. 3. Accuracy–speed frontier of standard confidence deferral (B0) and class-wise thresholds (G2) on a new cross-validation split (seed 43, band = fold min–max). Top: CPU, batch 1, forward pass with the second stage padded to 2,304 bytes. Bottom: GPU, batch 1024, padded to the longest request in the batch. Left: benign requests as in the validation mix; right: real-user benign requests.

seed 반복. 판정은 seed 43 하나로 하되, 같은 교차검증을 seed 44와 45로 되풀이해 산포를 함께 보고하기로 미리 정하였다. 1차 규칙은 세 seed 모두(43·44·45), 두 정상 요청 분포 모두에서 충족되었다. 네 지점 평균 차이는 검증 분포에서 +0.34, +1.66, +0.64%p, 실사용자 분포에서 +0.64, +2.43, +0.95%p로 방향은 같지만 크기는 다섯 배까지 달랐고, 어느 seed에서도 유의하지 않았다($p=0.17\sim0.41$). 판정에 쓴 seed 43이 세 seed 가운데 가장 작은 값이었다. 검증으로 고른 운영점의 채움 기준 배수 이득은 발견 분할을 포함한 네 seed에서 +30.3, +15.7, +43.8, +23.1%였고, 2차 규칙의 세 조건을 모두 채운 것은 seed 44 하나이다. G2의 운영점 배수는 seed 사이에서 1.71~1.84배로 안정적이었고 B0가 1.26~1.59배로 흔들렸으므로, 이득의 크기를 좌우한 것은 단일 임계값 쪽의 불안정이다. 단독 모델의 교차검증 평균 Macro-F1은 RGB CNN이 seed 42~45에서 0.8949, 0.9229, 0.9054, 0.9080(seed 간 표준편차 1.15%p), char-CNN이 0.9884, 0.9862, 0.9901, 0.9897(0.18%p)이었다. 5.4~5.8절의 교차검증 수치는 모두 seed 42에서 잰 것이며, 이 seed는 네 seed 가운데 RGB CNN이 가장 낮은 경우이다. 따라서 단일 seed에서 얻은 1차 모델 간 2%p 안팎의 차이는 seed 잡음과 같은 크기로 읽어야 한다.

5.13 1차 모델의 대안

5.11절에서 속도 이득을 없앤 것은 1차의 지연이었다. 그래서 1차를 바꾸면 결과가 달라지는지 두 방향으로 확인하였다. 하나는 같은 세 채널 인코딩을 유지한 채 1차의 구조를 고치는 것이고, 다른 하나는 이미지 표현을 버리고 2차와 같은 문자 표현 계열의 선형 모델을 1차로 쓰는 것이다. 두 실험 모두 판정 규칙을 측정 전에 고정하였다(커밋 2a456d7). 지연은 5.11절과 같은 방식(전처리 포함, CPU, 배치 1, 스레드 1, 2,000개 요청 × 30회의 중앙값)으로 재고, 2차는 seed 42 교차검증의 char-CNN을 그대로 쓴다.

1차 구조의 재설계. 후보는 셋이며 모두 채널 폭(32·64·128)이 현행과 같다. 위 8행(384바이트)만 입력으로 쓰는 것, 전역 평균 풀링을 전역 최대 풀링으로 바꾸는 것, 세 채널을 2차원으로 접지 않고 길이 2,304의 수열로 두어 1차원 합성곱을 쓰는 것이다. 채택 조건은 교차검증 Macro-F1이 현행보다 2%p 이상 높고, 후보 3개에 대한 Holm 보정 p가 0.05 미만이며(fold별 차이의 보정 t-검정[30]), 1차 지연이 현행 이하인 것 세 가지 모두이다.

Table 13. First-stage redesign candidates under the same three-channel encoding (5-fold cross-validation, seed 42). Latency is the end-to-end median on CPU at batch size 1 with one thread, from two independent runs in which the four models were measured alternately.

First stage	Parameters	Macro-F1	Difference	Holm p	Latency (ms), run 1 · run 2	Decision
RGB CNN (current)	93,988	0.8949±0.0140	—	—	1.238 · 1.260	baseline
Top 8 rows only (384 bytes)	93,988	0.9165±0.0116	+2.15 pp	0.178	0.640 · 0.654	rejected
Global max pooling	93,988	0.9178±0.0124	+2.29 pp	0.178	1.236 · 1.259	rejected
1-D convolution over the 3×2,304 sequence	**31,972**	**0.9341±0.0090**	**+3.92 pp**	**0.009**	**1.205 · 1.234**	**adopted**

1차원 합성곱 후보만 세 조건을 모두 채워 채택되었다(Table 13). 다섯 fold 모두에서 2.6%p 이상 높았고, 0.9341은 현행 RGB CNN의 네 seed 값 가운데 가장 높은 0.9229도 넘는다(5.12절). 지연은 두 번의 실행에서 현행보다 2.7%, 2.1% 낮았는데, 여유가 작으므로 더 빠르다가 아니라 느려지지 않았다고 읽는다. 나머지 두 후보는 2%p를 넘었지만 보정 뒤 유의하지 않았고, 그 차이는 5.12절에서 본 seed 간 범위(2.8%p) 안이다. 사전 규칙에 따라 채택된 1차로 캐스케이드를 다시 계산하면, 검증으로 고른 운영점의 넘김률 E_π는 43.7%에서 29.8%로 줄지만 π=3.3% 배수는 0.27배에서 0.28배로 거의 그대로이다(Table 14). 상한 t_2/t_1이 0.31이어서 넘김을 0으로 줄여도 그 이상이 될 수 없기 때문이다. 입력을 384바이트로 줄여 지연을 절반으로 만든 후보도 탐색적으로 계산하면 0.47배에 그친다. RGB 이미지 변환만 0.41ms로 2차 전체(0.39ms)보다 길어서, 같은 변환을 쓰는 1차는 합성곱을 아무리 줄여도 2차보다 빨라질 수 없다. 한편 2차원 배치를 없앤 것만으로 정확도가 3.9%p 오른 것은, 본 인코딩에서 정확도에 기여한 것이 채널 정보이고 48바이트 떨어진 바이트를 위아래 이웃으로 만드는 배치는 오히려 손해였음을 시사한다. 이는 Q1의 음성 결과와 같은 방향이다. 1차원 합성곱 1차는 seed 42 한 번만 쟀고, 5.2~5.12절의 다른 결과는 모두 현행 RGB CNN 1차에서 잰 값이다.

선형 n-그램 1차. 본 논문의 캐스케이드는 1차와 2차의 표현이 다르다는 데서 출발하였다. 이 전제가 속도 이득에 필요한지 보려고 1차를 문자 n-그램 선형 모델로 바꾸었다. 후보는 해싱(2^{18}차원, 문자 1~3그램)과 TF-IDF(단어 경계 문자 2~4그램 2만 개)에 각각 클래스 가중치 로지스틱 회귀를 붙인 두 가지이며, RGB CNN과 같은 fold에서 학습하였다. 판정 규칙은 π=3.3% 배수가 RGB CNN 1차보다 20% 이상 높으면 표현 이질성은 속도 이득의 필요조건이 아니라고 쓰는 것이다. 두 단계가 같은 요청에서 함께 틀리는 정도는 정오답의 Q 통계량[34]으로 재며, 1에 가까울수록 오류가 겹친다.

Table 14. Alternative first stages in front of the same char-CNN second stage (t_2=0.393 ms), with B0 at the operating point selected on the validation part of each fold. S is the speedup over the stand-alone second stage at π=3.3% under end-to-end latency.

First stage	t_1 (ms)	t_2/t_1	Stand-alone Macro-F1	Q	E_π	Cascade Macro-F1	S, validation mix
RGB CNN (current)	1.311	0.300	0.8949	0.954	43.7%	0.9830	0.265
1-D CNN (adopted in Table 13)	1.284	0.306	0.9341	0.978	29.8%	0.9839	0.281
Hashing + logistic regression	1.953	0.201	0.9078	0.993	18.1%	0.9839	0.194
TF-IDF + logistic regression	**0.295**	**1.331**	**0.9406**	**0.996**	**5.3%**	**0.9834**	**1.244**

TF-IDF 1차는 RGB CNN 1차보다 검증 분포에서 4.7배, 실사용자 분포에서 3.4배 빨랐고($p<0.001$, 다섯 fold 모두 같은 방향), 판정 기준 20%를 크게 넘었다. 따라서 표현 이질성은 속도 이득의 필요조건이 아니다. 5.11절의 지연 기준에서 2차 단독보다 빠른 구성은 이것이 처음이다(1.24배, Macro-F1은 2차 단독보다 0.50%p 낮다). 1차가 2차보다 빠르고(0.295ms 대 0.393ms) 요청의 5.3%만 넘기기 때문이다. 다만 이 이득에는 두 가지 제한이 있다. 실사용자 정상 요청에서는 정상 넘김률이 5.2%에서 43.4%로 올라 0.86배로 다시 1배 아래가 된다. 그리고 2차가 이미 1차만큼 싸서 상한이 1.33배이다. Tasdemir 등[8]의 20배는 2차가 1차보다 수천 배 비싼 BERT였기에 가능한 값이다. 해싱 1차는 단독 정확도가 RGB CNN보다 높았지만 호출당 1.95ms로 더 느려 기준에 미달하였다. Q 통계량은 RGB CNN 0.954, 해싱 0.993, TF-IDF 0.996으로, 표현이 다른 1차가 실제로 2차와 오류를 덜 겹치게 한다. 그러나 운영점의 캐스케이드 Macro-F1은 네 1차 모두 0.983~0.984로 같아, 이 차이는 정확도로도 속도로도 이어지지 않았다. 사전 규칙 밖의 관찰로, TF-IDF 1차에 클래스별 임계값(G2)을 얹으면 실사용자 분포의 E_π가 42.2%에서 1.5%로 줄고 배수가 1.31배가 되었다($p=0.001$). 이 조합은 미리 정하지 않았으므로 새 분할에서 확인하기 전에는 결과로 쓰지 않는다.

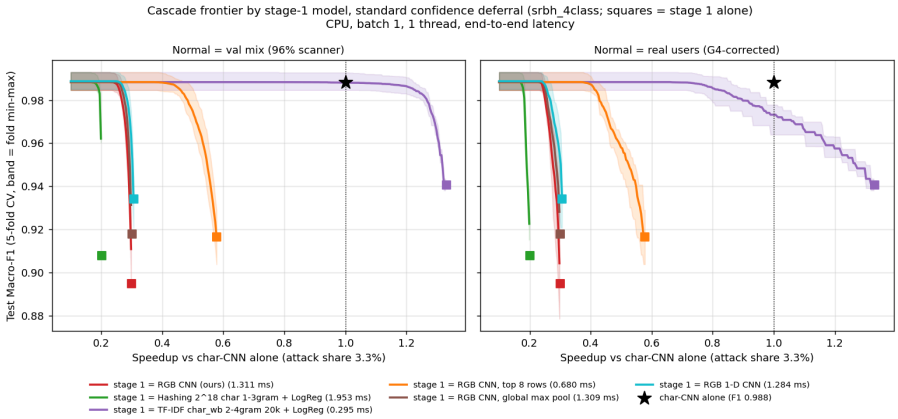


Fig. 4. Accuracy–speed frontier of cascades with alternative first stages in front of the same char-CNN (CPU, batch 1, one thread, end-to-end latency, π=3.3%). Left: benign requests as in the validation mix; right: real-user benign requests. Squares mark each first stage alone, the star the stand-alone second stage (speedup 1), and bands the fold min–max.

유사 연구와의 비교. Fig. 5의 (a)는 지연을 보고한 유사 연구의 값을 그대로 옮긴 것이다. 데이터, 클래스 수, 측정 장치가 달라 직접 비교는 아니다. 같은 SR-BH를 쓴 Osama 등[31]의 XGBoost는 Macro-F1 0.9705에 요청당 0.061ms(8 vCPU)로, 본 논문의 char-CNN(0.9884, 0.393ms)보다 정확도가 낮고 빠르다. Tasdemir 등[8]의 캐스케이드는 F1 0.9981에 0.099ms이지만 SQL 주입 이진 분류를 GPU에서 잰 값이다. 같은 SR-BH의 Luo 등[32]과 Bitussi와 Doriguzzi-Corin[33]은 지연을 보고하지 않았다. 보고값 평면에서 본 논문의 캐스케이드(0.9830, 1.482ms)가 이들보다 위라고 쓸 근거는 없다. (b)와 (c)는 같은 데이터, 같은 CPU에서의 비교이다. 지연을 보고한 유사 연구 가운데 정확도가 가장 높은 Tasdemir 등[8]의 구조, 곧 선형 1차 뒤에 신경망 2차를 두는 구조를 본 데이터에 옮긴 것이 TF-IDF 1차 곡선이며, 이 곡선은 모든 속도 구간에서 RGB CNN 1차 곡선의 위에 있다. 정확도-속도 평면에서 본 논문이 제안한 표현 이질적 구성은 같은 조건의 선형 텍스트 1차 구성에 지배된다. XGBoost[31]는 재구현하지 않았으므로 (a)의 점은 원문 보고값이며, 선형 1차의 지연은 라이브러리 호출을 그대로 잰 값이다.

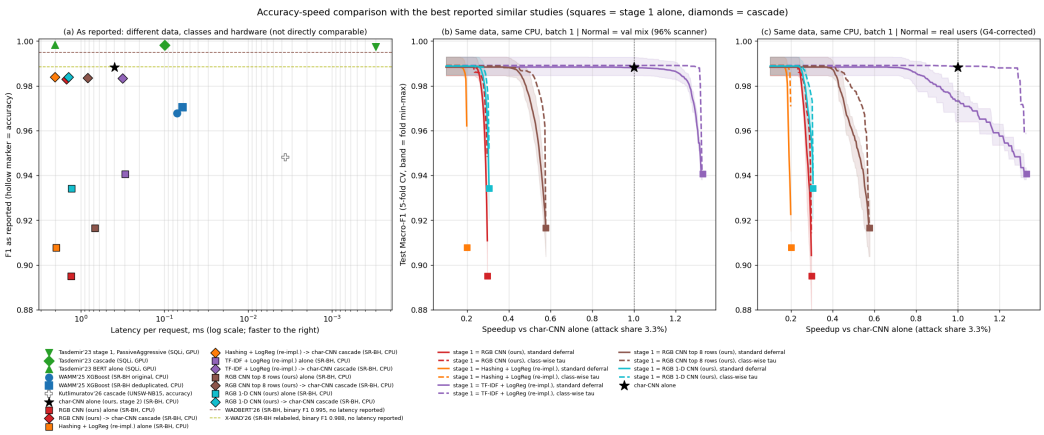


Fig. 5. Comparison with related work. (a) Accuracy and per-request latency as reported in each paper; datasets, tasks and hardware differ. (b), (c) Same data and same CPU: accuracy–speed frontiers of the proposed RGB-CNN cascade and of a linear-first-stage cascade re-implemented on SR-BH, with benign requests as in the validation mix (b) and from real users (c). Solid lines use standard confidence deferral and dashed lines class-wise thresholds.

5.14 템플릿 묶음 분할과 시험 집합 사용 점검

템플릿 묶음 교차검증. 숫자와 긴 토큰을 가린 요청 템플릿을 기준으로 보면, 교차검증 fold 시험 부분의 66.5%가 같은 fold의 학습·검증 부분에 같은 템플릿을 갖고 있다(SQL 주입 70.7%, 코드 주입 63.0%, 정상 59.7%, 명령 주입 14.7%). 이 중복이 점수를 부풀리는지 보려고, 같은 템플릿이 양쪽에 함께 들어가지 않도록

묶어 나눈 5-fold(템플릿 96,037종)에서 두 모델을 처음부터 다시 학습하였다. 측정 전 기준은 두 모델 중 하나라도 Macro-F1이 일반 분할보다 2%p 이상 내려가면 템플릿 중복이 점수를 부풀린다고 쓰고 본문 수치를 묶음 기준으로 바꾸는 것이었다. RGB CNN은 0.8949±0.0140에서 0.8943±0.0254로(−0.06%p), char-CNN은 0.9884±0.0037에서 0.9894±0.0014로(+0.10%p) 바뀌어 기준에 해당하지 않았다. 묶음 분할에서 중복은 0%이므로 점수가 유지된 것은 분리가 덜 되어서가 아니다. 두 모델의 점수는 템플릿 중복에 견고하다. 다만 RGB CNN의 fold 간 표준편차는 0.014에서 0.025로 커졌고, 템플릿 키는 숫자와 긴 토큰만 가리므로 같은 도구가 만든 비슷한 요청이 양쪽에 들어가는 것까지 막지는 못한다. 묶음 분할 위에서 B0와 G2를 비교하면 G2가 네 지점 모두에서 높았고(+1.05~+2.66%p, p=0.21), 검증으로 고른 운영점의 채움 기준 배수는 1.36배에서 1.90배로 올랐다(+39.3%, p=0.047). G2를 찾아낸 행을 그대로 쓴 값이어서 탐색적 관찰로만 적는다.

시험 집합 사용 점검. 고정 분할의 시험 집합은 본 연구에서 아홉 번의 평가에 쓰였다. 그 가운데 설계를 바꾼 것은 1차의 학습 방식을 언더샘플링에서 클래스 가중치로 바꾼 결정(5.2·5.3절) 하나이고, 나머지 여덟 번은 이미 정한 구성의 보고이거나 기각으로 끝난 비교이다. 시험 집합을 보고 내린 이 결정이 시험 집합 없이도 같은 방향으로 내려지는지 보려고, 언더샘플링 1차를 같은 교차검증으로 다시 학습해 4.2절의 기준 (2)(π=3.3% 배수 20% 이상 상승, Macro-F1 손실 0.3%p 이하)을 다시 적용하였다. 1차 단독 Macro-F1은 언더샘플링 0.8178±0.0329, 클래스 가중치 0.8949±0.0140이었다. 기준이 정해졌던 조건인 채움 기준·검증 분포에서 배수는 1.05배에서 1.34배로 27.4% 올랐고 캐스케이드 Macro-F1 차이는 −0.07%p여서 기준은 교차검증에서도 충족되었다. 다만 fold 간 차이는 유의하지 않았고(p=0.11), 크기는 시험 집합에서 본 값(0.99배 → 1.42배, +43%; Table 3)의 약 60%이다. 따라서 본문의 대표값은 교차검증 값으로 두고 시험 집합 값은 확인용으로 읽는다. 이 이득은 조건을 바꾸면 사라진다. 실사용자 정상 요청 분포에서는 0.97배에서 1.01배(+4.9%, p=0.70)였고, 5.11절의 지연 기준에서는 두 분포 모두 0.25~0.27배로 차이가 6% 이하였다. 클래스 가중치가 줄인 것은 스캐너 층 정상 요청의 넘김이며, 넘김률의 감소가 속도로 이어지려면 1차가 2차보다 빨라야 한다.

VI. 논의

이득이 사라진 이유와 되돌린 것. 캐스케이드의 속도 이득은 두 조건이 함께 맞아야 난다. 1차가 대부분의 요청을 맞혀 넘김이 적어야 하고, 2차가 1차보다 충분히 비싸야 한다. 이전 데이터셋에서는 두 모델의 Macro-F1 차이가 1.5%p, GPU 처리량 비가 13.6배였다. SR-BH의 헤드라인 조건(CPU·배치 1)에서는 지연 비가 3.18배라 상한이 낮았다. 다만 SR-BH의 GPU 지연 비(배치 128에서 17.5배)는 이전 값과 비슷하므로, 상한을 낮춘 것은 데이터셋이 아니라 측정 조건이다. 한편 언더샘플링 1차는 학습 행의 92%를 버린 탓에 정상 요청을 자주 틀리고(FPR 9.4%) 확신도도 낮아 정상 요청을 70%나 넘겼다. 같은 구조의 1차를 전체 학습 집합으로 학습하는 것만으로 정상 넘김이 39.5%로 줄고 배포 배수가 0.99배에서 1.42배로 올랐다. 채움 기준의 측정에서 배포 조건의 속도를 실제로 움직인 것은 넘김 판단보다 1차의 학습 방식이었다. 다만 이 이득은 교차검증에서 +27%로 시험 집합 값보다 작았고 실사용자 분포에서는 나타나지 않았다(5.14절). 더 근본적으로, 전처리를 포함한 지연에서는 1차가 2차보다 느려 넘김을 아무리 줄여도 이득이 없다(5.11절). 1차를 더 정확하게 고쳐 넘김을 14%p 줄였는데도 배수가 0.27배에서 0.28배로만 움직인 것이 이를 보여 준다(5.13절). 캐스케이드의 첫째 조건은 넘김이 적은 것이 아니라 1차가 2차보다 충분히 싼 것이며, 본 연구의 이미지 1차는 변환 비용 때문에 이 조건을 채우지 못했다.

표현 이질성의 역할. 본 논문은 두 단계의 표현이 다르면 틀리는 요청도 달라 캐스케이드에 유리하다는 가정에서 출발하였다. Q 통계량은 이 가정의 앞부분을 지지한다(RGB CNN 0.954, TF-IDF 0.996). 그러나 운영점의 정확도는 1차의 표현과 무관하게 같았고, 속도는 표현이 같은 선형 1차 쪽이 4.7배 높았다(5.13절). 확신도 게이트는 1차가 확신하지 못하는 요청을 넘길 뿐 2차가 그 요청을 맞힐지는 보지 않으므로[11], 오류가 덜 겹친다는 성질이 게이트를 거쳐 이득으로 바뀌지 못한 것으로 보인다. 이 결과는 Q1의 음성 결과와 마찬가지로 질문을 바꾸지 않고 그대로 보고한다. 제목의 '표현 이질적'은 본 논문이 검증한 대상을 가리키며, 이 데이터에서 그 답은 이득의 근거가 아니라는 것이다. 정확도–속도 평면에서 본 논문의 구성이 유사 연구의 구조보다 위에 있지 않다는 것도 같은 결과의 다른 면이다(Fig. 5).

기저율과 게이트 평가. 대부분의 요청이 정상인 환경에서는 넘김률이 정상 요청의 넘김률에 수렴하므로, 시험 집합에서 잰 넘김률은 배포 비용을 과소평가한다. 탐지 성능에서 알려진 기저율 문제[21]가 비용 쪽에서도 나타나는 셈이다. 5.6절은 이것이 보고의 문제에 그치지 않고 게이트 선택을 뒤집을 수 있음을 보여 준다. 공격 쪽 넘김을 덜어내는 게이트는 시험 집합 기준을 통과하면서 배포 조건에서는 느려진다. 캐스케이드와 넘김 규칙을 보고할 때 장치, 배치 크기와 함께 평가 집합의 공격 비율, 정상·공격 요청별 넘김률을 밝혀야 하는 이유이다.

넘김 판단의 한계. 신호 교체, 배분 변경, 1차 밖 정보를 쓴 학습형 라우터 모두 엄격한 목표에서 과잉 넘김 배율을 줄였다는 사전 기준을 충족하지 못했다.

fold 5개의 대응표본 검정이라 검정력이 낮으므로, 이는 개선이 없다는 증거가 아니라 검출하지 못했다는 뜻이다. 1차 내부 표현까지 넣은 로지스틱 회귀 라우터가 기준에 미달한 것은, 적어도 선형 라우터로는 2차가 맞힐지를 1차가 본 정보만으로 예측하기 어렵다는 것을 시사한다. 넘김 점수를 확률이 아니라 1차 내부 표현의 거리로 바꾼 네 점수도 MSP보다 오히려 많이 넘겼다(5.8절). 신호를 바꾸는 쪽은 이 데이터에서 막혀 있고, 남은 여지는 임계값의 구조(G2)와 라벨 잡음 쪽에 있다. 이는 1차 확신도의 한계에 대한 Jitkrittum 등[11]의 분석과 맞고, 그 분석이 실패 조건으로 든 라벨 잡음의 직접 증거도 5.7절에서 찾았다. 엄격한 목표(2차 단독 Macro-F1)의 꼬리에는 2차가 잡음을 따라 맞힌 요청이 섞여 있으므로, 과잉 넘김 배율의 일부는 게이트의 비효율이 아니라 목표의 잡음일 수 있다. 남은 방향은 비선형 라우터, 2차를 일부 돌린 뒤 판단하는 라우터, 넘김 비용을 정상·공격별로 달리 매기는 비용 민감 넘김 학습[15], 그리고 라벨을 정제한 데이터에서의 재평가이다.

한계. 첫째, 5.2~5.10절의 속도 배수는 2차 입력을 2,304바이트로 채우고 순전파만 잰 값이다. 전처리를 넣고 채움을 없앤 재측정(5.11절)에서는 1차(1.311ms)가 2차(0.393ms)보다 느려 요청 단위 CPU 처리의 속도 이득이 없었다. 따라서 그 절들의 배수는 넘김 규칙과 1차 학습 방식의 상대 비교에만 쓰고, 캐스케이드가 2차 단독보다 빠르다는 근거로는 쓰지 않는다. 5.11절의 지연도 한 대의 데스크톱 CPU에서 잰 값이며, 1차의 이미지 변환은 파이썬 구현 그대로여서 변환을 최적화하면 달라질 수 있다. 둘째, SR-BH의 정상 요청은 스캐너 트래픽이 대부분이고 실사용자 정상 요청은 시험 집합에 95개뿐이어서, 실사용자 오탐률과 배포 조건의 r_N은 신뢰구간이 넓다. 교차검증의 실사용자 550개로 잰 r_N은 검증 집합 값보다 약 25%p 높았으므로(5.9절), 본문의 배포 배수는 실사용자 보정 배수(B0 1.01배, G2 1.28배)와 함께 읽어야 한다. 셋째, 라벨은 헤더를 포함한 요청 전체에서 정해졌지만 입력은 URI와 본문뿐이어서 일부 라벨은 입력으로 관찰할 수 없다. 또한 숫자·긴 토큰을 가린 요청 템플릿 기준으로 시험 행의 66.4%가 학습 집합에 같은 템플릿을 갖고 있다(CmdI는 14.9%). 같은 템플릿을 한쪽에만 두도록 묶어 나눈 교차검증에서 두 모델의 Macro-F1은 내려가지 않았지만(5.14절), 이 키는 숫자와 긴 토큰만 가리므로 같은 도구가 만든 비슷한 요청의 중복까지 배제한 것은 아니다. 넷째, 5.2~5.3절의 속도-정확도 곡선과 고정 분할 게이트 확인은 단일 분할·단일 seed의 값이고, 배치가 1보다 클 때의 캐스케이드 지연은 근사이다. 1차 학습 방식 비교는 교차검증으로 다시 확인했으나(5.14절), 같은 시험 집합을 아홉 번의 평가에 썼다. 5.4~5.8절과 5.13절의 교차검증은 seed 42 하나에서 잰 값이며, 이 seed는 RGB CNN의 교차검증 평균이 네 seed 가운데 가장 낮았다(5.12절). 1차원 합성곱 1차와 선형 1차는 seed를 반복하지 않았다. 선형 1차의 지연은 라이브러리 호출을 그대로 잰 값이고, 1차와 2차의 지연을 서로 다른 실행에서 재어 4~6%의 실행 간 차이가 들어 있다. 다섯째, 클래스 가중치 1차 위의 게이트 결과와 교차검증 운영점 비교는 사후 분석이다. 여섯째, 라벨 감사는 대형 언어모델 한 개의 판정으로 220건만 보았고, 사람 판정자를 더한 2인 감사와 일치도 산출은 하지 못했다. 다만 같은 데이터셋의 라벨 문제는 독립적으로도 보고되었다. Bitussi와 Doriguzzi-Corin[33]은 SR-BH 2020의 약 13.8%가 잘못 라벨링되어 있다고 보고하고, 라벨을 고친 판본에서 이상 탐지 F1이 0.9131에서 0.9884로 올랐다고 하였다. Osama 등[31]도 같은 데이터의 중복과 라벨을 정제한 판본을 따로 평가하였다. 일곱째, 넘김 부풀리기는 고정된 표면 변형으로만 쟀고(5.10절), 게이트를 알고 넘김을 최대화하도록 최적화하는 적응형 공격[19]은 포함하지 않았다. 여덟째, 다른 시기·다른 서버의 데이터에서 임계값이 같은 넘김률을 유지하는지는 아직 확인하지 않았다. 같은 데이터 안에서도 실사용자 정상 요청과 감사로 뺀 탐침에서 넘김률이 검증 집합보다 높았다(5.9절). 분포가 바뀌면 사후 보정만으로는 부족하다는 보고[23]가 있어 별도 검증이 필요하다. 공개된 운영 서버 데이터[24]는 차단된 악성 요청만 담고 있어 r_A만 검증할 수 있고, 배포 배수를 좌우하는 r_N은 정상 트래픽이 있는 다른 데이터가 필요하다.

VII. 결론

본 연구의 웹 요청 바이트 이미지 탐지는 텍스트 모델보다 정확도가 낮았고, 이 음성 결과에서 출발한 표현 이질적 캐스케이드는 이전 데이터셋에서 5.07배의 속도 이득을 보였다. 실트래픽 기반 SR-BH 2020에서 다시 측정하자 이 이득은 두 단계로 사라졌다. 2차 입력을 최대 길이로 채우고 순전파만 재는 기존 방식에서도 요청 단위 CPU 처리의 이득은 1.22배, 배포 수준의 공격 비율에서는 0.99배였고, 1차를 클래스 가중치로 학습해도 1.63배와 1.42배였다. 전처리를 포함하고 채움을 없앤 기준에서는 1차가 2차보다 3.3배 느려 캐스케이드가 2차 단독의 0.27배였으며, 이 조건의 속도 이득 주장은 철회하였다. 1차의 구조를 고쳐 정확도를 3.9%p 올려도 배수는 0.28배였고, 1차를 문자 n-그램 선형 모델로 바꾸었을 때에만 1.24배(실사용자 정상 요청에서는 0.86배)가 되었다. 표현이 다른 1차는 2차와 오류가 덜 겹쳤지만 그것이 속도나 정확도의 이득으로 이어지지 않았으므로, 표현 이질성은 이 구조에서 속도 이득의 근거가 아니다. 넘김 판단은 신호 교체, 1차 내부 표현을 쓰는 로지스틱 회귀 라우터, 거리 점수 어느 것으로도 사전 기준을 넘지 못했고, 클래스별 임계값은 분할을 바꾼 세 번의 확인에서 모두 정확도-속도 경계가 위였으나 유의성과 운영점의 이득은

확인하지 못했다. 실사용자 정상 요청에서는 넘김률이 검증 집합보다 약 25%p 높았고, 시험 집합의 넘김률로만 평가하면 배포 조건에서 더 느린 게이트를 고를 수 있었다. 캐스케이드의 속도 이득은 전처리를 포함한 지연, 2차 입력의 채움 여부, 장치·배치 크기·공격 비율, 정상·공격 요청별 넘김률을 함께 밝힐 때에만 의미가 있다. 선형 1차와 클래스별 임계값을 합친 구성의 새 분할 확인, 이미지 변환의 최적화, 사람 판정자를 더한 라벨 감사가 다음 과제이다.

References

1. D. Arp, E. Quiring, F. Pendlebury, A. Warnecke, F. Pierazzi, C. Wressnegger, L. Cavallaro, and K. Rieck, “Dos and don'ts of machine learning in computer security,” Proceedings of the 31st USENIX Security Symposium, pp. 3971-3988, Aug. 2022.
2. L. Nataraj, S. Karthikeyan, G. Jacob, and B.S. Manjunath, “Malware images: visualization and automatic classification,” Proceedings of the 8th International Symposium on Visualization for Cyber Security (VizSec), pp. 1-7, Jul. 2011.
3. Y. Wu, D. Zou, S. Dou, W. Yang, D. Xu, and H. Jin, “VulCNN: an image-inspired scalable vulnerability detection system,” Proceedings of the 44th International Conference on Software Engineering (ICSE), pp. 2365-2376, May 2022.
4. E. Eroğlu Demirkan and M. Aydos, “Enhancing malware detection via RGB assembly visualization and hybrid deep learning models,” Applied Sciences, 15(13), 7163, Jun. 2025.
5. J.R. Tadhani, V. Vekariya, V. Sorathiya, S. Alshathri, and W. El-Shafai, “Securing web applications against XSS and SQLi attacks using a novel deep learning approach,” Scientific Reports, 14, 1803, Jan. 2024.
6. F. Sureda Riera, J. Bermejo Higuera, J.R. Bermejo Higuera, J.J. Martínez Herraiz, and J.A. Sicilia Montalvo, “A new multi-label dataset for web attacks CAPEC classification using machine learning techniques,” Computers & Security, 120, 102788, Sep. 2022.
7. X. Wang, D. Kondratyuk, E. Christiansen, K.M. Kitani, Y. Movshovitz-Attias, and E. Eban, “Wisdom of committees: an overlooked approach to faster and more accurate models,” International Conference on Learning Representations (ICLR), Apr. 2022.
8. K. Tasdemir, R. Khan, F. Siddiqui, S. Sezer, F. Kurugollu, S.B. Yengec-Tasdemir, and A. Bolat, “Advancing SQL injection detection for high-speed data centers: a novel approach using cascaded NLP,” arXiv:2312.13041, Dec. 2023.
9. M. Sevri and H. Karacan, “Two stage deep learning based stacked ensemble model for web application security,” KSII Transactions on Internet and Information Systems, 16(2), pp. 632-657, Feb. 2022.
10. A. Kutlimuratov, F. Rakhmatov, J. Khamzaev, I. Saymanov, P. Allayarov, G. Bekbaev, S. Otamurodov, and F. Makhmudov, “A lightweight cascade-based framework for real-time zero-day attack detection,” Computers, 15(3), 174, Mar. 2026.
11. W. Jitkrittum, N. Gupta, A.K. Menon, H. Narasimhan, A.S. Rawat, and S. Kumar, “When does confidence-based cascade deferral suffice?,” Advances in Neural Information Processing Systems (NeurIPS), Dec. 2023.
12. D. Hendrycks and K. Gimpel, “A baseline for detecting misclassified and out-of-distribution examples in neural networks,” International Conference on Learning Representations (ICLR), Apr. 2017.
13. Y. Geifman and R. El-Yaniv, “Selective classification for deep neural networks,” Advances in Neural Information Processing Systems (NIPS), pp. 4878-4887, Dec. 2017.
14. D. Madras, T. Pitassi, and R. Zemel, “Predict responsibly: improving fairness and accuracy by learning to defer,” Advances in Neural Information Processing Systems (NeurIPS), pp. 6147-6157, Dec. 2018.
15. H. Mozannar and D. Sontag, “Consistent estimators for learning to defer to an expert,” Proceedings of the 37th International Conference on Machine Learning (ICML), pp. 7076-7087, Jul. 2020.
16. A. Kag, I. Fedorov, A. Gangrade, P. Whatmough, and V. Saligrama, “Efficient edge inference by selective query,” International Conference on Learning Representations (ICLR), May 2023.
17. S. Enomoto and T. Eda, “Learning to cascade: confidence calibration for improving the accuracy and computational cost of cascade inference systems,” Proceedings of the AAAI Conference on Artificial Intelligence, 35(8), pp. 7331-7339, Feb. 2021.
18. S. Teerapittayanon, B. McDanel, and H.T. Kung, “BranchyNet: fast inference via early exiting from deep neural networks,” Proceedings of the 23rd International Conference on Pattern Recognition (ICPR), pp. 2464-2469, Dec. 2016.
19. S. Hong, Y. Kaya, I.-V. Modoranu, and T. Dumitraş, “A panda? No, it's a sloth: slowdown attacks on adaptive multi-exit neural network inference,” International Conference on Learning Representations (ICLR), May 2021.
20. V.J. Reddi et al., “MLPerf inference benchmark,” Proceedings of the 47th Annual International Symposium on Computer Architecture (ISCA), pp. 446-459, May 2020.
21. S. Axelsson, “The base-rate fallacy and its implications for the difficulty of intrusion detection,” Proceedings of the 6th ACM Conference on Computer and Communications Security (CCS), pp. 1-7, Nov. 1999.
22. C. Guo, G. Pleiss, Y. Sun, and K.Q. Weinberger, “On calibration of modern neural networks,” Proceedings of the 34th International Conference on Machine Learning (ICML), pp. 1321-1330, Aug. 2017.
23. Y. Ovadia et al., “Can you trust your model's uncertainty? Evaluating predictive uncertainty under dataset shift,” Advances in Neural Information Processing Systems (NeurIPS), Dec. 2019.
24. G. Lucz and B. Forstner, “A thirty-day dataset of malicious HTTP requests blocked by OWASP ModSecurity on a production web server,” Data, 10(11), 186, Nov. 2025.
25. K. Lee, K. Lee, H. Lee, and J. Shin, “A simple unified framework for detecting out-of-distribution samples and adversarial attacks,” Advances in Neural Information Processing Systems (NeurIPS), Dec. 2018.
26. J. Ren, S. Fort, J. Liu, A.G. Roy, S. Padhy, and B. Lakshminarayanan, “A simple fix to Mahalanobis distance for improving near-OOD detection,” arXiv:2106.09022, Jun. 2021.

27. Y. Sun, Y. Ming, X. Zhu, and Y. Li, “Out-of-distribution detection with deep nearest neighbors,” Proceedings of the 39th International Conference on Machine Learning (ICML), Jul. 2022.
28. H. Jiang, B. Kim, M.Y. Guan, and M. Gupta, “To trust or not to trust a classifier,” Advances in Neural Information Processing Systems (NeurIPS), Dec. 2018.
29. P.F. Jaeger, C.T. Lüth, L. Klein, and T.J. Bungert, “A call to reflect on evaluation practices for failure detection in image classification,” International Conference on Learning Representations (ICLR), May 2023.
30. C. Nadeau and Y. Bengio, “Inference for the generalization error,” Machine Learning, 52(3), pp. 239-281, Sep. 2003.
31. H. Osama, O. Elebiary, Y. Qassim, M. Amgad, A. Maghawry, A. Saafan, and H. Ghalwash, “Enhanced web payload classification using WAMM: an AI-based framework for dataset refinement and model evaluation,” arXiv:2512.23610, Dec. 2025.
32. K. Luo, Y. Xie, S. Zhao, and J. Pan, “WADBERT: dual-channel web attack detection based on BERT models,” arXiv:2601.21893, Jan. 2026.
33. M. Bitussi and R. Doriguzzi-Corin, “X-WAD: explainable web anomaly detection,” arXiv:2608.27172, Aug. 2026.
34. L.I. Kuncheva and C.J. Whitaker, “Measures of diversity in classifier ensembles and their relationship with the ensemble accuracy,” Machine Learning, 51(2), pp. 181-207, May 2003.