

# 현행 기준 정리 — RQ · 평가지표 · 데이터셋

기준일: 2026-08-24 · 대상 브랜치 `phase1-data-acquisition`

이 문서의 목적: Phase 1~12 에서 쌓인 기록과 Phase 13(2026-08-13 교수 미팅) 이후의 개편이 섞여 "지금 무엇이 유효한지"를 매번 되짚어야 하는 상태를 끝내기 위한 **통합 참조본**이다. 특히 ① **단일 RGB CNN 이 제안 모델이던 시절의 RQ 문구**, ② **MCC 중심의 옛 지표**, ③ **Kaggle+CSIC 조합의 옛 데이터셋** 세 가지가 혼동의 원인이므로 이 셋을 시기별로 분리해 정리한다.

⚠ 이 문서는 새 사실을 만들지 않는다. 모든 수치·결정에는 원 출처 문서를 표기했고, 원문과 어긋나면 원문이 옳다. 단일 진실 소스 지도는 §0.2.

## 0. 읽는 법

### 0.1 세 개의 시기 — 이것만 구분하면 대부분의 혼동이 사라진다

| 시기         | 기간                                 | 제안 모델                              | 헤드라인 지표                                                | 주 데이터셋                                                 |
|------------|------------------------------------|------------------------------------|--------------------------------------------------------|--------------------------------------------------------|
| 1기         | Phase 1~6<br>(~2026-07-15)         | 단일 CNN<br>( <b>grayscale 1채널</b> ) | Accuracy · Macro-F1 · ROC-AUC                          | Kaggle 페이로드 4클래스                                       |
| 2기         | Phase 7~12<br>(2026-07-15 ~ 08-12) | 2026-08-02 부터<br><b>캐스케이드</b>      | <b>MCC</b> · PR-AUC · benign-evasion                   | <code>payload_4class_csicnorm</code> (Normal=CSIC 실패픽) |
| 3기<br>(현행) | Phase 13~ (2026-08-13 ~)           | <b>캐스케이드</b> (변동 없음)               | <b>Macro-F1</b> · PR-AUC · TPR@FPR · pAUC · 경보부하 · ECE | <b>SR-BH 2020</b> + Data 2025 외부검증 + CSIC 2010 legacy  |

#### 핵심 3줄 요약

- 1. **제안 모델은 2026-08-02 부터 캐스케이드다.** 단일 RGB CNN 은 제안 지위를 내려놓고 **비교 기준**이 됐다.
- 2. **MCC 는 2026-08-13 부로 완전히 제거됐다.** 옛 문서의 MCC 수치는 **2기의 실측 기록**으로 읽고, 새 측정과 섞지 않는다.
- 3. **데이터셋은 아직 교체되지 않았다.** SR-BH 2020 채택은 **확정**됐으나 다운로드부터가 미착수다 → 현재 `experiments/results/` 의 수치는 전부 2기 기준이며 **재측정 대상**이다.

### 0.2 단일 진실 소스 지도 — 어긋나면 어느 쪽이 옳은가

| 알고 싶은 것              | 진실 소스                                                         | 비고                                                               |
|----------------------|---------------------------------------------------------------|------------------------------------------------------------------|
| RQ 표 · 기여 문구 · 논문 목차 | <code>docs/web_attack_image_cnn_thesis_design.md</code> (마스터) | Phase 문서와 어긋나면 <b>마스터를 고친다</b>                                   |
| 현행 평가지표 · 데이터셋 결정    | <code>docs/13_dataset_metric_revision_design.md</code>        | 마스터 §6.1~§3 보다 <b>이쪽이 최신</b>                                     |
| 지표별 1차 출처(인용)        | <code>docs/13 §1.6</code>                                     | 원문 대조 완료(2026-08-23). 논문 인용은 이 표를 그대로 쓴다                         |
| 저 FPR 지표의 성립 조건      | <code>docs/13 §1.7</code>                                     | 표본 수 제약                                                          |
| 수집 논문 목록·서지          | <code>docs/12 §1.3</code>                                     | <code>docs/thetics/</code> 는 <code>.gitignore</code> → 추적본은 이 표본 |

| 알고 싶은 것      | 진실 소스                                       | 비고                                                  |
|--------------|---------------------------------------------|-----------------------------------------------------|
| 실측 수치        | experiments/results/*.json                  | ⚠️ 전체 .gitignore, 재생성으로 확보                          |
| 그림           | docs/figures/                               | 추적·커밋 대상                                            |
| 코드 관례·함정     | CLAUDE.md                                   | 트랙 추가 "5곳", tag 규칙 등                                |
| 논문 서술용 흐름 정리 | docs/reports/thesis_onepass_2026-08-12.html | ⚠️ <b>Phase 13 이전 판</b> — 지표·데이터셋 절은 이 문서로 갱신해 읽을 것 |

## 1. 지금 유효한 것 / 폐기된 것 (한 표)

| 항목            | ❌ 더 이상 쓰지 않음                                               | ✅ 현행                                                                       |
|---------------|------------------------------------------------------------|----------------------------------------------------------------------------|
| 제안 모델         | 단일 RGB CNN                                                 | 캐스케이드(1차 RGB CNN + 2차 char-CNN, $\tau$ 게이트)                                |
| 모델 호칭         | 제안 CNN (금지어)                                               | RGB CNN / gray CNN / 얇은 CNN / 캐스케이드                                        |
| 단일 요약 기준 지표   | MCC                                                        | Macro-F1                                                                   |
| 지표 근거 문헌 (1차) | MDPI <i>Technologies</i> 14(1):54, 2026 · arXiv:2512.19203 | Arp et al. USENIX Sec 2022 / CACM 67(11):104–112, 2024 (+ 지표별 개별 출처, §4.4) |
| ECE 의 근거      | ~~Arp et al.~~ (오귀속)                                       | Naeini AAAI 2015 · Guo ICML 2017 (+ CalexNet)                              |
| 주 데이터셋        | payload_4class_csicnorm                                    | SR-BH 2020 (미착수 — §5.2)                                                    |
| 외부 검증셋        | 없음                                                         | Data 2025 10(11):186 (미착수)                                                 |
| CSIC 2010     | 주 트랙                                                       | legacy 비교 기준으로 강등(삭제 아님)                                                   |
| ViT / hybrid  | —                                                          | 미채택 확정(F13)                                                                |
| 조기종료 1차 (M4)  | —                                                          | 미채택 확정(한계로 정직 보고)                                                          |
| RQ1 의 답       | ~~"이미지가 더 낫다"~~                                            | "아니오" — 그대로 보고(HARKing 금지, §3.3)                                           |

## 2. 용어 — 실제로 사고가 났던 지점

근거: 마스터 §5.1, docs/10 §0.1, CLAUDE.md

| 용어              | 뜻                                                                | 주의                                            |
|-----------------|------------------------------------------------------------------|-----------------------------------------------|
| 캐스케이드 (cascade) | 1차 RGB CNN 전량 → 확신도 $< \tau$ 인 소수만 2차 char-CNN. 배치 구조이며 새 학습이 없다 | 제안 모델은 이것                                     |
| hybrid          | CNN stem + Transformer 로 된 모델 아키텍처(docs/08, ViT 계열)              | ⚠️ cascade 와 다른 것. 이름 섞지 말 것. 미채택             |
| RGB CNN         | 48×48×3 단일 CNN (93,988 파라미터)                                     | 캐스케이드의 1차 부품이자 비교 기준                          |
| gray CNN        | 위의 1채널 판본                                                        | 1기의 기본형                                       |
| 얇은 CNN          | 채널과 무관하게 아키텍처를 지칭                                                | Conv 32→64→128, BN, ReLU, MaxPool ×3, GAP, FC |

| 용어         | 뜻 | 주의                                           |
|------------|---|----------------------------------------------|
| ~~제안 CNN~~ | — | ❌ 금지어. (ㄱ)제안 모델과 (ㄴ)1차 부품 두 뜻으로 읽혀 실제 혼동이 났다 |

⚠️ 옛 회피 수치 0.594 / 0.5944 / 0.0022 는 gray 실측이다. RGB 기준선은 0.5981(2026-08-02 측정).

### 3. 연구 질문 (RQ)

#### 3.1 번호 규약 — 재배열 금지

RQ 번호가 파일명에 박혀 있다( 05\_evasion\_attacks\_rq2 , 06\_...\_rq4 , 10\_...\_rq3 ). 전면 재번호는 파일명 + 12개 문서 136곳의 상호참조를 혼든다. → ID 는 고정, 새 질문은 뒤 번호로 추가. 논문 본문의 서술 순서만 §3.4 를 따른다.

#### 3.2 현행 RQ 표 (마스터 §1.2, 2026-08-06 개정)

| ID          | 질문                                                                                                                   | 2기 기준 상태                                                     | Phase 13 이후                                   |
|-------------|----------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------|-----------------------------------------------|
| RQ1         | 웹 공격 페이로드(SQLi, XSS, CmdI)를 바이트 이미지로 변환한 탐지는, 텍스트 기반 모델(char-CNN/BiLSTM, TF-IDF+전통 ML) 대비 정확도-비용 Pareto 상 어디에 위치하는가? | ✅ 답 완료 — 음성 결과 (F1-F2-F3)                                    | ⚠️ 재측정 필요. 답이 바뀔 수 있고, 바뀌어도 원 문구와 함께 보고       |
| RQ5<br>★    | 확신도 게이트 캐스케이드는 그 Pareto 위의 두 점을 $\tau$ 하나로 잇는 연속 곡선으로 바꾸는가? char-CNN 급 정확도를 얼마나 싸게 살 수 있으며, 그 게이트는 최적 라우터에 얼마나 근접한가? | ✅ 답 완료 (F4-F5-F6)                                            | $\tau$ 재선택 + ECE 신설로 게이트 전제 보강                |
| RQ2         | 캐스케이드는 실제 WAF 우회 기법(인코딩·주석 삽입·대소문자 변형)에 얼마나 취약한가? 나아가 정확도가 아닌 지연을 표적으로 하는 비용 기반 공격이 성립하는가?                           | ✅ 답 완료 (F7-F8-F11)                                           | 새 트랙 기준선 재측정                                  |
| RQ3         | 적대적 증강은 학습에서 보지 못한 변형까지 일반화되는가? 캐스케이드에서 그 대가는 어느 통화(정확도 vs 지연)로 지불되는가?                                               | ✅ 답 완료 (F9-F10-F14)                                          | 새 트랙에서 전 구성 재조립                               |
| RQ4         | 탐지 신호가 콘텐츠에서 사라질 때(인코딩→암호화), 내용 기반 이미지 탐지는 어디서 원리적으로 붕괴하는가?                                                          | ✅ RQ4a 완료(F12) / ⚠️ RQ4b 포화(G6)                              | 영향 적음 — 엔트로피 스위프는 데이터셋 의존이 약함                 |
| RQ6         | 1차와 2차의 표현 간 불일치 자체가 "회피 시도"의 탐지 신호가 되는가?                                                                            | ⚠️ 부분 답 — ROC-AUC 0.764, 커버리지 35.5% → 기준 0.90 미달, 보조 지표로만 보고 | 재측정                                           |
| (RQ7<br>후보) | 2020년 데이터로 학습한 탐지기는 2025년 실운영 공격에 얼마나 일반화되는가? (시간축 일반화)                                                              | —                                                            | Data 2025 외부셋 실험 시 RQ7 로 뒤에 추가 (번호 재배열 금지 준수) |

#### 3.3 ⚠️ 원 RQ1 문구와 HARKing 방지 원칙

RQ1 은 원래 다음과 같았다.

"이미지 기반 CNN 이 텍스트 모델과 유사하거나 더 나은 성능을 보이는가?"

실측 답은 "아니오"(F1)였다. 결과를 본 뒤 질문을 비용 축으로 바꾸는 것은 사후가설(HARKing)이 될 수 있다. → 논문 서술에서 반드시 지킬 원칙 3가지:

- 1. 원 RQ1 문구와 그 답이 '아니오'였음을 그대로 보고한다. 숨기거나 바뀌치지 않는다.
- 2. RQ5(캐스케이드)는 그 음성 결과에서 파생된 질문임을 명시한다.
- 3. Phase 12 이후의 판정 기준(H5·H6·H7)은 실측 전에 문서로 고정한다(docs/11 §7 — 이행 완료).

이렇게 쓰면 "질문을 살짝 바꾼 것"이 아니라 "음성 결과에서 출발한 설계"가 되어, 선행 8편 중 유의성 검정이 0편인 상황(docs/12 §0)에서 오히려 방법론적 강점이 된다.

3.4 논문 서술 순서 (번호 순이 아니다)

RQ1 (음성 결과: 이미지 단독은 진다)  
↳ RQ5 (그래서 캐스케이드 – 이 논문의 제안)  
↳ RQ2 (그 제안은 회피에 얼마나 버티는가 + 비용 공격)  
↳ RQ3 (방어를 붙이면 어떻게 되는가)  
↳ RQ6 (제안 구조에서만 공짜로 얻어지는 능력)  
RQ4 (별도 축: 내용 기반 탐지 자체의 경계)

3.5 범위 가정

- 다중 클래스 분류(정상 / SQLi / XSS / Cmdl). 시간 부족 시 이진으로 축소 가능.
- G4 적응형 공격(방어를 알고 설계된 공격)은 수행하지 않는다 — 한계로 명시(docs/11 §9).

4. 평가지표

4.1 시기별 지표 변천 — 옛 문서를 읽을 때의 환산표

| 시기              | 헤드라인                                                                            | 근거 문헌                                            | 옛 문서에서 이 수치를 보면                     |
|-----------------|---------------------------------------------------------------------------------|--------------------------------------------------|-------------------------------------|
| 1기 (Phase 1~6)  | Accuracy · Macro-F1 · ROC-AUC                                                   | 웹공격 탐지 관행                                        | 균형 데이터 가정 → 탐지력 과대평가. 참고용           |
| 2기 (Phase 7~12) | <b>MCC</b> · PR-AUC · benign-evasion (+Acc·Macro-F1)                            | MDPI <i>Technologies</i> 2026 · arXiv:2512.19203 | <b>2기 실측 기록으로 읽는다.</b> 새 측정과 섞지 말 것 |
| 3기 (현행)         | Macro-F1 · PR-AUC · <b>TPR@FPR</b> · <b>pAUC</b> · 경보부 하 · ECE + benign-evasion | <b>Arp et al.</b> (+지표별 개별 출처)                   | —                                   |

4.2 현행 지표 — 순서·역할·상태 (docs/13 §1.2)

| 순서 | 지표                                    | 역할                                  | 상태 |
|----|---------------------------------------|-------------------------------------|----|
| 1  | Precision / Recall / <b>Macro-F1</b>  | 선행연구 직접 대조(최근 논문의 공통 통화가 F1)        | 기존 |
| 2  | <b>PR-AUC (AP, macro)</b>             | 희귀 사건에서 ROC 보다 정보량 큼                | 기존 |
| 3  | <b>TPR@1%FPR · TPR@0.1%FPR</b>        | 운영 지점 성능 — WAF 는 저 FPR 영역에서만 쓸 수 있다 | 신설 |
| 4  | <b>pAUC</b> (FPR≤0.01 구간 정규화 ROC-AUC) | "ROC 는 감당 가능한 FPR 까지만 보라"           | 신설 |

| 순서 | 지표                                            | 역할                                                           | 상태 |
|----|-----------------------------------------------|--------------------------------------------------------------|----|
| 5  | 경보 부하 (배포 base rate 기준 100만 요청당 오탐 수)         | FPR 을 음성 클래스 base rate 와 함께 논한다                              | 신설 |
| 6  | ECE / MCE / reliability diagram               | $\tau$ 게이트가 곧 확신도 임계값 $\rightarrow$ 교정 품질(단, 논거는 \$4.5 로 하향) | 신설 |
| 7  | Accuracy, 전구간 ROC-AUC                         | 부록                                                           | 강등 |
| —  | benign-evasion (공격 $\rightarrow$ Normal 오분류율) | 4.5번이 그것의 운영 해석판                                             | 유지 |
| —  | ~~MCC~~                                       | —                                                            | 제거 |

**왜 경보 부하가 필요한지 — 실제로 드러난 예** (docs/13 §1.5, 합성 입력 점검): Accuracy 0.997 / Macro-F1 0.995 / PR-AUC 1.000 / ROC-AUC 1.000 인 모델도, FPR 0.03 에 배포 공격비율 0.1% 를 가정하면 **경보 정밀도가 0.032** 로 붕괴한다(100만 요청당 헛경보 29,970건 vs 진짜 1,000건). 기존 지표만 보고했다면 이 모델을 "완벽"으로 보고했을 것이다.

### 4.3 최근 논문이 실제로 보고하는 지표 (docs/13 §1.3)

| 논문                          | 게재                                    | 보고 지표                                         |
|-----------------------------|---------------------------------------|-----------------------------------------------|
| WADBERT (Dual-channel BERT) | arXiv:2601.21893, 2026-01             | <b>F1</b> (CSIC2010 99.63%, SR-BH2020 99.50%) |
| E-WebGuard                  | <b>Comput. &amp; Secur. 148, 2025</b> | Acc/P/R/F1 계열                                 |
| WAMM                        | arXiv:2512.23610, 2025-12             | Accuracy, 추론 속도( $\mu$ s), TP 차단율             |

$\rightarrow$  ① 공통 통화는 여전히 **F1** 이므로 1번에 둔다. ② 이들은 **저 FPR 운영 지점·경보 부하·교정을 보고하지 않는다**  $\rightarrow$  3·4·5·6번을 넣으면 심사 대응을 넘어 **방법론적 우위**가 된다. "지표를 바꿨다"가 아니라 "**선행연구가 안 보는 운영 지점을 본다**"로 서술할 수 있다.

### 4.4 ⚠️ 지표별 1차 출처가 다르다 (docs/13 §1.6 — 원문 대조 완료 2026-08-23)

논문 인용 시 이 표를 그대로 쓴다. "신설 4종은 전부 Arp et al. 권고"는 틀린 서술이다.

| 지표             | 1차 출처                                                                                                                                                    |
|----------------|----------------------------------------------------------------------------------------------------------------------------------------------------------|
| TPR@FPR · pAUC | <b>Arp et al. P7</b> (bounded AUC 권고) + pAUC 의 [0.5,1] 표준화는 <b>McClish, Medical Decision Making 9(3):190–195, 1989</b>                                   |
| 경보 부하          | <b>Arp et al. P8</b> + 계보의 원점 <b>Axelsson, ACM CCS 1999</b> (doi:10.1145/319709.319710)                                                                  |
| ECE / MCE      | <b>Naeini et al. AAAI 2015</b> (정의의 원점) · <b>Guo et al. ICML 2017</b> (현대 신경망 평가 표준화) · <b>CalexNet</b> arXiv:2509.08318 (조기종료 분기 캘리브레이션 = 캐스케이드 도메인 판본) |
| (MCC — 제거됨)    | Arp et al. P8 이 실제로 권고하는 것은 사실 — \$4.6                                                                                                                   |

**Arp et al. 서지 확정:** *Dos and Don'ts of Machine Learning in Computer Security*, **USENIX Security 2022**. 확장판 *Pitfalls in Machine Learning for Computer Security*, **CACM 67(11):104–112, 2024**, doi:10.1145/3643456 (ACM DL **Research Highlights** 게재 = CACM 편집위 선별 지면). 원문 PDF 2편 확보 완료(2026-08-23).

### 4.5 ⚠️ ECE 의 필요성 논거는 하향됐다

기존 문구 "**확신도가 교정되어 있지 않으면 게이트 자체가 근거를 잃는다**" 는 **정확하지 않다**.  $\tau$  게이트에 필요한 것은 확신도의 **순위(ranking)** 이지 수치의 교정이 아니다. 확신도가 전부 0.99 쪽에 쏠려 있어도 val 에서  $\tau=0.995$  로 잡히면 게

이트는 정상 작동한다. → 심사에서 "val 에서  $\tau$  를 튜닝하는데 교정이 왜 필요한가" 한 마디에 무너지는 논거다.

정정된 논거 3가지 (이것만 쓴다):

- 1.  $\tau$  의 이식성 — 교정돼 있어야 val 에서 고른  $\tau$  가 다른 데이터셋·배포 환경에서 같은 의미를 갖는다. **Data 2025 외 부셋 실험이 정확히 이 검증이다.**
- 2.  $\tau$  의 해석 가능성 — "확신도 0.9 미만은 승급"이 실제로 "오답 확률 10%"를 뜻하는지.
- 3. 틀린 샘플에 과확신하는 실패의 진단 — 이건 순위 자체를 망가뜨리므로 게이트에 실제 타격이다. 평균인 ECE 가 가 리는 이 국소 실패를 **MCE** 가 드러낸다.

4.6 MCC — 제거했지만 근거는 보존한다

⚠ **먼저 사실관계:** MCC 자체는 "고등학생 지표"가 아니다. Arp et al. 은 P8 권고 절에서 "*other measures like Matthews Correlation Coefficient (MCC) are more suitable*" 라고 **명시적으로 권고**한다(원문 대조 확인). 우리 2기 트랙이 정확히 그 조건이었다 (Normal 3.4k vs 공격 각 28~40k — 공격이 인위적으로 과대표집).

그럼에도 **완전 제거로 확정**했다(2026-08-13 교수 지시 이행). 이 근거 문단을 문서에 **보존하는 이유**는 심사에서 "**왜 권고 지표를 뺐나**" 라는 역질문이 나올 때의 대응 자료이기 때문이다.

4.7 ⚠ **MCC 제거의 파급 — 기준 지표 이관 (docs/13 §1.4)**

MCC 는 보고 열이 아니라 **자동 의사결정의 기준값**으로 코드에 박혀 있었다. 단순 삭제하면 캐스케이드가 임계값을 못 고르고 CV 비교가 기준을 잃는다. 이관 완료된 5개 지점:

| # | 위치                                         | MCC 의 역할                                    | 이관 결과                                                |
|---|--------------------------------------------|---------------------------------------------|------------------------------------------------------|
| 1 | src/eval/metrics.py                        | mcc 키 산출·출력                                 | 키·출력·import 삭제 (부활 방지 테스트 있음)                        |
| 2 | src/eval/cv_compare.py                     | --metric 기본값 = paired t-test 기준             | 기본값 <b>macro_f1</b> , choices 에서 <b>mcc</b> 제거       |
| 3 | src/models/cascade.py                      | EXIT_MCC_TOLERANCE=0.0011 + 조기종 료 임계값 선택 규칙 | <b>EXIT_F1_TOLERANCE</b> 로 개명, 규칙을 Macro-F1 기준으로 재작성 |
| 4 | src/models/cascade.py                      | H7-1 판정 기준                                  | Macro-F1 기준으로 재서술                                    |
| 5 | tests/test_cascade.py , test_early_exit.py | 스윙 행 픽처치 키                                  | 키 이름 갱신                                              |

⚠ **허용폭 0.0011 은 그대로 쓸 수 없다.** 이 값은 "단일 split 실행 간 MCC 흔들림  $\pm 0.11\text{pp}$ "를 실측해 정한 것이다 (docs/07 §2.5). 지표가 Macro-F1 로 바뀌고 데이터셋도 바뀌므로 **새 트랙에서 같은 방식으로 노이즈 폭을 재측정**한 뒤 값을 정한다. 그 전까지 **조기종료 임계값 선택 결과는 신뢰하지 않는다.**

4.8 구현 현황 — 무엇이 코드에 있고 무엇이 없는가

지표 **추가**는 src/eval/metrics.py 한 곳만 고치면 전 모델에 자동 반영된다 (베이스라인·CNN·ViT·캐스케이드가 같은 함수를 탄다). 지표 **제거**는 그렇지 않다(→ §4.7).

| 구현                                                            | 위치         | 상태   |
|---------------------------------------------------------------|------------|------|
| tpr_at_fpr · partial_roc_auc · attack_operating_points        | metrics.py | ✅ 구현 |
| calibration_metrics (ece·mce·bins) · save_reliability_diagram | metrics.py | ✅ 구현 |
| alert_load (경보 부하) · attack_score                             | metrics.py | ✅ 구현 |

| 구현                                                                                                                                                                              | 위치                                                                                     | 상태                                                                                                                       |
|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------------------------|
| 기준값 상수 <code>TARGET_FPRS=(0.01, 0.001)</code> ·<br><code>PAUC_MAX_FPR=0.01</code> ·<br><code>DEPLOYMENT_ATTACK_PREVALENCES=(0.01, 0.001)</code> ·<br><code>ECE_N_BINS=15</code> | <code>metrics.py</code>                                                                | ✅ 모듈 상수                                                                                                                  |
| CV 요약의 신설 지표 평탄화 ·<br><code>LOWER_IS_BETTER</code> (ece:benign-evasion)                                                                                                         | <code>cross_validate.py</code> ·<br><code>cv_compare.py</code>                         | ✅ 구현                                                                                                                     |
| 교정 곡선 저장( <code>cal_&lt;tag&gt;.png</code> )                                                                                                                                    | <code>train.py</code> ·<br><code>baseline_tfidf.py</code> ·<br><code>cascade.py</code> | ✅ 구현                                                                                                                     |
| <code>nan</code> 누출 차단( <code>_finite_or_none</code> )                                                                                                                          | <code>metrics.py</code> 3곳                                                             | ✅ 구현(2026-08-23)                                                                                                         |
| 부트스트랩 95% CI                                                                                                                                                                    | —                                                                                      | ❌ 미구현. docs/13 §1.2 에 "신설"로 적혀 있으나 <code>src/</code> 전체에 <code>bootstrap</code> 문자열 0건(2026-08-23 확인) → 구현하거나 문구를 내려야 한다 |

검증 상태: `python -m pytest tests/ -q` → 168 passed (2026-08-23).

#### 4.9 ⚠ 저 FPR 지표는 현 트랙에서 측정 불가 (docs/13 §1.7)

FPR의 해상도는 test 셋 Normal 표본 수가 결정한다. Normal 이 N 개면 FPR 이 가질 수 있는 값은  $1/N$  의 배수뿐이다. 목표 FPR 이  $1/N$  보다 작으면 그 지점은 존재하지 않고, 코드는 "오탐 0건" 지점을 집어온다 → 사실상 "무오탐 탐지율"이 되고 표본 하나에 크게 흔들린다.

| 트랙                                             | test Normal | 해상도(1건당) | TPR@1%FPR    | TPR@0.1%FPR |
|------------------------------------------------|-------------|----------|--------------|-------------|
| <code>payload_4class_csicnorm</code> (2기 주 트랙) | 722         | 0.139pp  | FP 7.2건 → 거침 | ❌ 정의 불가     |
| <code>csic_binary</code>                       | 726         | 0.138pp  | 거침           | ❌ 불가        |
| <code>payload_4class</code>                    | 8,062       | 0.0124pp | ✅            | FP 8건 → 겨우  |
| SR-BH 2020 (예정, test 15%)                      | ≈78,779     | 0.0013pp | ✅            | ✅           |

pAUC( $FPR \leq 1\%$ )도 같은 제약을 받는다 — 722개 트랙에서는 그 구간에 들어오는 음성이 약 7개뿐이라 계단 몇 칸짜리 값이 되어 비교 근거로 쓸 수 없다.

→ 결론 2가지

- 신설 지표 3종(TPR@FPR·pAUC·경보부하)은 데이터셋 교체와 세트로만 성립한다. 현 트랙에서 미리 돌려 논문에 실는 것은 위험하다. 이걸 오히려 교수 지시 2건(지표·데이터셋)이 왜 한 묶음이어야 하는지에 대한 논거가 된다.
- 논문에 저 FPR 지표를 실을 때는 Normal 표본 수를 반드시 함께 표기한다.

외부 검증셋(Data 2025)에서의 지표 가용성 — 악성만 있고 정상이 없다.

| 지표                           | 외부셋                                              |
|------------------------------|--------------------------------------------------|
| Recall(탐지율) · benign-evasion | ✅                                                |
| ECE / MCE                    | ✅ (확신도 vs 정답 여부만 필요) → §4.5-1 의 $\tau$ 이식성 검증 핵심 |
| TPR@FPR · pAUC · 경보부하 · FPR  | ❌ 음성 표본이 없어 정의 불가                                |

5. 데이터셋

5.1 지금까지 실제로 쓴 트랙 (1~2기 — 현재 experiments/results/ 의 근거)

| 트랙                       | 구성                                                           | train / val / test        | test 클래스 분포                                               | 용도                                     |
|--------------------------|--------------------------------------------------------------|---------------------------|-----------------------------------------------------------|----------------------------------------|
| payload_4class           | Kaggle 페이로드 단독 (206,636행 → 중복 제거 199,793)                    | 139,855 / 29,969 / 29,969 | CmdI 7,202 · <b>Normal 8,062</b> · SQLi 8,592 · XSS 6,113 | RQ1 초기                                 |
| payload_4class_csicnorm★ | 공격=Kaggle, <b>Normal=CSIC 2010 실트래픽</b> (156,115행 → 150,855) | 105,598 / 22,628 / 22,629 | CmdI 7,202 · <b>Normal 722</b> · SQLi 8,592 · XSS 6,113   | <b>2기 주 트랙</b> — F1~F14 대부분의 근거        |
| csic_binary              | CSIC 2010 단독 이진 (61,065행 → <b>중복 77.9% 제거</b> → 13,498)      | 9,448 / 2,025 / 2,025     | Anomalous 1,299 · Normal 726                              | 보조                                     |
| ustc_flow_binary         | USTC-TFC2016 세션 → 앞 2304B → 48×48                            | —                         | —                                                         | RQ4b (F1 0.9999 <b>포화</b> → 부록 강등, G6) |

공통: train/val/test = 70/15/15, stratified, **seed=42 결정론**. 완전 중복 제거 후 분할. 클래스 불균형 트랙은 `train.py --balance` (train 만 언더샘플링, val/test 는 실분포 유지).

⚠ **payload\_4class\_csicnorm** 의 구조적 약점이 곧 교체 사유다 — "합성 공격 페이로드 + CSIC 정상 트래픽"을 억지로 붙인 조합이고, Normal 이 722개(test)뿐이라 \$4.9 의 저 FPR 지표가 성립하지 않는다.

5.2 Phase 13 확정 구성 (docs/13 §2.4) — 아직 미착수

| 역할        | 데이터셋                                        | 연도   | 용도                                      | 상태           |
|-----------|---------------------------------------------|------|-----------------------------------------|--------------|
| 주 트랙      | SR-BH 2020                                  | 2020 | RQ1·RQ2·RQ3·RQ5·RQ6 전부의 새 측정 기반         | ⌚ 다운로드부터 미착수 |
| 외부 검증     | Data 2025 (Zenodo)                          | 2025 | 시간축 일반화 탐지율(정상 없음 → recall 전용)          | ⌚ 미착수        |
| legacy 대조 | CSIC 2010                                   | 2010 | 선행연구(E-WebGuard·WADBERT) 직접 대조용, 부록/비교표 | 보유           |
| 페이로드 보강   | Kaggle SQLi-XSS-CmdI + PayloadsAllTheThings | —    | RQ2 회피 변형 생성 재료로 유지                     | 보유           |
| 흐름 (RQ4b) | USTC-TFC2016                                | 2016 | 포화 → 부록 강등(G6 결정 유지)                    | 보유           |

SR-BH 2020

Riera, Higuera, Higuera, Herraiz, Montalvo. *A new multi-label dataset for Web attacks CAPEC classification using machine learning techniques*. **Computers & Security 120 (2022) 102788**. doi:10.1016/j.cose.2022.102788 · 배포: Harvard Dataverse doi:10.7910/DVN/OGOIXX

- 수집: 2020-07, 12일간, 인터넷에 **실제 노출된** WordPress 서버
- 라벨링: ModSecurity 2.9.2 + **CRS 3.3.0** detection-only 기록 → **수동/반자동 검수로 교정**
- 규모: **907,814 요청** (정상 525,195 / 이상 382,619), 24 features + **13 라벨**(멀티라벨 CAPEC)
- 최근 사용: E-WebGuard(2025), WADBERT(2026-01), WAMM(2025-12)



- **✅ 우리 파이프라인 적합성:** 배포본에 `request_http_request (URI)` · `request_body` · `request_user_agent` · `request_cookie` 등 원문 문자열 컬럼이 살아 있다 → 바이트→48×48 변환이 수정 없이 동작. ⚠ 원 논문의 방법은 필드별 ASCII 평균으로 24개 수치를 뽑는 것이라, 이 구분을 놓치면 "인코딩된 수치뿐이라 이미지화 불가"로 오판한다.

## Data 2025

Lucz, G., Forstner, B. *A Thirty-Day Dataset of Malicious HTTP Requests Blocked by OWASP ModSecurity on a Production Web Server*. **Data 2025, 10(11), 186**. doi:10.3390/data10110186 배포: Zenodo 10.5281/zenodo.17178461 (owasp.zip, 29.5 MB, **CC-BY 4.0**)

- 2025년 실운영 서버에서 OWASP CRS 가 실제 차단한 악성 요청 30일분
- 익명화하되 method / URI / 헤더 / user-agent / 발동 rule ID 구조 보존 → 원문 바이트 사용 가능
- ⚠ 악성만 있고 정상이 없다 → FPR 계산 불가. 탐지율(recall) 전용 외부 테스트셋으로만 쓴다.

왜 이게 지시 ②의 진짜 답인가: 2020년판으로 바꾸는 것만으로는 "그것도 6년 전"이라는 같은 지적을 다시 받는다. 대신 2020년 데이터로 학습 → 2025년 실운영 공격 탐지율을 보고하면, "최신성"을 데이터 연도가 아니라 측정된 일반화 결과로 답하게 된다.

## 5.3 CSIC 2010 은 왜 강등이고 삭제가 아닌가

문헌에서 확인된 실제 한계: 단일 도메인·단일 머신 트래픽 / 공격 유형 수가 매우 제한적이고 세부 공격 유형 라벨이 없어 선행연구가 대체로 이진 분류에 머뭇 / 정상 트래픽이 합성. → 논문에는 "2010년이라서"보다 구성 자체의 한계로 쓰는 게 강하다.

⚠ 다만 CSIC 2010 은 2025~2026 최신 논문에서도 여전히 보고된다(E-WebGuard 2025, WADBERT 2026 둘 다 CSIC 2010 + SR-BH 2020 병기). 삭제하면 선행연구와 대조할 통화를 잃는다 → 강등 + 병기.

## 5.4 CAPEC 13라벨 → 4클래스 매핑 (docs/13 §2.5, 2026-08-13 확정)

| SR-BH 라벨 (CAPEC)                                                                 | 우리 클래스                  |
|----------------------------------------------------------------------------------|-------------------------|
| 000 Normal                                                                       | Normal                  |
| 66 SQL Injection                                                                 | SQLi                    |
| 242 Code Injection                                                               | XSS(→ 권고: CodeInj 로 표기) |
| 88 OS Command Injection                                                          | CmdI                    |
| 나머지 9라벨 (Path Traversal, Scanning, Verb Tampering, HTTP Response Splitting, ...) | 제외(또는 부록 별도 보고)         |

⚠ 코드로 못박아야 할 규칙 3건 (나중에 "왜 이 수치인가"를 재현할 근거):

1. 242 Code Injection → XSS 는 완전한 동의어가 아니다. CAPEC-242 는 코드 주입 일반이며 XSS 를 포함하지만 더 넓다. → CodeInj 로 표기하고 "XSS 를 포함하는 상위 범주"로 명시. 이름을 XSS 로 두면 과대주장이 된다.
2. 멀티라벨 → 멀티클래스 축약 규칙. 대상 4클래스 중 2개 이상이 붙은 요청은 모호 표본으로 제외하고 제외 건수를 보고.
3. 제외된 9라벨 요청의 처리. Normal 로 넣으면 안 된다(그건 공격이다) → 데이터셋에서 제외하고 규모를 보고. ⚠ 이걸 Normal 로 흘리면 §5.5 의 라벨 노이즈를 우리 손으로 재현하게 된다.

## 5.5 ⚠ 알려진 리스크 — SR-BH 2020 의 라벨 노이즈

Osama et al. *Enhanced Web Payload Classification Using WAMM*. arXiv:2512.23610, 2025-12 (rev. 2026-01)

이 논문의 감사 결과 **정상**으로 **잘못 라벨된 악성 요청 48,522건**(정상 525,195건의 **약 9.2%**). LLM 판정 후 웹 침투테스트 전문가가 300여 표본을 수동 검증(LLM 판정과 100% 일치)했다고 보고한다.

대응 방침 3가지

- 1. 착수 시 **우리 자체 감사**를 먼저 돌린다(정규식 기반 SQLi/XSS/Cmdl 시그니처로 정상 클래스 스캔) → 규모를 **우리 손으로 재현 확인**한 뒤 수치를 인용.
- 2. **정제 전/후를 병기 보고**한다. 라벨 노이즈를 숨기지 않는 것 자체가 방법론 점수다.
- 3. ⚠️ 노이즈는 **정상 클래스에 악성이 섞인** 방향 → benign-evasion 과 FPR 을 **낙관적으로** 왜곡한다. 우리 헤드라인이 정확히 그 지표들이므로 이 감사는 **선택이 아니라 필수**다.

5.6 이미지 변환 (데이터셋이 바뀌어도 그대로)

- **Step 1** 정규화: 페이로드 문자열 → UTF-8 바이트 시퀀스
- **Step 2** 2D 리셰이프(Nataraj 방식): 고정 폭 48 → 48×48. 짧으면 zero-padding, 길면 truncation. 픽셀 = 바이트값 0~255 → 0~1 정규화. 픽셀 (r,c) ↔ 바이트 오프셋 `r*48+c` 는 **전단사**(Grad-CAM 역변환 근거)
- **Step 3** RGB 채널: **R = raw byte / G = 문자 클래스 / B = local n-gram 엔트로피**. 인코더는 `src/imaging/channel_encoders.py` 레지스트리(교체형 ablation)

6. 기존 실측 F1~F14 — 무엇이 어떤 지표로 측정됐나

⚠️ 아래 수치는 전부 2기 기준(주로 `payload_4class_csicnorm`, MCC 헤드라인)이다. 데이터셋 교체 시 `experiments/results/` 의 141개 JSON 전부와 그로부터 파생된 그림·문구가 무효화된다. 살아남는 것은 코드·아이디어·방법론 전부 — 트랙만 갈아끼우면 그대로 동작한다.

| #   | 확정 사실                                          | 수치 (2기 실측)                                                                           | 출처            | 지표             |
|-----|------------------------------------------------|--------------------------------------------------------------------------------------|---------------|----------------|
| F1  | 이미지화 CNN 은 텍스트 베이 스라인에 <b>유의하게 열세</b>          | char-CNN 0.9944±0.0004 vs RGB CNN 0.9762±0.0025, adj p=0.0010~0.0247                 | docs/04 §5.1  | MCC            |
| F2  | gray→RGB 개선은 <b>진짜</b> (CV 확정)                 | 0.9493 → 0.9762 ( <b>+2.69pp</b> ), adj p=0.0037~0.0201                              | docs/07 §2.5  | MCC            |
| F3  | RGB 채널 조합 간 우열은 <b>판정 불가</b>                   | 6쌍 전부 adj p ≥ 0.88                                                                   | docs/07 §2.5  | MCC            |
| F4  | clean 탐지 <b>상보성 이득 없음</b>                      | 캐스케이드 vs char-CNN 탐지집합 <b>완전 동일</b> (둘 다 놓침 8건)                                      | docs/09 §9.6  | 탐지집합           |
| F5  | 캐스케이드는 <b>같은 정확도를 5.07배 싸게</b>                 | esc 7.99%, F1 0.9934 / MCC 0.9907, 0.0111 ms                                         | docs/09 §9.2  | MCC + 지연       |
| F6  | 확신도 게이트는 <b>나쁜 라우터</b>                         | oracle esc 1.87% vs 실측 27.73% ( <b>14.8배 과잉</b> )                                    | docs/09 §9.4  | 에스컬레이션         |
| F7  | <b>비용 기반 공격 실재</b>                             | 저에스컬레이션 운영점에서 2.54%→5.50%( <b>2.17배</b> ), SLA 붕괴                                    | docs/09 §9.5  | 에스컬레이션         |
| F8  | benign-evasion 은 <b>전 모델·전 구성 바닥</b> (~0)      | 0.0000~0.0022, 방어 후에도 동일                                                             | docs/05 §13.2 | benign-evasion |
| F9  | 적대적 증강은 <b>본 변형만 암기</b> 하며 그 정도는 <b>표현에 의존</b> | S-0 -44.20pp vs S-A -4.80pp. S-A/S-0 비: 이미지 7.0~43.9% (미달) vs 텍스트 41.7~ <b>54.0%</b> | docs/10 §11.2 | any-misclass   |
| F10 | 캐스케이드는 방어 비용을 <b>지연으로 지불</b>                   | clean MCC -0.12pp인데 esc 34.97%→ <b>69.52%</b>                                        | docs/10 §11.3 | MCC + esc      |

| #               | 확정 사실                                 | 수치 (2기 실측)                                                                                                    | 출처            | 지표           |
|-----------------|---------------------------------------|---------------------------------------------------------------------------------------------------------------|---------------|--------------|
| F11             | 변형 하 동요를 만드는 것은 사실상 3종                | space_to_comment +0.635, url_encode +0.584, double_url_encode +0.572                                          | docs/10 §11.2 | any-misclass |
| F12             | 탐지를 죽이는 것은 엔트로피가 아니라 랜덤화(키)           | S3 고정키 XOR F1 0.9445 유지 → S4 AES <b>0.3965 붕괴</b>                                                             | docs/06 §5.5  | F1           |
| F13             | ViT/hybrid 는 채택 안 함                   | hybrid vs CNN 평균차 +0.12pp, p(adj)=1.0000                                                                      | docs/08 §9.4  | MCC          |
| <b>F14</b><br>★ | 비학습 정규화(B)가 학습형 증강(A)을 이긴다 — 미지 변형 조건 | RGB CNN 0.2112 vs 0.4693/0.5704, char-CNN 0.0650 vs 0.1176/0.1383. 단 B 는 이미지 표현에서 clean MCC <b>-1.04pp</b> 지불 | docs/10 §11.5 | any-misclass |

### 6.1 Phase 12 확장 3안 (docs/11 §16)

| 방안                  | 무엇을 시도했나                      | 판정                  | 핵심 수치                                                           | 논문에서의 자리                 |
|---------------------|-------------------------------|---------------------|-----------------------------------------------------------------|--------------------------|
| <b>M1</b> 표현 불일치    | 1·2차 예측 불일치를 회피 시도 신호로        | ⚠ 보조 지표로 하향         | ROC-AUC <b>0.764</b> (기준 0.90), 커버리지 35.5%, 추가 비용 <b>0</b>      | RQ6 부분 답 · 기여 C5         |
| <b>M2</b> 인코딩 불변 채널 | %XX · &#NN 해독 후 문자 클래스를 G 채널로 | ⚠ 단독 미채택 / 증강 결합 채택 | 단독 0.4707→ <b>0.5552</b> (악화) · 증강 결합 S-A 0.4227→ <b>0.1833</b> | RQ3 보강 · 기여 <b>C6·C7</b> |
| <b>M4</b> 다단 조기 종료  | 1차 비용 C_cnn 자체를 낮춰 속도 천장 돌파   | ❌ 미채택               | 연산 18% 생략했는데 시간 <b>+3.3%</b> , speedup 5.07→ <b>3.99배</b>       | 한계로 정직 보고                |
| (M3) CAM 크롭         | —                             | ● 미착수               | —                                                               | 후보로만 남음                  |

부정 결과 2건(M4·ViT/hybrid)을 숨기지 않는다 — 오히려 C1("1차가 이미 충분히 싸다")의 근거를 강화한다.

## 7. 논문이 주장하는 기여 — 확정 문구와 금지어 (마스터 §11)

이 표의 왼쪽 문구를 그대로 쓰고, 오른쪽은 쓰지 않는다. 선행 대조로 이미 하향된 결과다.

| #  | 기여                        | ✅ 쓸 문구                                                                                                | ❌ 금지 문구                                                           |
|----|---------------------------|-------------------------------------------------------------------------------------------------------|-------------------------------------------------------------------|
| C1 | 표현 이질적 캐스케이드              | "이미지 표현과 텍스트 표현을 잇는 캐스케이드로, 같은 정확도를 <b>5.07배 싸게</b> 얻는다"                                              | "이미지 기반이 더 정확하다"                                                  |
| C2 | τ 연속 스펙트럼                 | "τ 하나가 clean 정확도뿐 아니라 공격 하 강건성에서도 두 단독 모델 사이를 연속 이동한다(0.364↔0.556)"                                   | —                                                                 |
| C3 | problem-space slowdown 공격 | "DeepSloth 가 보인 slowdown 공격이 웹공격 탐지 캐스케이드에서도 성립함을 실측했다. 단 <b>모델 접근 없이, 실제로 동작하는 페이로드 변형만으로</b> 2.17배" | "새로운 공격면을 발견했다"                                                   |
| C4 | 게이트 품질의 상한 정량화            | "확신도 게이트는 oracle 대비 <b>14.8배 과잉</b> 공급한다 — 개선 여지의 상한을 못 박았다"                                          | —                                                                 |
| C5 | 표현 불일치 회피 탐지 ⚠ 하향         | "추가 비용 정확히 0(모드 A)으로 회피 시도의 보조 신호를 낸다 (ROC-AUC 0.764, 커버리지 35.5%)"                                    | "표현 불일치를 쓰는 것이 새롭다" · "회피 시도를 탐지한다" · "실용적이다"                     |
| C6 | 인코딩 불변 채널 + 증강 ⚠ 조건부      | "단독으로는 들지 않지만, 적대적 증강과 결합하면 <b>미지</b> 인코딩 변형 일반화를 <b>10.9%→69.2%</b> 로 끌어올린다(clean 대가 -0.02pp)"       | "인코딩 불변 채널이 회피를 막는다" · "정규화 방어를 대체한다" · "F9 를 해결했다"(→ 부분적으로 뒤집었다) |

| #  | 기여               | ✅ 쓸 문구                                                                   | ❌ 금지 문구               |
|----|------------------|--------------------------------------------------------------------------|-----------------------|
| C7 | 인코딩 회피의 작동 원리 진단 | "인코딩 회피의 위력은 바이트 <b>값</b> 이 아니라 <b>길이</b> <b>팽창에 따른 2차원 배치 밀림</b> 에서 온다" | "길이가 <b>유일한</b> 원인이다" |

⚠️ **속도 배수는 2차 기준 모델을 명시해 병기한다** — 우리 5.07배 vs Tasdemir 20배는 기준이 BERT 라 직접 비교 불가.

**정직하게 함께 쓸 한계:** 이미지 단독은 텍스트 모델에 **유의하게 진다**(F1) / clean 탐지 **상보성 이득 없음**(F4) / 적대적 증강은 **본 변형만 암기**(F9) / 소규모 배포에서는 **char-CNN 단독으로 충분** / **적응형 공격 미수행**(G4) / 성능 차이는 **표면 토큰 포화 상태의 트랙**에서 측정됨 / **조기종료 1차 미채택**(M4) / 적대적 증강 방어를 켜면 **C5의 불일치 신호가 지워진다** (0.764→0.598) / **M2 단독은 회피를 오히려 쉽게 만든다**(0.5981→0.6550) / **M2를 켜면 비용 기반 공격 표면이 넓어진다** (esc 35.39%→77.71%)

## 8. 남은 작업 — 순서

**GPU는 1대뿐 → 학습 작업은 순차 실행 필수.**

| 순서 | 작업                                                                                                                                                                                   | 상태                                                                           |
|----|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------------|
| 1  | SR-BH 2020 Dataverse 다운로드 → 포맷-용량-라이선스 <b>직접 확인</b>                                                                                                                                  | ⌚ ⚠️ 2026-08-13에 한 기기에서 Dataverse API 조회가 네트워크 차단으로 실패 → 브라우저 또는 다른 기기에서 재확인 |
| 2  | <code>src/data/download_srbh.py</code> · <code>download_owasp2025.py</code> 신설 + <code>.gitignore</code> 에 <code>data/raw/&lt;신규&gt;</code> 추가 후 <code>git check-ignore -v</code> 확인 | ⌚                                                                            |
| 3  | SR-BH <b>라벨 노이즈 자체 감사</b> (\$5.5) → 48,522건 규모 재현 확인                                                                                                                                 | ⌚                                                                            |
| 4  | CAPEC→4클래스 매핑 구현(\$5.4 규칙 3건) + 제외 건수 보고                                                                                                                                             | ⌚                                                                            |
| 5  | 새 트랙 <code>preprocess.py</code> → <code>build_image_dataset.py</code> (⚠️ <code>--track choices 5곳</code> 동시 갱신)                                                                     | ⌚                                                                            |
| 6  | <b>부트스트랩 95% CI</b> 구현 또는 문서 문구 하향(\$4.8)                                                                                                                                            | ⌚                                                                            |
| 7  | Macro-F1 노이즈 폭 재측정 → <code>EXIT_F1_TOLERANCE</code> 확정(\$4.7)                                                                                                                        | ⌚ 새 트랙 준비 후                                                                  |
| 8  | RQ1 본 측정(모델 6종 + TF-IDF) → 5-fold CV                                                                                                                                                 | ⌚                                                                            |
| 9  | 캐스케이드 $\tau$ 재선택 + ECE                                                                                                                                                               | ⌚                                                                            |
| 10 | RQ2 / RQ3 회피·방어 재측정                                                                                                                                                                  | ⌚                                                                            |
| 11 | Data 2025 외부 탐지율(= RQ7 후보)                                                                                                                                                           | ⌚                                                                            |
| 12 | legacy CSIC 2010 대조표(선행연구 비교용, 축소 구성)                                                                                                                                                | ⌚                                                                            |
| 13 | 마스터 §3 데이터셋 표를 §5.2로 갱신 · docs/12 §1에 Phase 13 인용문헌 등재                                                                                                                               | ⌚                                                                            |

## 9. 자주 헷갈리는 것 — 빠른 대조표

| 마주친 것                    | 어떻게 읽어야 하나                                                    |
|--------------------------|---------------------------------------------------------------|
| 옛 문서에서 <b>MCC</b> 수치를 봤다 | <b>2기 실측 기록</b> 이다. 그대로 보존하되 새 측정과 섞지 않는다. 현행 기준 지표는 Macro-F1 |

| 마주친 것                                               | 어떻게 읽어야 하나                                                                         |
|-----------------------------------------------------|------------------------------------------------------------------------------------|
| 문서에 "제안 CNN" 이라고 쓰여 있다                              | 옛 표기다. 제안 모델은 <b>캐스케이드</b> . 문맥상 1차 부품이면 <b>RGB CNN</b> 으로 읽는다                     |
| 회피율 <b>0.594 / 0.5944 / 0.0022</b>                  | <b>gray CNN 실측</b> 이다. RGB 기준선은 <b>0.5981</b>                                      |
| <b>hybrid</b> 라는 말                                  | docs/08 의 <b>모델 아키텍처</b> (CNN stem+Transformer, 미채택). 배치 구조인 <b>cascade</b> 와 다른 것 |
| <b>ECE</b> 는 <b>Arp et al.</b> 권고라고 쓰여 있다           | ❌ <b>오귀속</b> . 원문에 언급 0건. Naeini 2015 · Guo 2017 로 인용(\$4.4)                       |
| <b>TPR@0.1%FPR</b> 수치가 나왔다                          | 현 트랙(Normal 722)에서는 <b>정의 불가</b> . SR-BH 교체 후에만 유효(\$4.9)                          |
| 문서에 <b>부트스트랩 95% CI</b> 가 "신설"로 적혀 있다               | <b>미구현</b> 이다( <code>src/</code> 에 <code>bootstrap</code> 0건). 문서가 앞서 나간 상태(\$4.8) |
| <code>experiments/results/*.json</code> 의 수치        | 2기 기준. 데이터셋 교체 시 <b>141개 전부 무효화</b> — 코드·방법론은 그대로 산다                               |
| <code>docs/reports/thesis_onepass_2026-08-12</code> | <b>Phase 13 이전 판</b> . 흐름·기여 문구는 유효, <b>지표·데이터셋 절은 이 문서로 갱신해 읽을 것</b>              |
| <code>docs/07 §1.3</code> (지표 모범사례)                 | <b>Phase 13 으로 대체됨</b> . 두 문헌은 보조 근거로만 남음                                          |
| RQ 번호를 정리하고 싶다                                      | ❌ <b>재배열 금지</b> . 파일명에 박혀 있다. 새 질문은 뒤 번호(RQ7~)로 추가                                 |

## 10. 이 문서의 유지 규칙

- **새 사실을 여기서 만들지 않는다**. 결정은 해당 Phase 문서( `docs/0N_*.md` )에 먼저 남기고, 여기에는 **요약과 포인터만** 옮긴다.
- 마스터 설계 문서( `docs/web_attack_image_cnn_thesis_design.md` )와 어긋나면 **마스터가 옳다** — 단, 지표·데이터셋 만은 **docs/13 이 최신**이다.
- 데이터셋 교체가 실행되면 §5.1(옛 트랙) → §5.2(새 트랙)로 무게를 옮기고 §6 표에 **재측정 완료 열**을 추가한다.

## 개정 이력

| 날짜         | 내용                                           |
|------------|----------------------------------------------|
| 2026-08-24 | 신설. 1~3기 구분, RQ·지표·데이터셋 통합 정리, 자주 헛갈리는 것 대조표 |

## 재생성 (PDF)

이 문서가 **원본(Markdown)** 이고 PDF 는 산출물이다. 내용은 `.md` 를 고치고 다시 굽는다. `pandoc · wkhtmltopdf` 는 이 프로젝트에 없으므로 **python-markdown → HTML → Chrome 헤드리스**로 굽는다. Chrome 은 상대 경로 출력에서 액세스 거부가 나므로 **입출력 모두 절대 경로**로 넘긴다. 산출물은 `docs/reports/current_baseline_2026-08-24.pdf` , 굽는 절차는 `docs/reports/README.md` 의 "PDF 재생성" 절을 따른다(경로는 `git rev-parse --show-toplevel` 로 그때그때 구할 것).