

웹 공격 페이로드 이미지화 기반 캐스케이드 탐지 및 적대적 강건성 연구

제안 모델을 단일 CNN → 캐스케이드로 전환한 이후의 설계·실측 정리 (Phase 10 ~ 12)

보고일 2026-08-08 · 보고 범위 2026-07-25 ~ 2026-08-06 · 근거 문서 docs/09 · 10 · 11 · 12 및 마스터 설계 문서

세 줄 요약

- 이미지화 CNN 단독으로는 텍스트 모델을 이길 수 없음을 통계적으로 확정했습니다 (char-CNN MCC 0.9944 vs RGB CNN 0.9762, 5-fold CV + Holm 보정 adj $p = 0.0010 \sim 0.0247$). 대신 처리량이 **13.6배** 우위였습니다.
- 그래서 제안 모델을 캐스케이드(1차 RGB CNN → 확신도 미달분만 2차 char-CNN)로 바꿨습니다. 트래픽의 **8.0%만** 2차로 올려 char-CNN급 정확도를 유지하면서 지연을 **5.07배** 낮췄고, 추가 학습은 0입니다.
- 구조를 바꾸자 단일 모델에서는 보이지 않던 축이 두 개 드러났습니다 — 지연을 표적으로 하는 비용 기반 공격(에스컬레이션 2.17배)과, 방어의 대가가 정확도가 아니라 지연으로 지불된다는 현상(esc 34.97% → 69.52%)입니다.

1. 왜 제안 모델을 캐스케이드로 바꿨는가

지난 미팅에서 지적하신 “신규성이 약하다”에 대해, 먼저 단일 이미지 CNN의 한계를 실측으로 확정하는 것부터 했습니다. 결론은 **음성**이었습니다.

모델	clean Macro-F1	MCC	추론 처리량	Pareto 상 위치
gray CNN (1채널)	0.9676	0.9418	92,466 /s	정확도 하위 · 비용 최저
RGB CNN (48×48×3)	0.9804	0.9725	81,964 /s	RGB로 격차를 좁혔으나 여전히 열세
char-CNN (텍스트)	0.9954	0.9940	6,010 /s	정확도 최상위 · 13.6배 느림

표 1. 단일 모델 비교 (트랙 `payload_4class_csicnorm`, Normal = CSIC 2010 실트래픽)

- 열세는 통계적으로 유의합니다. 5-fold CV + paired t-test + Holm 보정에서 char-CNN MCC 0.9944 ± 0.0004 vs RGB CNN 0.9762 ± 0.0025 , adj $p = 0.0010 \sim 0.0247$.
- 교수님께서 제안하신 RGB 채널 확장은 효과가 확인됐습니다. gray→RGB로 MCC 0.9493 → 0.9762 (+2.69pp, adj $p = 0.0037 \sim 0.0201$). 다만 어떤 채널 조합이 더 낫다고는 말할 수 없습니다 — 6쌍 전부 adj $p \geq 0.88$ 이라 조합 간 우열은 판정 불가입니다.
- 즉 이미지화의 실질적 강점은 탐지 우월성이 아니라 비용이었습니다.


이 관찰이 방향 전환의 근거입니다. Pareto front 위에 떨어져 있는 두 점(싼 CNN · 정확한 char-CNN)을 τ 하나로 잇는 연속 곡선으로 바꾸는 것이 이번에 만든 제안 모델입니다.

연구 정직성에 대한 조치(HARKing 방지) — 원래 RQ1은 “이미지 기반 CNN이 텍스트 모델과 유사하거나 더 나은 성능을 보이는가”였고 그 답은 “아니오”였습니다. 결과를 보고 질문을 비용 축으로 바꾸면 사후가설이 되므로, ① 원 RQ1 문구와 그 답이 ‘아니오’였음을 그대로 보고하고, ② 캐스케이드(RQ5)는 그 음성 결과에서 파생된 질문임을 명시하며, ③ 이후 실험의 판정 기준은 실측 전에 문서로 고정했습니다. 선행 8편 중 유의성 검정을 한 논문이 0편인 상황이라, 이 서술은 오히려 방법론적 강점이 됩니다.

용어 정리 (혼동 사고 후 확정)

용어	의미
캐스케이드	논문의 제안 모델. 1차 RGB CNN + 2차 char-CNN의 배치 구조(아키텍처가 아님)
RGB CNN	48×48×3 단일 CNN. 제안 지위를 내려놓고 지표 비교 기준이 됨
gray CNN	1채널 판본
“제안 CNN”	⚠ 사용 금지 — (ㄱ)제안 모델과 (ㄴ)캐스케이드 1차 부품 두 뜻으로 읽혀 실제 혼동이 발생

2. 제안 모델 — 확신도 게이트 캐스케이드



비용식은 다음과 같습니다 (r = 에스컬레이션 비율, 2차 호출 비중).

$$C_{\text{cascade}} = C_{\text{cnn}} + r \cdot C_{\text{charcnn}} = 0.0066 + r \times 0.0561 \text{ [ms/sample]}$$

2.1 왜 '특징 융합'이 아니라 '캐스케이드'인가 — 가장 중요한 설계 결정

"하이브리드"라고 하면 보통 두 브랜치의 특징을 concat하는 **융합형**을 떠올립니다. 그러나 융합형은 **모든 입력이 두 브랜치를 전부 통과**하므로 비용이 $C_{\text{cnn}} + C_{\text{charcnn}}$ 이 되어 **char-CNN 단독보다도 느립니다**(실측 0.0627 ms vs 0.0561 ms). 애초 목표였던 속도 이점이 사라지므로 채택하지 않았습니다. 선택적 실행(cascade)만이 "정확도는 char-CNN급, 지연은 CNN급"을 가능하게 합니다.

2.2 이 구조의 이론적 성질

- $\tau \rightarrow 0$ 이면 아무도 넘기지 않으므로 **정확히 RGB CNN 단독**, $\tau \rightarrow 1$ 이면 전부 넘기므로 **정확히 char-CNN 단독**으로 수렴합니다. 즉 두 단독 모델은 이 구조의 **특수해**이고, 캐스케이드는 그 사이의 **연속 스펙트럼**입니다. 이 성질은 단위 테스트로 고정해 뒀습니다(`tests/test_cascade.py`, $\tau=0 \rightarrow \text{esc } 0.0000/\text{F1 } 0.9676$, $\tau=1.01 \rightarrow \text{esc } 1.0000/\text{F1 } 0.9954$ 로 실측 확인).
- **추가 학습이 없습니다.** Phase 4-5에서 이미 학습해 둔 체크포인트 2개를 조합할 뿐입니다. 덕분에 "같은 모델을 배치 방식만 바꿨다"는 인과가 깨끗하게 성립합니다.

2.3 공정성을 지키기 위해 박아둔 세 가지 못

원칙	내용
τ 는 val에서만	test로 τ 를 고르면 임계값이 test에 과적합됩니다(정보 누수). val 스윕으로 확정 한 뒤 test에 1회만 적용합니다. 회피 실험에서도 τ 는 파일에서 읽어 오며, 공격 데이터로 재튜닝하지 않습니다.
기준선 4종 병기	① 1차 단독(곡선 좌단) ② 2차 단독(우단) ③ 융합형 비용선 (안 쓴 대안이 실제로 더 비쌈을 증명) ④ oracle 라우팅 (1차가 틀린 것만 정확히 승급 = 어떤 게이트도 넘을 수 없는 상한)
지연 측정 프로토콜	초기 단발 측정은 실행 간 60% 나 흔들려 speedup이 9.30배로 부풀려졌습니다(재측정 7.05 배). → 5라운드 × 20회의 중앙값 으로 바꾸고 전 arm을 재실측(변동 0.7% 이내). 헤드라인이 속도인 실험에서는 지연의 분산 관리가 정확도만큼 중요했습니다.

3. Phase 10 실측 — 정확도·비용 (2026-07-25, RTX 4080 SUPER)

트랙 `payload_4class_csicnorm`, val 22,628 · test 22,629건, 4클래스 (CommandInjection / Normal / SQLInjection / XSS). **학습 없이** 기존 체크포인트를 조립해 arm 7종을 측정했습니다.

1차	2차	τ 선택 규칙	τ	esc	Macro-F1	MCC	ms/sample	spd	ovh
gray	char-CNN	match-teacher	0.9998	78.36%	0.9954	0.9940	0.0508	1.11×	7.74×
gray	char-CNN	budget 10%	0.7509	7.46%	0.9856	0.9756	0.0108	5.23×	1.64×
gray	char-CNN	budget 5%	0.5678	2.54%	0.9754	0.9579	0.0080	7.05×	1.22×
gray	BiLSTM	match-teacher	0.8099	9.98%	0.9831	0.9714	0.0212	6.92×	3.23×
RGB	char-CNN	match-teacher	0.9971	27.73%	0.9955	0.9941	0.0223	2.52×	3.32×
RGB	char-CNN	budget 10%	0.9425	7.99%	0.9934	0.9907	0.0111	5.07×	1.68×
RGB	char-CNN	budget 5%	0.7516	2.71%	0.9890	0.9837	0.0081	6.92×	1.23×

표 2. 캐스케이드 arm 7종. esc = 에스컬레이션 비율, spd = 2차 단독 대비 배속, ovh = 1차 단독 대비 비용

같은 test-같은 지표의 기준선 — **1차 단독** gray 0.9676 / RGB 0.9804 (둘 다 0.0066 ms) · **2차 단독** char-CNN 0.9954 (0.0561 ms) / BiLSTM 0.9838 (0.1468 ms) · **융합형** 0.0627 ms.

헤드라인 — “같은 정확도를 몇 분의 1 비용으로”

대표 운영점(RGB 1차 + 예산 10%)에서 트래픽의 **8.0%만 2차로 올려** char-CNN 대비 MCC 0.9940 → 0.9907(−0.33pp)에 **지연은 5.07배 낮습니다**(0.0561 → 0.0111 ms/sample). 융합형(0.0627 ms) 대비로는 5.6배입니다.

정확도를 한 치도 양보하지 않으려면 **match-teacher** 운영점이 27.7% 에스컬레이션으로 char-CNN을 **넘어서면서** 도(MCC 0.9941 vs 0.9940) 2.52배 빠릅니다.

과장하지 않기 위해 명시하는 것 — 이 트랙의 clean 지표는 **표면 토큰 포화** 상태이고, 위 정확도 차이는 단일 split의 실행 간 노이즈(± 0.11 pp)와 같은 자릿수입니다. 따라서 **정확도 개선은 주장하지 않습니다**. 주장의 무게는 전부 **“같은 정확도에서의 비용 절감폭”**에 둡니다 — 이쪽은 노이즈에 훨씬 둔감합니다.




그림 1. τ 스위치로 그린 정확도-비용 곡선(대표 운영점, RGB 1차). 왼쪽: 에스컬레이션 대비 Macro-F1 — 초록 마름모가 운영점($\tau=0.9425$), 주황 별이 oracle 상한. 오른쪽: 에스컬레이션 대비 평균 지연 — 융합형(0.0627 ms)·2차 단독(0.0561 ms) 대비 운영점이 0.0111 ms에 놓인다. 곡선의 왼쪽 끝이 CNN 단독, 오른쪽 끝이 char-CNN 단독이라는 점이 이 구조의 핵심 성질이다.

3.1 미결 과제 — 확산도 게이트는 '나쁜 라우터'다

oracle 라우팅(1차가 틀린 샘플만 정확히 승급했을 때의 상한)과 비교하면 격차가 큼니다.

1차	oracle esc	oracle Macro-F1	실측 게이트가 같은 수준에 쓰는 esc	과잉 배수
gray	3.96%	0.9968	78.36%	19.8배
RGB	1.87%	0.9982	27.73%	14.8배

max softmax 확산도는 오답을 **15~20배 과잉 포착**합니다. 문제는 정확도 상한이 아니라 **비용 상한**이며, 게이트를 개선하면(예측 엔트로피 · 상위 2개 마진 · temperature scaling) 정확도를 그대로 두고 에스컬레이션만 최대 -25.8pp 줄일 여지가 있습니다. **남은 가장 큰 미착수 이득**으로 기록해 뒀습니다.

3.2 clean에서 새로 잡는 건 없다 (상보성 분석)

공격 21,907건 기준으로 캐스케이드와 char-CNN의 **탐지 집합이 완전히 동일**합니다(둘 다 놓친 8건까지 같음). 즉 이 구조의 기여는 **탐지 집합의 확장이 아니라 비용 축소**입니다 — 이 점을 논문에서 과장하지 않고 그대로 씁니다.

4. RQ2 — 회피 강건성과 ‘비용 기반 공격’

실제 WAF 우회 기법(주석 삽입 `/**/`, 대소문자 랜덤화, 공백/탭 치환, URL-이중 인코딩, 동치 SQL 토큰 치환, XSS `String.fromCharCode`)을 누적 $k=1\sim 5$ 로 적용한 problem-space 공격입니다. 모든 변형은 의미를 보존합니다(실제로 동작하는 페이로드).

운영점	benign-evasion	any-misclass	esc (clean)	esc (공격 k=5)	비용 증가
$\tau=0.9998$ (match-teacher)	0.0001	0.3641	78.36%	79.96%	1.02배
$\tau=0.5678$ (budget 5%)	0.0009	0.5557	2.54%	5.50%	2.17배
참고: char-CNN 단독	0.0001	0.2239	—	—	—
참고: gray CNN 단독	0.0022	0.5944	—	—	—

표 3. 회피 하 거동 ($k=5$ 기준). any-misclass = 변형 하 오분류율, 낮을수록 강건

4.1 τ 스펙트럼은 강건성 축에서도 성립한다

캐스케이드의 회피 강건성은 τ 하나로 두 단독 모델을 연속 이동합니다 — 높은 τ 는 char-CNN 쪽(0.364), 낮은 τ 는 CNN 쪽(0.556). 2장에서 주장한 “연속 스펙트럼”이 clean 정확도뿐 아니라 공격 하 강건성에서도 성립한다는 뜻입니다. 다만 $\tau=0.9998$ 에서도 char-CNN 단독(0.224)에는 못 미치는데, 원인은 넘기지 않은 21.6%입니다. 1차가 확신했기에 남은 샘플인데 변형되면 틀립니다 — “확신도가 높다”가 “변형에 강하다”를 뜻하지 않습니다.

4.2 ★ 캐스케이드 고유의 공격면 — 정확도가 아니라 지연을 표적으로

저에스컬레이션 운영점에서 공격은 정확도를 흔드는 것과 동시에 2차 호출을 2.17배로 늘려 예산 5% SLA를 깨뜨렸습니다(2.54% → 5.50%). 정확도 지표만 보면 전혀 보이지 않는 열화입니다. 반대로 이미 78%를 넘기는 운영점은 증가 여지가 없어 1.02배에 그칩니다 — 즉 비용 공격 표면은 캐스케이드가 싸게 돌아갈수록 커집니다. 운영 시 에스컬레이션 비율을 지표로 모니터링하고 상한 큐를 두는 완화책이 필요합니다.

이 축은 제안 모델을 캐스케이드로 세웠기 때문에 비로소 존재하는 발견입니다. 단일 모델만 다뤘다면 논문에 존재하지 않았을 결과입니다.

5. Phase 11 / RQ3 — 적대적 방어 학습 (2026-08-02)

5.1 먼저 해결한 문제 — 방어할 대상이 이미 0이었다

원래 RQ3의 주 지표였던 **benign-evasion**(공격→Normal 오분류 = 실제 WAF 우회)은 5개 모델 전부 ~0이었습니니다(0.0000~0.0022). 이대로 실험하면 **0을 0으로 만드는 실험**이라 개선폭도 희생폭도 측정 불가능합니다. → 주지표를 **any-misclass**(변형 하 오분류율)로 옮기고, benign-evasion은 바닥 효과를 명시하며 보조 지표로 계속 보고합니다. **이 교체는 결과를 보고 고른 것이 아니라**, 근거가 되는 실측이 방어 실험 **이전에** 이미 존재했고 문서로 사전 고정했습니다.

5.2 방법론의 핵심 — seen / held-out 변형 분할

학습에 쓴 변형으로 평가하면 “본 적 있는 공격을 막았다”는 자명한 결과가 나옵니다. 그래서 변형 14종을 4계열 (E 인코딩 / C 대소문자 / W 공백·주석 / S 구문동치)로 묶고 두 시나리오를 함께 돌렸습니다.

- **S-0 (seen)**: 4계열 전부를 학습에 사용 → **낙관 상한**. 방어가 원리적으로 얼마나 줄일 수 있는가
- **S-A (leave-encoding-out)**: 가장 강력한 인코딩 계열(E)을 **학습에서 완전 배제** → **진짜 질문**. 미지의 변형에 일반화되는가

증강은 ‘추가’가 아니라 **치환** 방식입니다(공격 클래스만 불어내면 FPR이 방어 효과가 아니라 분포 변화 때문에 움직임). held-out 계열은 train은 물론 **val에도 넣지 않았습니다**(조기 종료로 통한 간접 누수 차단). 캐스케이드는 학습이 없으므로 **1·2차 양쪽 방어본을** 조립하고 τ 를 그 구성의 val에서 **재선택**했습니다.

구성	캐스케이드 (제안)	Δ	단일 RGB CNN (비교 기준)	Δ
base (방어 없음)	0.4707	—	0.5981	—
advtrain S-0 p0.25	0.0318	-43.89pp	0.1955	-40.26pp
advtrain S-0 p0.5	0.0287	-44.20pp	0.2029	-39.52pp
advtrain S-A p0.25	0.2780	-19.27pp	0.4693	-12.88pp
advtrain S-A p0.5	0.4227	-4.80pp	0.5704	-2.77pp

표 4. 적대적 증강 후 any-misclass (k=5). ρ = 증강 비율

가설	판정	근거
H3-1 강건성 개선	✅ 효과 있음	S-0에서 40~44pp 감소 = 사전 기준(10pp)의 4배 이상. 단일 split 노이즈(± 0.11 pp)와 자릿수가 달라 CV 불필요
H3-2 대가 수용성	⚠️ 구조에 따라 갈림	캐스케이드는 전 구성 통과(clean MCC 최대 -0.12pp, FPR 변화 0.00pp). 단일 CNN은 4셀 중 2셀 실패 (S-0 p0.5 -1.86pp, S-A p0.25 -3.81pp·FPR +0.69pp)
H3-3 ★ 미지 변형 일반화	❌ “본 변형 암기”	S-A/S-0 감소폭 비 — 캐스케이드 43.9%(p0.25)·10.9%(p0.5), 단일 CNN 32.0%·7.0%. 네 경우 모두 사전 기준 50% 미달
H3-4 학습형 vs 정규화	⏸ 미판정	정규화 방어(입력 디코딩) 2셀 미실행 — 남은 작업

표 5. 사전에 고정한 가설의 판정 결과

H3-3이 이 Phase의 핵심 결과입니다. 학습에 넣은 변형은 거의 완벽히 막지만(0.47 → 0.03), 빼둔 인코딩 계열에는 거의 무력합니다. 원인은 명확합니다 — base에서 오분류를 끌어올린 변형이 사실상

`space_to_comment` (+0.635) · `url_encode` (+0.584) · `double_url_encode` (+0.572) **3종뿐**이고, 그중 2종이 held-

out이라 S-A는 배울 것이 거의 없었습니다. 이는 “인코딩 계열은 학습으로 못 막고 **입력 정규화**로 막는 종류”라는 가설을 강하게 지지합니다.

5.3 ★ 캐스케이드는 방어 비용을 ‘정확도’가 아니라 ‘지연’으로 지불한다

구조	clean MCC 하락	공격 하 에스컬레이션
단일 RGB CNN	최대 -3.81pp (FPR +0.69pp)	해당 없음
캐스케이드	최대 -0.12pp (FPR 변화 0)	34.97% → 최대 69.52%

캐스케이드는 1차가 흔들려도 2차 char-CNN이 받아내므로 **정확도를 거의 잃지 않습니다**. 대신 1차 확신도가 낮아진 만큼 2차 호출이 늘어 **추론 비용이 최대 2배**가 됩니다. 정확도 지표만 보면 “공짜 방어”로 오독되는 열화이며, 4.2절의 비용 기반 공격과 직결됩니다.

부수 확인 — RGB 캐스케이드 기준선을 새로 잴 것이 옳았습니다(RGB 0.4707 vs gray 0.3641, **10.66pp 차이**). 단일 CNN에서는 gray(0.594)와 RGB(0.598)가 사실상 같았지만, 캐스케이드에서는 채널이 1차 확신도 분포를 바꾸고 그것이 곧 게이트 동작이라 영향이 훨씬 큼니다. gray 수치를 기준선으로 썼다면 감소폭이 10pp 이상 왜곡됐을 것입니다.

강건성 서열(방어 없음): char-CNN 0.224 < gray 캐스케이드 0.364 < **RGB 캐스케이드 0.471** < gray CNN 0.594 < RGB CNN 0.598. 제안 모델이 단일 CNN보다 강건하다는 관계는 유지됩니다.

6. Phase 12 — 선행연구 대조와 주장 강도 하향

“비용 개선”을 헤드라인으로 세운 이상, 같은 축의 선행이 있는지를 먼저 조사했습니다. 결과: 있습니다. 숨기지 않고 먼저 인용하고 대조하는 방식으로 씁니다.

6.1 최근접 선행 — Tasdemir et al. 2023 (SQLi 캐스케이드, 20배)

Advancing SQL Injection Detection for High-Speed Data Centers: A Novel Approach Using Cascaded NLP (arXiv:2312.13041, QUB + NVIDIA). 1차 Passive Aggressive Classifier → 2차 BERT-Electra, accuracy 99.86%, transformer 단독 대비 20배. 본문을 전수 확인한 결과 겹치는 것은 프레이밍뿐이었습니다.

축	Tasdemir 2023	본 연구
1·2차 표현	텍스트 → 텍스트 (동종)	이미지 → 텍스트 (이종) ★
라우팅 기준	예측 클래스(양성이면 승급, Viola-Jones식)	예측 불확실성(max softmax < τ)
운영점	고정 1개	τ 연속 곡선, 양 끝점이 두 단독 모델로 수렴 ★
과제	SQLi 이진	SQLi / XSS / CmdI / Normal 4-class
게이트 품질	미분석	oracle 대비 14.8배 과잉 정량화 ★
회피 강건성	없음(본문 전수 검색 결과 0)	RQ2 / RQ3 전 축 ★
통계 검정	없음	5-fold CV + Holm 보정
속도 배수	20× (기준 = BERT)	5.07× (기준 = char-CNN)

표 6. Tasdemir 2023과의 대조 — 이 표가 차별화의 근거

배수(20배 vs 5.07배)를 직접 비교하지 않습니다. 2차 기준 모델이 다릅니다(BERT vs char-CNN). BERT가 훨씬 무거워 분모가 크므로 배수가 크게 나옵니다. 논문에는 기준 모델을 반드시 명시해 병기합니다.

추가로 말할 수 있는 것: 저쪽 라우팅은 “공격처럼 보이면 무조건 승급”이라 비용 공격에 구조적으로 더 취약합니다 (공격자가 확신도를 조작할 필요조차 없음). 우리 확신도 게이트는 1차의 확신도를 떨어뜨려야 하므로 한 단계 어렵지만, 그럼에도 problem-space 변형만으로 2.17배가 나왔습니다.

6.2 조사 결과 스스로 낮춘 주장 3건

항목	선행	조정 내용
비용 기반 공격	DeepSloth (ICLR 2021 Spotlight) — 지연 1.5~5배 증폭	✗ “새 공격면을 발견했다” → ✔ “DeepSloth의 slowdown 공격이 웹공격 탐지 캐스케이드에서도 성립함을 실측했다. 단 DeepSloth는 픽셀 gradient 교란(화이트박스)인 반면 본 연구는 모델 접근 없이, 실제로 동작하는 페이로드 변형만으로 달성했다” — 낮춘 문구가 오히려 더 강합니다
표현 불일치 탐지 (향후 M1)	Feature Squeezing (NDSS 2018) — 원본 vs 압축 입력의 예측 불일치	✗ “표현 불일치를 쓰는 것이 새롭다” → ✔ “캐스케이드는 이미 2차를 돌리므로 추가 비용이 정확히 0” — 메커니즘은 기지이고, 구조적 무상화가 유일한 기여
다단 조기종료 (향후 M4)	ACM SAC 2025 early-exit IDS, FastDet, ACM CSUR 서베이	침입탐지 도메인에 직접 선행이 다수 → 우선순위 최하로 강등 권고
RQ4 (암호화 경계)	Kutlimuratov et al. 2026 (Computers 15,174) — 흐름 메타데이터만으로 470k req/s	“신호가 흐름으로 이동한다”는 결론의 도착지에 이미 사람이 있음 → 기여를 “경계가 어디인지 정량 증명”으로 좁힘 (고정키 XOR F1 0.9445 유지 → AES 0.3965 붕괴, 즉 엔트로피가 아니라 키 랜덤화가 원인)

6.3 반대로 확인된 우리 쪽 강점

- 개선폭 기준선이 낮습니다. *Scientific Reports*(Tadhani 2024)의 헤드라인 개선은 **+0.34pp**, *Applied Sciences*(Eroğlu 2025)는 **+0.11~1.27pp**로 "surpassing existing benchmarks"라고 씁니다. 우리 gray→RGB **+2.69pp(5-fold CV)**는 한 자릿수 큼니다.
- 선행 8편 중 유의성 검정을 한 논문이 0편, 회피/적대적 실험을 한 논문도 0편입니다. 즉 RQ2·RQ3 측은 경쟁자가 없습니다.
- 단, 그 축에서 우리가 가진 것은 아직 "제안 모델도 흔들린다"는 음성 결과가 중심입니다 → 다음 Phase의 동기.

7. 개정된 연구 질문과 기여

기존 RQ 표에는 캐스케이드를 묻는 질문 자체가 없었습니다. RQ1을 “정확도 우월성”이 아닌 “정확도-비용 Pareto 상의 위치 규명”으로 정직하게 고치고, RQ5(캐스케이드)를 신설했습니다. 번호는 파일명·상호참조에 박혀 있어 재배열하지 않고 뒤로 추가했습니다.

ID	질문	상태
RQ1	페이로드를 바이트 이미지로 변환한 탐지는 텍스트 기반 모델 대비 정확도-비용 Pareto 상 어디에 위치하는가?	✅ 답 완료 — 음성 결과
RQ5 ★	확신도 게이트 캐스케이드는 그 Pareto 위의 두 점을 τ 하나로 잇는 연속 곡선으로 바꾸는가? char-CNN급 정확도를 얼마나 싸게 살 수 있으며, 그 게이트는 최적 라우터에 얼마나 근접한가?	✅ 답 완료 (본 보고 3장)
RQ2	캐스케이드는 실제 WAF 우회 기법에 얼마나 취약한가? 나아가 정확도가 아닌 지연을 표적으로 하는 비용 기반 공격 이 성립하는가?	✅ 답 완료 (4장)
RQ3	적대적 증강은 학습에서 보지 못한 변형까지 일반화 되는가? 캐스케이드에서 그 대가는 어느 통화로 지불 되는가?	✅ 답 완료 (5장)
RQ4	탐지 신호가 콘텐츠에서 사라질 때(인코딩→암호화), 내용 기반 이미지 탐지는 어디서 원리적으로 붕괴 하는가?	✅ RQ4a 완료 / ⚠️ RQ4b 포화
RQ6	1차와 2차의 표현 간 불일치 자체가 “회피 시도”의 탐지 신호가 되는가? (단일 모델은 원리적으로 불가)	⌚ 미착수 (Phase 12 M1)

표 7. RQ 표 (2026-08-06 개정). 논문 서술 순서는 RQ1 → RQ5 → RQ2 → RQ3 → RQ6, RQ4는 별도 축

7.1 논문이 주장하는 기여 — 선행 대조 후 확정된 문구

#	기여	쓸 문구
C1	표현 이질적 캐스케이드	“이미지 표현과 텍스트 표현을 잇는 캐스케이드로, 같은 정확도를 5.07배 싸게 얻는다 ” (❌ “이미지 기반이 더 정확하다”)
C2	τ 연속 스펙트럼	“ τ 하나가 clean 정확도뿐 아니라 공격 하 강건성에서도 두 단독 모델 사이를 연속 이동한다 (0.364 ↔ 0.556)”
C3	problem-space slowdown 공격	“DeepSloth가 보인 slowdown 공격이 웹공격 탐지 캐스케이드에서도 성립함을 실측했다. 단 모델 접근 없이, 실제로 동작하는 페이로드 변형만으로 2.17배를 달성했다 ” (❌ “새로운 공격면을 발견했다”)
C4	게이트 품질 상한 정량화	“확신도 게이트는 oracle 대비 14.8배 과잉 공급한다 — 개선 여지의 상한을 못 박았다”
(C5)	표현 불일치 회피 탐지 ⌚	“캐스케이드는 이미 2차를 돌리므로 추가 비용 정확히 0 으로 회피 시도를 판정한다” — 미착수

7.2 정직하게 함께 쓸 한계

- 이미지 단독은 텍스트 모델에 **유의하게 진다**.
- clean 탐지 **상보성 이득이 없다** — 캐스케이드의 기여는 탐지 집합 확장이 아니라 비용 축소다.
- 적대적 증강은 **본 변형만** 암기한다.
- 소규모 배포에서는 char-CNN 단독으로 **충분하다**.
- 적응형 공격(방어를 알고 설계된 공격)은 **수행하지 않는다** — 한계로 명시.
- 성능 차이는 **표면 토큰이 포화된** 트랙에서 측정됐다.

- ViT · hybrid(CNN stem + Transformer)는 CNN 대비 +0.12pp, $p(\text{adj})=1.0000$ 으로 **미채택** — 시도했으나 안됐음을 그대로 보고.

8. 진행 현황과 남은 계획

Phase	작업	상태
1-3	데이터 확보 · 전처리 · 이미지 변환	✅ 완료
4	RQ1 모델 비교 (5-fold CV + Holm)	✅ 완료
5	RQ2 회피 공격	✅ 완료
6	RQ4 암호화 경계	✅ RQ4a / ⚠️ RQ4b 포화
7	관련연구 · 지표 개편 · RGB 채널	✅ 완료
8-9	ViT / hybrid arm	✅ 미채택 확정
10	캐스케이드 (제안 모델)	✅ GPU 실측 완료
11	RQ3 적대적 방어	✅ 실측 완료 (정규화 방어만 잔여)
12	캐스케이드 확장 3안 + 비용 축 선행 대조	🔵 설계 확정, 구현 미착수
잔여	미상환 항목 → M1 → M2 → (여유 시 M4) → 논문 작성	🕒

8.1 먼저 갚아야 할 것 (기존 Phase의 구멍)

#	내용	왜 필요한가 / 비용
G1	char-CNN 방어본의 회피 재평가가 미실행	학습은 끝났으나 회피 산출물이 없어 결과 표에 char-CNN 열이 비어 있음. 없으면 “이미지 표현만 방어가 필요하다”는 해석을 배제할 수 없음. 추론만, GPU 30분
G2	정규화 방어(입력 디코딩) 2셀 미실행 → H3-4 미판정	5.2절 결론상 “디코딩 한 줄이 학습형 방어를 이길” 가능성이 높음. 그 결과가 나오면 그것이 더 강한 실무적 기여. M2의 비교 기준이므로 M2보다 먼저 실행
G3	상보성 분석이 clean 한정	변형 테스트셋 상보성 — M1과 같은 실행에서 해결 가능
G4	적응형 공격 미수행	한계로 명시(수행하지 않기로 확정)
G5	관련연구 서지정보 원문 확정	논문 작성 시
G6	RQ4b(USTC 흐름) 포화(F1 0.9999)로 판별력 없음	부록 강등 또는 host 단위 분할 재실험 — 여쭙볼 사항 Q1

8.2 Phase 12 확장 3안

안	내용	신규성 / 비용 / 리스크
M1 (권장)	1.2차 표현 불일치를 “회피 시도” 신호로 사용 (RQ6)	신규성 중상 — Feature Squeezing 선행이 있으나 추가 비용 0이 고유. 새 학습 0. 리스크: 에스컬레이션된 8%에만 정의됨(커버리지)
M2	인코딩 불변 채널 인코더 — 학습으로 못 얻는 불변성을 이미지화 구조에 넣음	신규성 중상. H3-3이 실패한 지점을 정면으로 겨냥. 재빌드 + 1~2셀 학습. 리스크: 정규화 방어와 사실상 같아질 위험 → G2를 먼저 실행해 비교 기준 확보
M4 (강등 권고)	다단 조기종료로 1차 비용 자체를 절감 (5.07배 → 7.2배 예상)	신규성 낮음 — 침입탐지용 early-exit 직접 선행 다수(6.2절). 1셀. 리스크: 보조 헤드가 본 정확도를 해칠 수 있음

세 안 모두 캐스케이드 구조를 전제로만 성립합니다. “단일 모델로도 되는 것”은 제안 모델의 존재 이유가 되지 못하므로 넣지 않았습니다. 판정 기준(H5-1 ROC-AUC $\geq$ 0.90, H6-1 S-A 감소폭 $\geq$ S-0의 50%, H7-2 speedup $\geq$ 6.5배 등)은 실측 전에 이미 문서로 고정했

습니다.

9. 여쭙고 싶은 것

Q1 RQ4 처리 방침 — 가장 먼저 여쭙고 싶습니다

RQ4a(암호화 경계의 정량 증명)는 좋은 결과가 나왔습니다(고정키 XOR F1 0.9445 유지 → AES 0.3965 붕괴 = 탐지를 죽이는 것은 엔트로피가 아니라 **키 랜덤화**). 그런데 ① **RQ4b(흐름 이미지화)**는 **F1 0.9999로 포화**돼 판별력이 없고(USTC-TFC2016이 너무 쉬움), ② 조사해 보니 **흐름 메타데이터 기반 탐지는 이미 선행이 있습니다** (470k req/s). → RQ4 기여를 **경계의 정량 증명으로 좁히고 흐름 실험은 부록으로** 내릴까요, 아니면 host 단위 분할로 재실험해 난이도를 올릴까요?

교수님께서 직접 제안하신 방향이라 임의로 강등하지 않고 여쭙습니다.

Q2 헤드라인을 ‘정확도’가 아니라 ‘비용’으로 두는 것

주장을 “더 정확하다”가 아니라 “**같은 정확도를 5.07배 싸게**”로 두려 합니다. 정확도 차이는 단일 split 노이즈 ($\pm 0.11\text{pp}$)와 같은 자릿수라 주장하지 않을 생각입니다. 이 프레이밍이 심사에서 받아들여질까요?

Q3 남은 기간의 진행 순서 — 3안 중 선택

8.2절 표의 **M1 → M2** 순으로 가고, M4는 직접 선행이 많아 후순위로 내리려 합니다. 동의하시는지요? (구멍 G1 · G2를 먼저 갠 뒤 착수할 계획입니다.)

Q4 음성 결과의 배치

적대적 증강이 **본 변형만 암기**(-44.20 vs -4.80pp), ViT/hybrid **미채택**($p=1.0000$), clean 상보성 이득 0 등 음성 결과가 여럿입니다. ‘한계’로 쓰지 ‘발견’으로 쓰지 어떻게 배치하는 것이 좋을까요?

Q5 비용 기반 공격의 위치 설정

DeepSloth(ICLR 2021)가 early-exit 망에서 자연 1.5~5배 증폭을 이미 보였고 우리 2.17배는 그 범위 안입니다. 다만 DeepSloth는 픽셀 **gradient 교란(화이트박스)**인 반면 우리는 **모델 접근 없이 실제로 동작하는 페이로드 변형만**으로 달성했습니다. 이 정도를 독립 기여로 세울까요, ‘기존 공격의 도메인 이전’으로 낮출까요?

Q6 적응형 공격 미수행

방어 논문의 표준 비판 지점인 **적응형 공격은 수행하지 않을** 계획입니다. 학부 범위에서 ‘한계로 명시’가 수용될 수 있을까요?

Q7 지표 — Accuracy 병기 및 F1 Efficiency 채택 여부

선행 8편은 전부 Accuracy로 보고하는데 저희는 불균형 데이터라 MCC · PR-AUC가 헤드라인입니다. **Accuracy 병기**로 갈까요? 추가로 Tasdemir가 제안한 **F1 Efficiency**(F1과 자연의 가중평균)로 우리 캐스케이드를 평가하면 대조가 깔끔해집니다 — 저희는 τ 스위치가 있어 **가중치 α 별 최적 운영점 이동**까지 그릴 수 있습니다(저쪽은 고정 운영점이라 불가). 채택할까요?

Q8 유사 선행과의 거리

국내 발표문(‘시그니처 필터링 + 2D-CNN 하이브리드’)이 구조적으로 가깝지만 **2쪽 학술발표문**이고 1차가 Suricata 룰셋 · 2차가 Open-set 이상탐지라 메커니즘이 다릅니다. 관련연구에서 **한 문단 구분**으로 충분할까요?

부록. 재현 · 검증 관련 메모

A. 실험 환경

- 학습·측정: RTX 4080 SUPER / PyTorch cu124. 지연은 배치 512 순전파 기준 ms/sample, **CUDA synchronize 필수**(비동기 실행이라 동기화 없이 재면 0에 가깝게 나옴).
- 전처리는 seed=42 결정론, Train/Val/Test = 70/15/15 stratified. 클래스 불균형은 train만 언더샘플링(val/test는 실분포 유지).
- 모든 모델의 평가는 **단일 지표 모듈**로 일원화했습니다(계산 방식 차이 배제). 지표는 Accuracy · Macro-F1 · MCC · PR-AUC · ROC-AUC + attack-focused(benign-evasion / FPR).
- 단위 테스트 80건 통과. 커밋 전 전체 테스트를 실행합니다.

B. 이번 구간에 겪은 재현성 사고와 조치 (방법론 서술에 남길 것)

사고	조치 및 교훈
지연 측정이 실행마다 60% 흔들림 → speedup이 9.30배로 부풀려짐	5라운드 × 20회 중앙값으로 변경 후 전 arm 재실측(변동 0.7% 이내, 실제 7.05배). 헤드라인이 속도인 실험에서 지연의 분산 관리는 정확도만큼 중요하다.
산출물 파일명에 실험 축이 빠져 결과가 서로 덮어씀 (3회 발생)	파일명 규칙을 단일 모듈로 통합. 특히 세 번째는 “당장 못 쓰는 조합이라 막아뒀더니 그 차단이 버그를 가리고 있다가 차단을 푸는 순간 덮어썼다” — 측은 쓸 수 있게 되기 전에 넣어야 한다.
기본 학습률이 한쪽 아키텍처 기준값 이라 ViT 계열이 자동으로 불리했음	lr만 맞춰도 MCC가 최대 +23.9pp 이동. “같은 학습 루프를 썼으니 공정하다”는 성립하지 않는다. 이 교훈을 RQ3의 조기 종료 기준(arm별 자기 목적함수)에 재적용했습니다.
이미지 모델은 학습 데이터에 원문 텍스트가 없어 그 자리에서 변형 불가	train split 전체를 텍스트→이미지 언더플라이 경로로 통일(원본만 기존 경로로 두면 “증강본 여부”가 새 shortcut이 됨). 두 경로가 바이트 단위로 동일함 을 회귀 테스트로 고정.

본 보고서의 모든 수치는 저장소의 설계·의사결정 문서(docs/09 · 10 · 11 · 12)와 실험 산출 JSON에 근거합니다. 실험 결과 JSON은 용량 문제로 저장소에서 제외되어 있으며 재현 스크립트로 재생성됩니다. 그림은 저장소에 추적·보관됩니다.