

# 웹 공격 페이로드 이미지화 기반 캐스케이드 탐지 및 적대적 강건성 연구

제안 모델을 단일 CNN → 캐스케이드로 전환한 이후의 설계·실측 정리

## 세 줄 요약

- 이미지화 CNN **단독**으로는 텍스트 모델을 이길 수 없음을 통계적으로 확정.  
(char-CNN MCC 0.9944 vs RGB CNN 0.9762, 5-fold CV + Holm 보정  $\text{adj } p = 0.0010 \sim 0.0247$ )  
대신 처리량이 **13.6배** 우위.
- 그래서 제안 모델을 **캐스케이드**(1차 RGB CNN → 확신도 미달분만 2차 char-CNN)로 변경.  
트래픽의 **8.0%만** 2차로 올려 char-CNN급 정확도를 유지하면서 지연을 **5.07배** 낮췄고,  
**추가 학습은 0**.
- 구조를 바꾸자 단일 모델에서는 보이지 않던 축이 두 개 드러남.  
**지연을 표적으로 하는 비용 기반 공격**(에스컬레이션 2.17배)과  
**방어의 대가가 정확도가 아니라 지연으로 지불된다는 현상**(esc 34.97% → 69.52%).

## 1. 왜 제안 모델을 캐스케이드로 바꿨는가

단일 이미지 CNN의 한계를 실측으로 확정하는 것부터 진행. 결론은 **음성**.

| 모델                | clean Macro-F1 | MCC    | 추론 처리량    | Pareto 상 위치                  |
|-------------------|----------------|--------|-----------|------------------------------|
| gray CNN (1채널)    | 0.9676         | 0.9418 | 92,466 /s | 정확도 하위 ·<br>비용 최저            |
| RGB CNN (48×48×3) | 0.9804         | 0.9725 | 81,964 /s | RGB로 격차를<br>좁혔으나 여전히 열세      |
| char-CNN (텍스트)    | 0.9954         | 0.9940 | 6,010 /s  | 정확도 최상위 ·<br><b>13.6배 느림</b> |

표 1. 단일 모델 비교 (트랙 payload\_4class\_csicnorm, Normal = CSIC 2010 실트래픽)

- 열세는 통계적으로 유의합니다. 5-fold CV + paired t-test + Holm 보정에서

char-CNN MCC  $0.9944 \pm 0.0004$  vs RGB CNN  $0.9762 \pm 0.0025$ ,  $\text{adj } p = 0.0010 \sim 0.0247$ .

- RGB 채널 확장은 효과가 확인.

gray→RGB로 MCC 0.9493 → 0.9762 (+2.69pp, adj  $p = 0.0037 \sim 0.0201$ ).

다만 어떤 채널 조합이 더 낫다고는 말할 수 없음.

6쌍 전부 adj  $p \geq 0.88$ 이라 조합 간 우열은 판정 불가.

- 즉 이미지화의 실질적 강점은 탐지 우월성이 아니라 비용.

이 관찰이 방향 전환의 근거임.

Pareto front 위에 떨어져 있는 두 점(싼 CNN · 정확한 char-CNN)을  $\tau$  하나로 잇는 연속 곡선으로 바꾸는 것이 이번에 만든 제안 모델.

용어 정리 (혼동 사고 후 확정)

| 용어       | 의미                                                      |
|----------|---------------------------------------------------------|
| 캐스케이드    | 논문의 제안 모델.<br>1차 RGB CNN + 2차 char-CNN의 배치 구조(아키텍처가 아님) |
| RGB CNN  | 48×48×3 단일 CNN.<br>제안 지위를 내려놓고 지표 비교 기준이 됨              |
| gray CNN | 1채널 판본                                                  |

## 2. 제안 모델 — 확신도 게이트 캐스케이드

|                           |   |                                                            |   |                                                               |   |                                                            |
|---------------------------|---|------------------------------------------------------------|---|---------------------------------------------------------------|---|------------------------------------------------------------|
| 입력 페이로드<br>HTTP 요청<br>문자열 | → | 1차 : RGB CNN<br>전량 통과 · 93,988<br>파라미터<br>0.0066 ms/sample | → | 게이트<br>confidence =<br>max softmax<br>≥ $\tau$ 이면 1차<br>판정 채택 | → | 2차 : char-CNN<br>확신도 < $\tau$ 인<br>소수만<br>0.0561 ms/sample |
|---------------------------|---|------------------------------------------------------------|---|---------------------------------------------------------------|---|------------------------------------------------------------|

비용식 ( $r$  = 에스컬레이션 비율, 2차 호출 비중)

$$C_{\text{cascade}} = C_{\text{cnn}} + r \cdot C_{\text{charcnn}} = 0.0066 + r \times 0.0561 \text{ [ms/sample]}$$

### 2.1 왜 ‘특징 융합’이 아니라 ‘캐스케이드’인가 — 가장 중요한 설계 결정

“하이브리드”라고 하면 보통 두 브랜치의 특징을 concat하는 **융합형**을 떠올리지만,  
융합형은 모든 입력이 두 브랜치를 전부 통과하므로 비용이  $C_{\text{cnn}} + C_{\text{charcnn}}$ 이 되어

**char-CNN 단독보다도 느림**(실측 0.0627 ms vs 0.0561 ms).

애초 목표였던 속도 이점이 사라지므로 채택하지 않음.

선택적 실행(cascade)만이 “정확도는 char-CNN급, 지연은 CNN급”을 가능하게 함.

### 2.2 이 구조의 이론적 성질

- $\tau \rightarrow 0$ 이면 아무도 넘기지 않으므로 **정확히 RGB CNN 단독**,  $\tau \rightarrow 1$ 이면 전부 넘기므로 **정확히 char-CNN 단독**으로 수렴.

즉 두 단독 모델은 이 구조의 **특수해**이고, 캐스케이드는 그 사이의 **연속 스펙트럼**.

이 성질은 단위 테스트로 고정.

(tests/test\_cascade.py,  $\tau=0 \rightarrow \text{esc } 0.0000/\text{F1 } 0.9676$ ,  $\tau=1.01 \rightarrow \text{esc } 1.0000/\text{F1 } 0.9954$ 로 실측 확인)

## 2.3 공정성을 지키기 위해 박아둔 세 가지 못

| 원칙              | 내용                                                                                                                                                                     |
|-----------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| $\tau$ 는 val에서만 | test로 $\tau$ 를 고르면 임계값이 test에 과적합(정보 누수).<br><b>val 스윙으로 확인한 뒤 test에 1회만 적용.</b><br>회피 실험에서도 $\tau$ 는 파일에서 읽어 오며, 공격 데이터로 재튜닝하지 <b>않음</b> .                            |
| 기준선 4종 병기       | ① 1차 단독(곡선 좌단)<br>② 2차 단독(우단)<br>③ <b>융합형 비용선</b> (안 쓴 대안이 실제로 더 비쌈을 증명)<br>④ <b>oracle 라우팅</b> (1차가 틀린 것만 정확히 승급 = 어떤 게이트도 넘을 수 없는 상한)                                |
| 지연 측정 프로토콜      | 초기 단발 측정은 실행 간 <b>60%</b> 나 흔들려 speedup이 9.30배로 부풀려졌습니다(재측정 7.05배).<br>→ <b>5라운드 × 20회의 중앙값</b> 으로 바꾸고 전 arm을 재실측(변동 0.7% 이내).<br>헤드라인이 속도인 실험에서는 지연의 분산 관리가 정확도만큼 중요. |

### 3. Phase 10 실측 — 정확도·비용 (2026-07-25, RTX 4080 SUPER)

트랙 payload\_4class\_csicnorm, val 22,628 · test 22,629건, 4클래스 (CommandInjection / Normal / SQLInjection / XSS).

| 1차         | 2차       | $\tau$ 선택<br>규칙   | $\tau$        | esc    | Macro-F1      | MCC           | ms/sample     | spd   | ovh   |
|------------|----------|-------------------|---------------|--------|---------------|---------------|---------------|-------|-------|
| gray       | char-CNN | match-teacher     | <b>0.9998</b> | 78.36% | 0.9954        | 0.9940        | 0.0508        | 1.11× | 7.74× |
| gray       | char-CNN | budget 10%        | 0.7509        | 7.46%  | 0.9856        | 0.9756        | 0.0108        | 5.23× | 1.64× |
| gray       | char-CNN | budget 5%         | 0.5678        | 2.54%  | 0.9754        | 0.9579        | <b>0.0080</b> | 7.05× | 1.22× |
| gray       | BiLSTM   | match-teacher     | 0.8099        | 9.98%  | 0.9831        | 0.9714        | 0.0212        | 6.92× | 3.23× |
| <b>RGB</b> | char-CNN | match-teacher     | 0.9971        | 27.73% | <b>0.9955</b> | <b>0.9941</b> | 0.0223        | 2.52× | 3.32× |
| <b>RGB</b> | char-CNN | <b>budget 10%</b> | 0.9425        | 7.99%  | 0.9934        | 0.9907        | 0.0111        | 5.07× | 1.68× |
| <b>RGB</b> | char-CNN | budget 5%         | 0.7516        | 2.71%  | 0.9890        | 0.9837        | 0.0081        | 6.92× | 1.23× |

표 2. 캐스케이드 arm 7종. esc = 에스컬레이션 비율, spd = 2차 단독 대비 배속, ovh = 1차 단독 대비 비용

같은 test-같은 지표의 기준선 — **1차 단독** gray 0.9676 / RGB 0.9804 (둘 다 0.0066 ms) · **2차 단독** char-CNN 0.9954 (0.0561 ms) / BiLSTM 0.9838 (0.1468 ms) · **융합형** 0.0627 ms.

대표 운영점(RGB 1차 + 예산 10%)에서 트래픽의 **8.0%만 2차로 올려** char-CNN 대비 MCC 0.9940 → 0.9907(−0.33pp)에 **지연은 5.07배 낮음**(0.0561 → 0.0111 ms/sample).

융합형(0.0627 ms) 대비로는 5.6배.

정확도를 한 치도 양보하지 않으려면 **match-teacher** 운영점이 27.7% 에스컬레이션으로 char-CNN을 **넘어서면서도**(MCC 0.9941 vs 0.9940) 2.52배 빠름.

이 트랙의 clean 지표는 **표면 토큰 포화** 상태이고,

위 정확도 차이는 단일 split의 실행 간 노이즈( $\pm 0.11$ pp)와 같은 자릿수.

따라서 **정확도 개선은 주장하지 않습니다**. 주장의 무게는 전부 “같은 정확도에서의 비용 절감폭”에 둬.

Hybrid cascade: CNN (stage-1) -> charcnn (stage-2), payload\_4class\_csicnorm




그림 1.  $\tau$  스위치로 그린 정확도-비용 곡선(대표 운영점, RGB 1차). 왼쪽: 에스컬레이션 대비 Macro-F1 — 초록 마름모가 운영점( $\tau=0.9425$ ), 주황 별이 oracle 상한. 오른쪽: 에스컬레이션 대비 평균 지연 — 융합형(0.0627 ms)-2차 단독(0.0561 ms) 대비 운영점이 0.0111 ms에 놓인다. 곡선의 왼쪽 끝이 CNN 단독, 오른쪽 끝이 char-CNN 단독이라는 점이 이 구조의 핵심 성질이다.

### 3.1 미결 과제 — 확신도 게이트는 ‘나쁜 라우터’다

oracle 라우팅(1차가 틀린 샘플만 정확히 승급했을 때의 상한)과 비교하면 격차가 큼.

| 1차   | oracle esc | oracle Macro-F1 | 실측 게이트가 같은 수준에 쓰는 esc | 과잉 배수 |
|------|------------|-----------------|-----------------------|-------|
| gray | 3.96%      | 0.9968          | 78.36%                | 19.8배 |
| RGB  | 1.87%      | 0.9982          | 27.73%                | 14.8배 |

max softmax 확신도는 오답을 15~20배 과잉 포착.

문제는 정확도 상한이 아니라 **비용 상한**이며, 게이트를 개선하면(예측 엔트로피 · 상위 2개 마진 · temperature scaling) 정확도를 그대로 두고 에스컬레이션만 최대 -25.8pp 줄일 여지가 있음.

### 3.2 clean에서 새로 잡는 건 없다 (상보성 분석)

공격 21,907건 기준으로 캐스케이드와 char-CNN의 **탐지 집합이 완전히 동일**(둘 다 놓친 8건까지 같음).

즉 이 구조의 기여는 **탐지 집합의 확장**이 아니라 **비용 축소**.

## 4. RQ2 — 회피 강건성과 ‘비용 기반 공격’

실제 WAF 우회 기법(주석 삽입 `/**/`, 대소문자 랜덤화, 공백/탭 치환, URL·이중 인코딩, 동치 SQL 토큰 치환, XSS `String.fromCharCode`)을 누적  $k=1\sim5$ 로 적용한 problem-space 공격.

모든 변형은 의미를 보존함(실제로 동작하는 페이로드).

| 운영점                           | benign-evasion | any-misclass | esc (clean) | esc (공격 k=5) | 비용 증가        |
|-------------------------------|----------------|--------------|-------------|--------------|--------------|
| $\tau=0.9998$ (match-teacher) | 0.0001         | 0.3641       | 78.36%      | 79.96%       | 1.02배        |
| $\tau=0.5678$ (budget 5%)     | 0.0009         | 0.5557       | 2.54%       | 5.50%        | <b>2.17배</b> |
| 참고: char-CNN 단독               | 0.0001         | 0.2239       | —           | —            | —            |
| 참고: gray CNN 단독               | 0.0022         | 0.5944       | —           | —            | —            |

표 3. 회피 하 거동 ( $k=5$  기준). any-misclass = 변형 하 오분류율, 낮을수록 강건

### 4.1 $\tau$ 스펙트럼은 강건성 축에서도 성립한다

캐스케이드의 회피 강건성은  $\tau$  하나로 두 단독 모델을 연속 이동 — 높은  $\tau$ 는 char-CNN 쪽(0.364), 낮은  $\tau$ 는 CNN 쪽(0.556).

2장에서 주장한 “연속 스펙트럼”이 clean 정확도뿐 아니라 공격 하 강건성에서도 성립한다는 뜻.

다만  $\tau=0.9998$ 에서도 char-CNN 단독(0.224)에는 못 미치는데, 원인은 넘기지 않은 21.6%.

1차가 확신했기에 남은 샘플인데 변형되면 틀림 — “확신도가 높다”가 “변형에 강하다”를 뜻하지 않음.

### 4.2 캐스케이드 고유의 공격면 — 정확도가 아니라 지연을 표적으로

저에스컬레이션 운영점에서 공격은 정확도를 흔드는 것과 동시에 2차 호출을 2.17배로 늘려 예산 5% SLA를 깨뜨렸음(2.54% → 5.50%). 정확도 지표만 보면 전혀 보이지 않는 열화.

반대로 이미 78%를 넘기는 운영점은 증가 여지가 없어 1.02배에 그침 — 즉 비용 공격 표면은 캐스케이드가 싸게 돌아갈수록 커짐.

운영 시 에스컬레이션 비율을 지표로 모니터링하고 상한 규를 두는 완화책이 필요.

이 축은 제안 모델을 캐스케이드로 세웠기 때문에 비로소 존재하는 발견. 단일 모델만 다뤘다면 논문에 존재하지 않았을 결과.

## 5. RQ3 — 적대적 방어 학습

### 5.1 먼저 해결한 문제 — 방어할 대상이 이미 0

원래 RQ3의 주 지표였던 **benign-evasion**(공격→Normal 오분류 = 실제 WAF 우회)은 5개 모델 전부 ~0이었음(0.0000~0.0022).

이대로 실험하면 **0을 0으로 만드는 실험**이라 개선폭도 희생폭도 측정 불가능.

→ 주 지표를 **any-misclass**(변형 하 오분류율)로 옮기고, benign-evasion은 바닥 효과를 명시하며 보조 지표로 계속 보고.

이 교체는 결과를 보고 고른 것이 아니라, 근거가 되는 실측이 방어 실험 이전에 이미 존재했고 문서로 사전 고정.

### 5.2 방법론의 핵심 — seen / held-out 변형 분할

학습에 쓴 변형으로 평가하면 “본 적 있는 공격을 막았다”는 자명한 결과가 나옴.

그래서 변형 14종을 4계열(E 인코딩 / C 대소문자 / W 공백·주석 / S 구문동치)로 묶고 두 시나리오를 함께 돌림.

- **S-0 (seen)**: 4계열 전부를 학습에 사용 → **낙관 상한**. 방어가 원리적으로 얼마나 줄일 수 있는가
- **S-A (leave-encoding-out)**: 가장 강력한 인코딩 계열(E)을 학습에서 완전 배제 → **진짜 질문**.

미지의 변형에 일반화되는가

증강은 ‘추가’가 아니라 **치환** 방식(공격 클래스만 불어내면 FPR이 방어 효과가 아니라 분포 변화 때문에 움직임).

held-out 계열은 train은 물론 **val에도 넣지 않음**(조기 종료를 통한 간접 누수 차단).

캐스케이드는 학습이 없으므로 **1·2차 양쪽 방어본을 조립**하고  $\tau$ 를 그 구성의 val에서 **재선택**.

| 구성                          | 캐스케이드 (제안)    | $\Delta$ | 단일 RGB CNN (비교 기준) | $\Delta$ |
|-----------------------------|---------------|----------|--------------------|----------|
| base (방어 없음)                | <b>0.4707</b> | —        | <b>0.5981</b>      | —        |
| advtrain <b>S-0</b> $p0.25$ | 0.0318        | −43.89pp | 0.1955             | −40.26pp |
| advtrain <b>S-0</b> $p0.5$  | 0.0287        | −44.20pp | 0.2029             | −39.52pp |
| advtrain <b>S-A</b> $p0.25$ | 0.2780        | −19.27pp | 0.4693             | −12.88pp |
| advtrain <b>S-A</b> $p0.5$  | 0.4227        | −4.80pp  | 0.5704             | −2.77pp  |

표 4. 적대적 증강 후 any-misclass ( $k=5$ ).  $p$  = 증강 비율



| 가설                        | 판정          | 근거                                                                                                                                                      |
|---------------------------|-------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|
| <b>H3-1</b><br>강건성 개선     | 효과 있음       | S-0에서 40~44pp 감소 = 사전 기준(10pp)의 4배 이상. 단일 split 노이즈( $\pm 0.11$ pp)와 자릿수가 달라 CV 불필요                                                                     |
| <b>H3-2</b><br>대가 수용성     | △ 구조에 따라 갈림 | <b>캐스케이드는 전 구성 통과</b> (clean MCC 최대 $-0.12$ pp, FPR 변화 $0.00$ pp). <b>단일 CNN은 4셀 중 2셀 실패</b> (S-0 $p0.5 -1.86$ pp, S-A $p0.25 -3.81$ pp-FPR $+0.69$ pp) |
| <b>H3-3</b><br>미지 변형 일반화  | “본 변형 암기”   | S-A/S-0 감소폭 비 — 캐스케이드 $43.9\%(p0.25) \cdot 10.9\%(p0.5)$ , 단일 CNN $32.0\% \cdot 7.0\%$ . <b>네 경우 모두 사전 기준 50% 미달</b>                                    |
| <b>H3-4</b><br>학습형 vs 정규화 | 미판정         | 정규화 방어(입력 디코딩) 2셀 미실행 — 남은 작업                                                                                                                           |

표 5. 사전에 고정한 가설의 판정 결과

### H3-3이 이 Phase의 핵심 결과.

학습에 넣은 변형은 거의 완벽히 막지만( $0.47 \rightarrow 0.03$ ), 빼둔 인코딩 계열에는 거의 무력함.

base에서 오분류를 끌어올린 변형이 사실상

`space_to_comment(+0.635) · url_encode(+0.584) · double_url_encode(+0.572)` **3종뿐**이고,

그중 2종이 held-out이라 S-A는 **배울 것이 거의 없었음**.

이는 “인코딩 계열은 학습으로 못 막고 **입력 정규화**로 막는 종류”라는 가설을 강하게 지지.

### 5.3 캐스케이드는 방어 비용을 '정확도'가 아니라 '지연'으로 지불한다

| 구조         | clean MCC 하락                                | 공격 하 에스컬레이션        |
|------------|---------------------------------------------|--------------------|
| 단일 RGB CNN | 최대 $-3.81\text{pp}$ (FPR $+0.69\text{pp}$ ) | 해당 없음              |
| 캐스케이드      | 최대 $-0.12\text{pp}$ (FPR 변화 0)              | 34.97% → 최대 69.52% |

캐스케이드는 1차가 흔들려도 2차 char-CNN이 받아내므로 **정확도를 거의 잃지 않음**.

대신 1차 확신도가 낮아진 만큼 2차 호출이 늘어 **추론 비용이 최대 2배**가 됨.

**정확도 지표만 보면 “공짜 방어”로 오독되는 열화**이며, 4.2절의 비용 기반 공격과 직결.

## 6. 선행연구 대조와 주장 강도 하향

“비용 개선”을 헤드라인으로 세운 이상, 같은 축의 선행이 있는지를 먼저 조사함.

결과는 있었음.

### 6.1 최근접 선행 — Tasdemir et al. 2023 (SQLi 캐스케이드, 20배)

*Advancing SQL Injection Detection for High-Speed Data Centers: A Novel Approach Using Cascaded NLP*  
(arXiv:2312.13041, QUB + NVIDIA).

1차 Passive Aggressive Classifier → 2차 BERT-Electra, accuracy 99.86%, transformer 단독 대비 **20배**.

본문을 전수 확인한 결과 겹치는 것은 프레이밍뿐이었음.

| 축       | Tasdemir 2023                 | 본 연구                                      |
|---------|-------------------------------|-------------------------------------------|
| 1·2차 표현 | 텍스트 → 텍스트 (동종)                | 이미지 → 텍스트 (이종)                            |
| 라우팅 기준  | 예측 클래스(양성이면 승급, Viola-Jones식) | 예측 불확실성( $\max \text{softmax} < \tau$ )   |
| 운영점     | 고정 1개                         | $\tau$ 연속 곡선, 양 끝점이 두 단독 모델로 수렴           |
| 과제      | SQLi 이진                       | SQLi / XSS / CmdI / Normal <b>4-class</b> |
| 게이트 품질  | 미분석                           | <b>oracle 대비 14.8배</b> 과잉 정량화             |
| 회피 강건성  | 없음(본문 전수 검색 결과 0)             | RQ2 / RQ3 전 축                             |
| 통계 검정   | 없음                            | 5-fold CV + Holm 보정                       |
| 속도 배수   | 20× (기준 = BERT)               | 5.07× (기준 = char-CNN)                     |

표 6. Tasdemir 2023과의 대조 — 이 표가 차별화의 근거

**배수(20배 vs 5.07배)를 직접 비교 X.**

2차 기준 모델이 다릅니다(BERT vs char-CNN). BERT가 훨씬 무거워 분모가 크므로 배수가 크게 나옵니다.

논문에는 기준 모델을 반드시 명시해 기록.

## 6.2 조사 결과 스스로 낮춘 주장 3건

| 항목                   | 선행                                                                   | 조정 내용                                                                                                                                                                                          |
|----------------------|----------------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 비용 기반 공격             | DeepSloth (ICLR 2021 Spotlight) — 지연 1.5~5배 증폭                       | “새 공격면을 발견했다” → “DeepSloth의 slowdown 공격이 웹공격 탐지 캐스케이드에서도 성립함을 실측했다. 단 DeepSloth는 픽셀 <b>gradient</b> 교란(화이트박스)인 반면 본 연구는 <b>모델 접근 없이, 실제로 동작하는 페이로드 변형만으로 달성했다</b> ” — <b>낮춘 문구가 오히려 더 강합니다</b> |
| 표현 불일치 탐지<br>(향후 M1) | Feature Squeezing (NDSS 2018) — 원본 vs 압축 입력의 예측 불일치                  | “표현 불일치를 쓰는 것이 새롭다” → “캐스케이드는 이미 2차를 돌리므로 <b>추가 비용이 정확히 0</b> ” — 메커니즘은 기지이고, <b>구조적 무상화</b> 가 유일한 기여                                                                                          |
| 다단 조기종료<br>(향후 M4)   | ACM SAC 2025 early-exit IDS, FastDet, ACM CSUR 서베이                   | 침입탐지 도메인에 직접 선행이 다수 → <b>우선순위 최하로 강등 권고</b>                                                                                                                                                    |
| RQ4 (암호화 경계)         | Kutlimuratov et al. 2026 (Computers 15,174) — 흐름 메타데이터만으로 470k req/s | “신호가 흐름으로 이동한다”는 결론의 <b>도착지에 이미 사람이 있음</b> → 기여를 “ <b>경계가 어디인지 정량 증명</b> ”으로 좁힘 (고정키 XOR F1 0.9445 유지 → AES 0.3965 붕괴, 즉 엔트로피가 아니라 <b>키 랜덤화</b> 가 원인)                                          |

## 6.3 반대로 확인된 우리 쪽 강점

- 개선폭 기준선이 낮음.

*Scientific Reports*(Tadhani 2024)의 헤드라인 개선은 **+0.34pp**, *Applied Sciences*(Eroğlu 2025)는 **+0.11~1.27pp**로 “surpassing existing benchmarks”라고 씀.

우리 gray→RGB **+2.69pp(5-fold CV)**는 한 자릿수 큼.

- 단, 우리가 가진 것은 아직 “**제안 모델도 흔들린다**”는 음성 결과가 중심.

## 7. 개정된 연구 질문과 기여

기존 RQ 표에는 캐스케이드를 묻는 질문 자체가 없었음.

RQ1을 "정확도 우월성"이 아닌 "정확도-비용 Pareto 상의 위치 규명"으로 정직하게 고치고,  
RQ5(캐스케이드)를 신설.

| ID  | 질문                                                                                                                                 |
|-----|------------------------------------------------------------------------------------------------------------------------------------|
| RQ1 | 페이로드를 바이트 이미지로 변환한 탐지는 텍스트 기반 모델 대비 <b>정확도-비용 Pareto 상 어디에 위치하는가?</b>                                                              |
| RQ5 | 확신도 게이트 캐스케이드는 그 Pareto 위의 두 점을 $\tau$ 하나로 잇는 <b>연속 곡선</b> 으로 바꾸는가? char-CNN급 정확도를 얼마나 싸게 살 수 있으며, 그 게이트는 <b>최적 라우터에 얼마나 근접한가?</b> |
| RQ2 | 캐스케이드는 실제 WAF 우회 기법에 얼마나 취약한가? 나아가 정확도가 아닌 <b>지연을 표적으로 하는 비용 기반 공격</b> 이 성립하는가?                                                    |
| RQ3 | 적대적 증강은 <b>학습에서 보지 못한 변형까지 일반화</b> 되는가? 캐스케이드에서 그 대가는 <b>어느 통화로 지불</b> 되는가?                                                        |
| RQ4 | 탐지 신호가 콘텐츠에서 사라질 때(인코딩→암호화), 내용 기반 이미지 탐지는 <b>어디서 원리적으로 붕괴</b> 하는가?                                                                |
| RQ6 | 1차와 2차의 <b>표현 간 불일치</b> 자체가 "회피 시도"의 탐지 신호가 되는가? (단일 모델은 원리적으로 불가)                                                                 |

표 7. RQ 표 (2026-08-06 개정). 논문 서술 순서는 RQ1 → RQ5 → RQ2 → RQ3 → RQ6, RQ4는 별도 축

## 7.1 논문이 주장하는 기여 — 선행 대조 후 확인한 문구

| #    | 기여                        | 쓸 문구                                                                                                                           |
|------|---------------------------|--------------------------------------------------------------------------------------------------------------------------------|
| C1   | 표현 이질적 캐스케이드              | “이미지 표현과 텍스트 표현을 잇는 캐스케이드로, <b>같은 정확도를 5.07배 싸게 얻는다</b> ” ( “이미지 기반이 더 정확하다”)                                                  |
| C2   | $\tau$ 연속 스펙트럼            | “ $\tau$ 하나가 clean 정확도뿐 아니라 <b>공격 하 강건성에서도</b> 두 단독 모델 사이를 연속 이동한다( $0.364 \leftrightarrow 0.556$ )”                           |
| C3   | problem-space slowdown 공격 | “DeepSloth가 보인 slowdown 공격이 웹공격 탐지 캐스케이드에서도 성립함을 실측했다. 단 <b>모델 접근 없이, 실제로 동작하는 페이로드 변형만으로 2.17배를 달성했다</b> ” ( “새로운 공격면을 발견했다”) |
| C4   | 게이트 품질 상한 정량화             | “확신도 게이트는 oracle 대비 <b>14.8배 과잉</b> 공급한다 — 개선 여지의 상한을 못 박았다”                                                                   |
| (C5) | 표현 불일치 회피 탐지              | “캐스케이드는 이미 2차를 돌리므로 <b>추가 비용 정확히 0</b> 으로 회피 시도를 판정한다”                                                                         |

## 7.2 정직하게 함께 쓸 한계

- 이미지 단독은 텍스트 모델에 **유의하게 진다**.
- clean 탐지 **상보성 이득이 없다** — 캐스케이드의 기여는 탐지 집합 확장이 아니라 비용 축소다.
- 적대적 증강은 본 **변형만** 암기한다.
- 소규모 배포에서는 char-CNN 단독으로 **충분하다**.
- **적응형 공격**(방어를 알고 설계된 공격)은 수행하지 **않는다** — 한계로 명시.
- 성능 차이는 **표면 토큰이 포화된** 트랙에서 측정됐다.
- ViT · hybrid(CNN stem + Transformer)는 CNN 대비 +0.12pp,  $\rho(\text{adj})=1.0000$ 으로 **미채택** — 시도했으나 안 됐음을 그대로 보고.

## 부록. 재현 · 검증 관련 메모

### A. 실험 환경

- 학습·측정: RTX 4080 SUPER / PyTorch cu124. 지연은 배치 512 순전파 기준 ms/sample, **CUDA synchronize 필수**(비동기 실행이라 동기화 없이 재면 0에 가깝게 나옴).
  - 전처리는 seed=42 결정론, Train/Val/Test = 70/15/15 stratified. 클래스 불균형은 train만 언더샘플링(val/test는 실분포 유지).
  - 모든 모델의 평가는 **단일 지표 모듈**로 일원화(계산 방식 차이 배제).
- 지표는 Accuracy · Macro-F1 · MCC · PR-AUC · ROC-AUC + attack-focused(benign-evasion / FPR).